

摊销层次与闭式读出： 面向数据推断泄露的可认证集合敏感度审计

杜浩存

(西安交通大学 西安 710049)

摘要 数据推断泄露的风险是可见字段集合上的集合函数 $v_c(S)$ ——攻击者拿到子集 S 后针对 S 重训所能达到的推断精度上限。子集空间达 2^{44} ，逐集合重训不可行，因而必须**摊销**：用一个共享模型回答所有子集查询。本文首先给出一个负面诊断：这种“全摊销”的误差并非随机分布，而是**系统性地集中在最危险的强协同集合上**。在 PJM 数据的 11352 条重训真值上，共享读出 oracle 的全局排序相关为 0.606，但真值最强的 100 个协同上排序相关坍缩至 0.130，最强档平均低估 0.124；三个排除性对照（逐集合仿射校准只把尾部相关修到 0.199、集成方差在最强档失明、三个独立种子结论一致）表明这是**表达力与共享参数干涉造成的系统性偏差**，而非尺度漂移或训练噪声。本文将其归因于摊销层次错配： $v_c(S)$ 是内层优化的最优值，而摊销间隙恰在“最优解离共享平均解最远”的实例上最大，强协同正属此类。据此提出把摊销层次由“值”上移到“表示”：主干 $\varphi_\theta(x \odot m_S, m_S)$ 摊销条件特征，读出权重按集合闭式重解 $\beta_{S,c} = (\Phi^\top \Phi + \lambda I)^{-1} \Phi^\top Y_c$ 。直接复用现成主干（零训练）即把尾部排序相关由 0.130 提升至 0.781、最强档低估由 0.124 降至 0.016，性能超过 50 步查询微调而快 22.4 倍；把闭式头放进训练回路进一步提升至 0.858。在此基础上给出“摊销扫描—配对 FDR—重训认证”三层管线，并坚持“重训真值只用于评估与认证、绝不进入查询路径”的方法学红线。高阶实验给出一个被认证推翻的反例：手工多项式字典在五阶报出 441 个强协同，重训认证后**无一为真**、与随机对照无统计差异；而学出的表示在同一空间全枚举 108.6 万个集合，自选 top 经认证 10 个为真。由此定标出真值版衰减律（三至五阶最强协同 $0.455 \rightarrow 0.196 \rightarrow 0.154$ ，密度每阶降约一个数量级），并证明跨独立种子的**秩一致性**可把候选精确率由 45% 提升至 100%——对付共享摊销偏差须用秩统计而非集成方差。全部结论在第二个电网数据集 (CAISO) 上完整复现：方法阶梯同构（尾部 $0.596 \rightarrow 0.931 \rightarrow 0.969$ ）、自选候选认证精确率 95%、字典在五阶系统性膨胀 1.7 倍且无一为真、衰减律更陡（ $0.294 \rightarrow 0.157 \rightarrow 0.104$ ）。

关键词 数据推断泄露；集合函数；摊销优化；闭式读出；协同效应；假发现率；可认证审计

Amortization Level and Closed-Form Readout: Certifiable Set-Sensitivity
Auditing for Data Inference Leakage

DU Hao-Cun

(Xi'an Jiaotong University, Xi'an 710049, China)

Abstract The risk of data inference leakage is a set function $v_c(S)$ over subsets of visible fields: the best inference accuracy an attacker can reach by retraining on S . With 2^{44} subsets, per-subset retraining is intractable, so the mapping must be *amortized* into a single shared model. This paper first reports a negative diagnosis: the error of such full amortization is not random but *systematically concentrated on the most dangerous, strongly synergistic subsets*. On 11352 retraining ground-truth entries from PJM data, a shared-readout oracle attains a global rank correlation of 0.606, yet on the 100 strongest true synergies the rank correlation collapses to 0.130 with an average underestimation of 0.124. Three control experiments—per-subset affine recalibration lifts the tail correlation only to 0.199, ensemble variance is flat on the strongest band, and three independent seeds agree—show this is a *systematic bias from limited expressiveness and shared-parameter interference*, not a scale drift or training noise. We attribute it to a mismatch in the amortization level: $v_c(S)$ is the *optimal value* of an inner optimization, and the amortization gap is largest precisely where the per-instance optimum is farthest from the shared average solution—which is what strong synergy is. We therefore lift amortization from the value to the representation: a backbone $\varphi_\theta(x \odot m_S, m_S)$ amortizes conditional features while readout weights are re-solved per subset in closed form, $\beta_{S,c} = (\Phi^\top \Phi + \lambda I)^{-1} \Phi^\top Y_c$. Reusing an off-the-shelf backbone with zero training raises the tail rank correlation from 0.130 to 0.781 and cuts the strongest-band underestimation from 0.124 to 0.016, outperforming 50-step query-time fine-tuning while being $22.4\times$ faster; training with the closed-form head in the loop further raises it to 0.858. We then give a three-tier pipeline—amortized scan, paired FDR test, retraining certification—under the methodological red line that retraining truth is used only for evaluation and certification, never inside the query path. A certified counterexample follows: a handcrafted polynomial dictionary reports 441 strong fifth-order synergies of which *none* survives retraining certification (indistinguishable from a random control), whereas the learned representation, enumerating all 1.086 million fifth-order subsets, yields a self-selected top list with 10 certified true synergies. This calibrates a certified decay law (strongest synergy $0.455 \rightarrow 0.196 \rightarrow 0.154$ from third to fifth order, density dropping about one order of magnitude per level) and shows that *rank agreement across independently retrained seeds* raises candidate precision from 45% to 100%—shared amortization bias must be attacked with rank statistics rather than ensemble variance. All conclusions replicate on a second grid dataset (CAISO): an isomorphic method ladder ($0.596 \rightarrow 0.931 \rightarrow 0.969$ on the tail), 95% certified precision of self-selected candidates, systematic $1.7\times$ inflation of the dictionary at fifth order with zero true positives, and a steeper decay law ($0.294 \rightarrow 0.157 \rightarrow 0.104$).

Keywords data inference leakage; set function; amortized optimization; closed-form readout; synergy; false discovery rate; certifiable auditing

1 引言

电网、金融、医疗等领域的运行数据在跨主体共享前通常只做“删除机密字段”这一步脱敏，但保留字段之间由物理定律与统计规律决定的耦合，使攻击者仍能用公开字段训练推断模型间接恢复被删除的量，即数据推断泄露（Data Inference Leakage, DIL）^[1]。已有工作多为**每个字段**输出一个标量敏感度分数，而泄露的本质是字段**集合**的属性：存在大量“单看安全、合体泄露”的组合。以本文 PJM 数据为例，风电出力与风电占比各自单独推断总发电量的测试 R^2 仅 0.064 与 0.162，两者同时可见时跃升至 0.928——因为总量在物理上等于出力除以占比。因此敏感度评估必须升维为定义在任意字段集合上的集合函数 $v_c(S)$ 。

升维之后的困难在于**评估成本**。忠实的 $v_c(S)$ 要求“攻击者最优响应”语义，即对每个 S 从头重训攻击者至最优；44 个字段的子集空间达 $2^{44} \approx 1.8 \times 10^{13}$ ，而单次重训需分钟级开销。唯一现实的出路是**摊销**：训练一个以可见性掩码为条件的共享模型，一次前向回答任意子集查询。这正是摊销优化^[2]与摊销归因^[3-4]的标准范式，在本文的前置工作中也确实把单集合评估成本从分钟级降到毫秒级。

然而本文的出发点是一个负面观察：**这种摊销在最需要它准的地方最不准**。图 1 左给出直观证据——共享读出 oracle 在全体 11352 条重训真值上排序相关 0.606 看似可用，但把视野限制到真值最强的 100 个协同（安全审计唯一真正关心的那一档），排序相关坍塌到 0.130，估计值几乎与真值无关。换言之，一个“平均意义上不错”的摊销估计器，在尾部是失明的。若不修正，基于它的一切风险排序、防护集选择与高阶搜索都建立在流沙之上。

本文认为这不是工程调参问题，而是**摊销层次的错配**。 $v_c(S)$ 是一个内层优化问题的**最优值**（value function），而摊销间隙的已知性质是：在“逐实例最优解离共享平均解最远”的实例上最大^[2, 5]；强协同集合恰恰是这种实例——它要求模型实现一个仅在该子集上成立的精确配合（如除法电路），而这种掩码在训练中出现概率极低。更关键的是，协同 $\text{syn} = v(S) - \max_T v(T)$ 是两个同量级数的差，误差为两个间隙之差，而间隙在强协同 S 上大、在其平庸父集 T 上小，于是协同被**系统性压低**。

据此，本文把摊销层次从“值”上移到“表示”：让共享主干只负责摊销**条件特征** $\varphi_\theta(x \odot m_S, m_S)$ ，而把读出权重按集合闭式重解。这一改动使每个子集拥有自己的、不与其他子集共享的解，从而消除干涉；同时保留一次前向的摊销效率，因为闭式解只是一个小规模线性系统。实验表明，即便完全复用为共享读出训练的现成主干（零额外训练），尾部排序相关就从 0.130 升到 0.781、最强档低估从 0.124 降到 0.016，且超过 50 步查询微调的效果而快 22.4 倍。

有了可靠的估计器，才谈得上在指数空间里做发现。本文给出“摊销扫描—配对 FDR—重训认证”三层管线，并在全程坚持一条方法学红线：**重训真值只用于评估与认证，绝不进入查询、路由或校准路径**——否则“估计器有多准”会退化为不可证伪的循环论证。该管线在高阶实验中给出了一个有警示意义的结果：手工多项式字典在五阶报出 441 个 $\text{syn} > 0.2$ 的“强协同”，重训认证后**无一为真**，与随机对照组无统计差异（ $p = 0.058$ ）；而学出的表示全枚举同一空间的 108.6 万个集合后零个 $\text{syn} > 0.2$ ，其自选 top-21 经认证有 10 个为真。这说明高阶发现的瓶颈不在搜索策略而在**估计器的可信度**。

本文主要贡献如下：

(1) **诊断**。指出并量化全摊销集合敏感度估计的**尾部失明**现象，用三个排除性对照证明其为系统性偏差而非噪声或尺度问题，并以“值函数摊销间隙”给出机制归因（第 4 节）。

(2) **方法**。提出摊销表示 + 逐集合闭式读出，给出零训练（L0）与元训练（L1）两个实例，并把手工字典、L0、L1、微调统一为沿“表示适应程度”排列的连续谱；配合三层审计管线与方法学红线（第 5 节）。

(3) **实验与定标**。在两个真实电网数据集上系统验证：尾部保真度、成本、高阶认证对决、真值版衰减律、跨种子秩一致性过滤；并给出对既有手工字典方法的**认证级证伪**（第 6 节）。

2 相关工作

数据敏感度评估。IGNN^[1] 将电网字段间推断关系组织为图，用图注意力网络输出字段级敏感度，是本文的直接背景。本文与它的根本差别在于输出粒度（单字段分数升维为任意集合的集合函数）与测量口径（固定模型下的风险传播改为逐集合重训的最优响应）。

特征子集贡献与高阶交互。SHAP^[6] 与交互指标的公理化^[7] 刻画**固定模型**在特征扰动下的行为；FastSHAP^[3]、ViT-Shapley^[4] 用摊销网络加速归因。这些方法摊销的是**标量归因值**，正是本文诊断为尾部失明的“值摊销”。ProxySPEX^[8] 等高阶交互搜索依赖层级性假设（高阶交互的低阶子集也显著）以控制搜索代价；本文的可靠估计器使五阶以内可直接全枚举，从而把层级假设的适用性问题转为可测量的漏检率。Datamodels^[9] 在训练数据维度拟合“子集 $\mapsto$ 性能”，与本文在特征维度的工作平行。

摊销优化与闭式基学习器。摊销间隙及其在“难实例”上放大的性质在变分推断^[5] 与摊销优化综述^[2] 中已有讨论，本文把它迁移到集合函数估计并给出安全语义下的后果。R2D2^[10] 与 MetaOptNet^[11] 在小样本分类平均准确率上使用可微闭式基学习器；本文把同一机制用于**集合函数的尾部**——在安全审计里恰好只有尾部重要——并给出“摊销间隙集中在哪类实例”的定位与认证证据。LQF^[12] 与神经正切核^[13] 提供“凸化适应”的相关背景，但它们改造损失与整个模型，本文只重解读出层，零训练即用。

任意条件建模。VAEAC^[14]、ACFlow^[15]、GRAPE^[16] 学习任意观测子集条件化的模型，本文在“随机掩码训练”机制上与之同源，但目标是集合函数的忠实估计而非数据分布建模。多重检验方面，本文采用 Benjamini-Hochberg 程序^[17] 控制假发现率。

3 问题形式化

3.1 威胁模型

设数据表含字段集 F ，其中规程认定的机密字段集为 $C \subset F$ ，其余为一般字段集 $G = F \setminus C$ （本文两个数据集均为 $|G| = 44$ 、 $|C| = 12$ ）。共享时机密字段被删除，攻击者获得某可见集合 $S \subseteq G$ 的完整列数据，并假设其拥有同分布历史样本、知晓字段语义、可从任意模型族训练推断模型。这是对攻击者有利的保守假设，据此得到的是风险上界。防御方目标：对任意拟共享集合 S ，评估每个机密字段被推断的风险，并定位构成协同泄露的字段组合。

3.2 集合敏感度与不可约协同

定义 1 (集合敏感度) 给定机密字段 $c \in C$ 与可见集合 $S \subseteq G$,

$$v_c(S) = \max\left(0, \sup_{g \in \mathcal{G}} R_{\text{test}}^2(g(X_S); x_c)\right), \quad (1)$$

其中 X_S 为仅保留 S 中字段的数据，上确界取在模型族与训练过程之上。

式 (1) 的上确界语义是**攻击者最优响应**：对每个 S 攻击者从头重训至最优。这一点是本文全部方法论的支点——它意味着 $v_c(S)$ 是一个**内层优化问题的最优值**，而不是某个固定模型的读数。第 4 节将说明，正是这一“最优值”属性决定了全摊销失效的形态。

定义 2 (k 阶不可约协同) 对 $|T| = k \geq 2$,

$$\text{syn}_k^c(T) = v_c(T) - \max_{T' \subset T, |T'|=k-1} v_c(T'), \quad \text{syn}_k(T) = \max_{c \in C} \text{syn}_k^c(T). \quad (2)$$

采用“减去最优低阶子集”而非全交互展开源于安全语义：防御者关心“同时放行 T 是否比放行其任何真子集更危险”。注意 syn 是两个同量级数的差分，这一结构在第 4 节被证明是尾部失明的放大器。

3.3 测量口径、噪声底与方法学红线

本文以重训为唯一真值口径：对每个待测集合从头训练专用推断模型并实测保留集 R^2 。同集合不同种子重复重训的复现噪声底实测 $\sigma \approx 0.002\text{--}0.004$ ，据此取协同显著阈 $\text{syn} > 0.10$ （约噪声底 25 倍以上）。

数据被切分为训练集、搜索片 (search) 与审计片 (audit) 三部分：所有自适应选择（选哪个机密字段、选哪个最强父集、选哪些候选）只允许在搜索片上做，审计片只用于最终报数与检验，以避免选择性推断带来的赢家诅咒。

最后，本文坚持一条**方法学红线**：重训真值只允许出现在评估与认证环节，**绝不允许进入查询、路由或校准路径**。理由是部署时数据持有方没有任何真值可用；一旦把真值塞进查询路径，“估计器逼近得多准”就变成不可证伪的循环论证。本文在方案设计阶段以“承认性检查”执行该红线：把估计器拿掉、只留真值查表，看效果还剩多少——若大部分效果来自查表本身，该方案即被否决。

4 诊断：全摊销为何在最危险处失效

4.1 现象：尾部失明

全摊销 oracle 的标准形态是：主干接收 $[x \odot m_S, m_S]$ ，经共享读出层输出对 $|C|$ 个机密字段的预测，训练时用随机子集失活遍历掩码空间。这一设计在平均意义上是成功的：在 PJM 的 11352 条 (i, j, c) 重训真值上，其协同估计与真值的 Spearman 相关为 0.606。

但把视野收缩到尾部，结论完全反转。图 1(左) 中红色点为真值最强的 100 个协同：它们的估计值大量塌陷到 0 附近，与真值几乎无关，尾部 Spearman 仅 **0.130**；真值 top-10 的集合在估计排序中的中位名次是 **6527**（共 11352 条）。分档统计（图 3(a)）给出更清晰的形态：弱档（真值 < 0.1 ）平均低估 0.007，中档 0.037，而强档（真值 > 0.2 ）平均低估 **0.124**——低估量随真值强度单调放大。这正是安全审计最不能接受的失效模式：越危险的组合，越被判为安全。

4.2 三个排除性对照

尾部失明可能有三种平凡解释，本文逐一排除。

(1) 是不是尺度漂移？若 oracle 只是输出的尺度或偏置有系统性漂移，那么逐 (S, c) 的两参数仿射校准 $a \cdot \hat{v} + b$ (a, b 在训练集上最小二乘拟合) 应当能补回大部分。实测仿射校准把全局相关从 0.606 提到 0.676，但尾部相关只从 0.130 提到 **0.199**，真值 top-10 的中位名次反而从 6527 退到 8871。结论：这是**表达力**问题，不是尺度问题。

(2) 是不是训练噪声？若失效源于随机性，同族集成的方差 σ 应在失效处变大，从而可用“不确定度路由”识别。但实测集成方差在最强档是**平的**——因为所有集成成员共享同一结构性偏差，方差看不见它。结论：这是**系统性偏差**，标准的不确定度路由在此原理性失效。

(3) 是不是某次训练的偶然？三个独立种子训练的 oracle 给出一致的尾部失明形态（第 6.8 节的第二数据集也复现同一形态）。结论：这是该架构的稳定属性。

4.3 机制：值函数的摊销间隙

排除平凡解释后，本文给出机制归因。 $v_c(S)$ 由式 (1) 定义为内层优化的最优值，全摊销相当于用一组共享参数 θ 去逼近全部 $2^{|G|}$ 个子集各自的最优解 g_S^* 。摊销优化文献指出，摊销间隙 $\Delta(S) = v_c(S) - \hat{v}_\theta(S)$ 在**最优解离共享平均解最远**的实例上最大^[2, 5]。强协同集合正是这类实例：它要求模型实现一个仅在该特定子集上成立的精确配合（例如“出力除以占比得总量”），而该掩码在随机子集失活训练中出现的概率仅万分之几。

更致命的是协同的**差分结构**。由式 (2)，

$$\widehat{\text{syn}}_k(T) - \text{syn}_k(T) = \Delta(T') - \Delta(T), \quad (3)$$

其中 T' 为最强低阶子集。强协同 T 上 $\Delta(T)$ 大、平庸父集 T' 上 $\Delta(T')$ 小，故差值为负且随协同强度放大——协同被系统性压低。两个 0.8 量级的数相减得到 0.1 量级的量，任何在被减数上的系统性偏差都会被放大到结果中。




图 1 PJM 二阶协同：估计 vs 重训真值 (11352 条)。红点为真值 top-100。左：共享读出 oracle 的尾部塌陷 ($\rho_{tail} = 0.130$)；中：冻结主干 + 闭式读出 (零训练, 0.781)；右：闭式头进训练回路 (0.858)

5 方法：摊销表示与闭式读出

5.1 核心思想

诊断指向的修复方向是明确的：既然失效源于**读出权重被所有子集共享**，那就让读出权重按集合独有。但若为每个子集单独训练读出层，就退回了逐集合优化的高成本。本文的做法是让读出层有**闭式解**——岭回归。于是 (图 2)：

$$\Phi_S = \varphi_\theta(X \odot m_S, m_S) \in \mathbb{R}^{n \times d}, \quad (4)$$

$$\beta_{S,c} = (\Phi_S^\top \Phi_S + \lambda I)^{-1} \Phi_S^\top y_c, \quad (5)$$

$$\hat{v}_c(S) = \max\left(0, 1 - \frac{\|y_c^{\text{ev}} - \Phi_S^{\text{ev}} \beta_{S,c}\|^2}{\|y_c^{\text{ev}} - \bar{y}_c\|^2}\right). \quad (6)$$

主干 φ_θ 仍然摊销（一次前向对所有子集共享），但式 (5) 的 $\beta_{S,c}$ 是**每个 (S, c) 独有的**，不与任何其他子集共享参数，因而不受干涉。计算上，每次查询只需一次前向加一个 $d \times d$ 线性系统求解，仍是毫秒量级。

正则系数 λ 在训练集内部再切分的拟合/验证片上逐 (S, c) 独立选取（网格 10^{-3} 至 10^2 ），随后用全部训练数据重拟合、在审计片上评估——评估片从不参与 λ 选择或拟合。

5.2 两个实例：L0 与 L1


L0 (零训练)：直接取现成 oracle 主干的倒数第二层激活作为 φ ，主干完全冻结。这是最保守的实例——它不需要任何额外训练，唯一的改动就是把最后一层从“共享权重”换成“逐集合闭式解”，因而构成一个单变量受控对照，可以干净地把收益归因于读出层而非别的因素。

L1 (元训练)：把闭式头放进训练回路，梯度反传穿过式 (5) 的求解算子， λ 以对数参数化与主干联合学习 (R2D2/MetaOptNet 式^[10-11])。动机是：L0 的主干是为共享读出训练的，它并不知道自己的读出层将被逐集合重解，于是仍把容量花在“记住每个掩码该输出什么”而非“造一组好重解的基”。每个元步骤采样若干掩码，每个掩码从训练集抽 support 与 query 两批样本，用 support 闭式求解、在 query 上算损失。

5.3 统一视角

本文指出，四类方法是同一框架沿“表示适应程度”排列的四个点：手工多项式字典 (φ 冻成固定基)、L0 (φ 为冻结的学习表示)、L1 (φ 为面向重解而元训练的表示)、查询时微调 (φ 与 β 都动)。这一视角的价值在于：手工字典不是“另一类方法”，而是本框架的退化情形；第 6.4 节将证明这个退化情形在高阶上会系统性地报假。

摊销层次：把“值”摊销改为“表示”摊销



三层审计管线




图 2 方法总览。上：摊销层次由“值”上移到“表示”，读出权重逐集合闭式重解；下：三层审计管线与方法学红线

5.4 三层审计管线

估计器可靠之后，发现流程组织为三层（图 2 下半）：

第 1 层：摊销扫描。用 L1 对目标阶数做全枚举（本文 $k \leq 5$ ，五阶空间 $\binom{44}{5} = 1086008$ ），单集合约 2.5 ms，四卡约 13 分钟扫完。输出按 syn 降序的候选榜。注意全枚举使得“层级搜索是否漏检”这一长期困扰高阶交互发现的问题在 $k \leq 5$ 被消解而非绕过。

第 2 层：配对检验与 FDR。闭式读出的一个结构性优势是： S 与其父集 T 的预测误差来自同一个 φ 、同一批审计样本，可逐样本配对，且闭式解没有优化噪声（微调则两边各带独立的初始化与批序噪声，差分方差放大 $\sqrt{2}$ ）。构造逐样本配对差 $d_i = e_T^2(i) - e_S^2(i)$ ，检验 $H_0: \text{syn} \leq \tau$ ，单边 t 检验后做 BH-FDR^[17]。

选择（选 c 、选最强父集）在搜索片完成， p 值只在审计片算一次。

第 3 层：重训认证。对 top- K 候选（及随机对照组）逐个重训专用模型：对 $|S| = m$ 的集合重训 $1 + m$ 个模型（ S 自身与全部 $m - 1$ 阶子集），得 syn 的重训真值。早停用使用**训练集内部**划出的验证片，测试集完全不参与训练与早停。这一层昂贵（约 160 s/集合）但忠实，是唯一被允许写进结论的口径。

Algorithm 1 三层协同发现与认证

Require: 数据 X 、机密集 C 、阶数 k 、阈值 τ 、认证预算 K

```

1: 训练 L1 主干  $\varphi_\theta$ （随机子集失活 + 闭式头在回路内）
2: for all  $|S| = k$  与其全部  $(k-1)$  阶子集 do
3:   由式 (4)–(6) 算  $\hat{v}_c(S)$ ，得  $\widehat{\text{syn}}_k(S)$  ▷ 全枚举， $\sim 2.5$  ms/集合
4: end for
5: for all 候选  $S$  do
6:   在搜索片选  $c^*$  与最强父集  $T^*$ 
7:   在审计片算配对  $t$  统计量与  $p$  值（ $H_0 : \text{syn} \leq \tau$ ）
8: end for
9: BH-FDR ( $q = 0.05$ ) 得统计保证清单  $\mathcal{L}$ 
10: 从  $\mathcal{L}$  取 top- $K$  与随机对照组，逐个重训认证
11: return 认证清单与 Mann–Whitney 组间检验结果

```

6 实验

6.1 实验设置

数据集。主数据集为 PJM 区域 2025 年小时级运行数据（8760 行，清洗后 6556 行有效），44 个一般字段、12 个机密字段（含总发电量、计量负荷、净/毛交换功率、系统损耗、日前与实时阻塞价格、边际损耗价格、日前总电价、三类备用总量）。第二数据集为 CAISO 2025 年小时级数据（8760 行，清洗后 8722 行），原始 307 列经字段设计收缩为同样的 44+12 结构（详见 6.8 节）。两者均按 7:3 随机切分训练与保留集，保留集再对半切分为搜索片与审计片。

真值。二阶真值为全部 44 个单字段与 946 个字段对逐个重训（990 次），三阶为随机抽取的无偏三元组池，四、五阶为候选与对照的逐集合认证。重训协议：专用多层感知机（两隐层 128 维、dropout 0.15）、Adam (10^{-3} ，权重衰减 5×10^{-4})、最多 400 轮、耐心 120 轮，早停用训练集内部 15% 验证片。

指标。全局排序相关 ρ (Spearman)、**尾部排序相关** ρ_{tail} （真值 top-100 内部）、分档低估量 gap（真值减估计）、真值 top-10 的估计排名中位数、认证精确率（top- K 中真值 > 0.10 的比例）。

6.2 RQ1：尾部失明及其修复

表 1 给出全空间（11352 条）上沿“表示适应程度”排列的方法阶梯。共享读出 oracle 的全局相关尚可（0.606）而尾部坍缩（0.130）；仿射校准修不动尾部（0.199）；换成闭式读出后尾部跃升至 0.781（L0）与 0.858（L1）。值得注意的是，poly2 手工字典在二阶上的尾部表现（0.760）已远好于共享读出 oracle——这本身就说明问题出在读出层的共享而非特征的质量。

为把收益干净地归因到读出层，本文另做一个**单变量受控对照**：在按真值强度分层抽样的 960 条记录

表 1 二阶协同的方法阶梯 (PJM, 11352 条重训真值; audit 片)

估计器	ρ	ρ_{tail}	真 top-10 中位名次
共享读出 oracle (全摊销)	0.606	0.130	6527
+ 逐 (S, c) 仿射校准	0.676	0.199	8871
poly2 手工字典 + 闭式	0.680	0.760	4.5
L0 : 冻结 φ + 闭式	0.732	0.781	4.5
L1 : 闭式头进训练回路	0.808	0.858	4.5

上, 固定同一主干、只改变最后一层的处理方式。结果 (图 3(a)) 显示, 共享读出在强档低估 0.124, L0 降至 0.016, 而 50 步查询微调仅降到 0.036; 全局相关上 L0 (0.904) 也**超过 50 步微调** (0.899)。即: 唯一改动“最后一层是否逐集合重解”就能取得比微调整个网络更好的效果。




图 3 (a) PJM 单变量受控对照: 低估值随真值强度分档 (共享读出在强档低估 0.124, 闭式读出降至 0.016, 优于 50 步微调的 0.036); (b) 两个数据集上的方法阶梯 (尾部排序相关), 形态同构

6.3 RQ2: 成本

表 2 与图 4 给出三阶查询的实测成本。闭式读出 2.475 ms/集合, 相对 25 步微调 (55.5 ms) 快 **22.4 倍**, 同时精度更高; 共享读出 oracle 虽然最快 (0.32 ms), 但如前所述在尾部不可用。这一“更快且更准”的组合正是把摊销放在表示层的直接收益: 适应发生在闭式解里, 而不是梯度步里。

表 2 单集合查询成本与保真度 (PJM, 三阶, 200 个集合实测)

方法	ms/集合	相对微调加速	ρ
共享读出 oracle	0.32	172.9×	0.686
25 步查询微调	55.49	1.0×	0.876
L0 闭式读出	2.48	22.4×	0.904




图 4 成本—保真权衡。闭式读出同时占据“更快”与“更准”

6.4 RQ3：高阶决战——手工字典的认证级证伪

高阶（四、五阶）没有现成真值，必须靠认证。本文让两个估计器各自**自选** top 候选，再送同一套重训认证流程，另配随机对照组（从弱估计集合中随机抽取），用 Mann-Whitney 单边检验判断强组是否真的强于对照。

结果构成本文最强的负面证据（图 5 左、中）。手工 full 字典在五阶报出 441 个 $\text{syn} > 0.2$ 的强协同（最大 0.514），其 top-40 经重训认证后：认证均值仅 **0.031**，**无一超过 0.10**，65% 的集合出现“子集反超”（某个四阶子集的真值反而高于五阶全集，即根本没有增量），与随机对照组**无统计差异**（ $p = 0.058$ ）。机制是清楚的：字典在小子集上过拟合，差分把过拟合量记成了“高阶增量”，且字典越复杂越严重。

同一空间上，L1 全枚举 108.6 万个五阶集合，报出的最大 syn 为 **零个超过 0.2**；其自选 top-21 经认证有 **10 个超过 0.10**（最强 0.154），显著强于 full 的 top（ $p = 0.013$ ）与随机对照（ $p = 0.003$ ），且真强的那一半估计几乎无偏（0.143 对 0.154）。四阶复现同一结论：full 的 top-20 认证后 0 个过 0.10，L1 的 top-20 有 9 个过 0.10（最强 0.196）。此外，L1 还**正确否决**了 full 的整个候选榜——full 的假 top-40 在 L1 的排序中位名次为 438504/1086008，前 1000 名内 0 个。

这里也须诚实报告 L1 的局限：图 5(中) 显示其 top 候选呈**双峰**——一半认证为真（0.12–0.16），一半塌到 0.03 附近，单种子精确率约 48%。这说明结构化估计仍只是**候选生成器**，而非终值；6.7 节给出把精确率提到 100% 的过滤手段。

6.5 RQ4：真值版衰减律与反层级协同

以认证结果为准，本文给出协同强度与密度随阶数的定标（图 6、表 3）。PJM 上三至五阶的最强真值为 $0.455 \rightarrow 0.196 \rightarrow 0.154$ （衰减 2.3 倍再 1.3 倍，温和单调），密度（ $\text{syn} > 0.10$ 的比例）为 $0.498\% \rightarrow$




图 5 五阶协同的重训认证。左：PJM 上手工字典 top-40 全部塌陷（点远离对角线且全在 0.10 以下）；中：L1 自选 top-21 有 10 个为真，呈双峰；右：CAISO 上字典同样 0/20 为真，并系统性膨胀 1.7 倍

0.069% $\rightarrow$ 0.0051%（每阶下降 7–13 倍）。三阶数字由两条独立路径互证：专用重训给 0.455，配对 FDR 的统计口径给 0.461。

该定标有直接的安全含义：**最危险的协同是低阶的**。同时它也修正了本文前置工作中两个先后出现的错误结论——基于 poly2 字典曾得到“三到四阶存在断崖式下跌”，基于 full 字典曾得到“高阶不衰减、风险被系统性低估”；认证表明两者都是**字典假象**。这段修正链本身是本文方法论主张的最好例证：没有重训认证做裁判，结构化估计的任何定量结论都可能是估计器的伪影。

表 3 真值版衰减律（两个数据集，均以重训认证为准）

阶 k	PJM		CAISO	
	最强真值	密度	最强真值	密度
3	0.455	0.498%	0.294	0.921%
4	0.196	0.069%	0.157	0.031%
5	0.154	0.0051%	0.104	≈ 0

反层级协同。ProxySPEX^[8] 等阶搜索依赖层级性假设：高阶强交互的低阶子集也应当强，从而可用 beam 搜索逐层展开。本文用**认证过的真五阶协同**直接测量该假设：10 个已认证真协同的最好四阶父集在四阶全扫中的排名为 164–2429，即 beam 宽度 $B = 100$ 会全部漏掉、 $B = 1000$ 漏 4 个、 $B = 5000$ 才全覆盖。结论是双面的：反层级协同确实存在且幅度不可忽略，但由于 L1 查询仅 2.5 ms， $k \leq 5$ 可直接全枚举，因而该问题在本文管线中被**消解而非绕过**（ $k \geq 6$ 仍为开放问题）。

6.6 RQ5：统计层——配对 FDR 的筛选力

硬阈值“ $\widehat{\text{syn}} > \tau$ ”不带任何错误率保证。第 2 层的配对检验把它换成统计判断：PJM 三阶全扫的 13244 个三元组中， $\tau = 0.10$ 的硬阈值给出 1924 个，过 BH-FDR ($q = 0.05$) 后只剩 **66 个 (3.4%)**；CAISO 上同一口径为 1526 个收缩到 122 个（图 7）。

一个值得记录的观察是： $\tau = 0$ 的点零假设**没有筛选力**——PJM 上 57.5%、CAISO 上 69.9% 的三元组都能拒绝“增量为零”，因为“多给一个字段几乎总能带来一点统计可检测的信息”。审计要控制的错误是“声称 $\text{syn} > \tau$ 但实际不足”，因此 τ 必须取审计真正关心的强度而非 0。




图 6 真值版衰减律。(a) 最强协同强度温和单调衰减；(b) 强协同密度每阶下降约一个数量级。CAISO 比 PJM 更陡




图 7 CAISO 三阶：配对检验 + BH-FDR 把“看起来强”收缩为“站得住”。 $\tau = 0$ 无筛选力

6.7 RQ6: 跨种子秩一致性过滤

RQ3 暴露的双峰问题需要一个 truth-free 的过滤器。本文的解法基于一个观察：真协同在**独立重训**的不同种子模型中都排在前面，而假候选的排名在种子间剧烈漂移。定义跨种子几何平均排名 $cr(S) = \sqrt{r_1(S) \cdot r_2(S)}$ ，则 PJM 四阶认证批上真协同的 cr 中位数为 105、假候选为 27647，**分离 263 倍**；取阈值 $cr \leq 500$ 后精确率由 45% 提升至 **100%**，召回 9/9 不损失（图 8）。

这一结果与 4.2 节的对照 (2) 构成方法论上的呼应：**同族集成的方差**对摊销偏差失明（因为成员共享同一偏差），而**独立重训的秩一致性**恰好能打破它。对付共享偏差要用秩统计，不能用方差。诚实标注：该阈值是在同一批认证集合上选定的，需要前瞻验证；但 263 倍的分离幅度使结论对阈值极不敏感（300–1000 之间结果一致）。




图 8 跨种子秩一致性过滤。真协同（圆点）集中在小 cr 区，假候选（叉号）漂移到小 cr 区

6.8 RQ7: 第二数据集的完整复现

为检验结论是否只是 PJM 的特性，本文在 CAISO 2025 数据上重跑整条管线，除字段设计外**零协议改动**。

字段设计与泄露审计。CAISO 原始表 307 列（35 个平衡区负荷、34 个日前负荷预测、分区风光实际与预测、三枢纽日前与实时 LMP 及其分量、日前计划的发电量与进出口、辅助服务需求与出清、实时区域间转移等）。为与 PJM 可比，收缩为 44 可见 + 12 机密，并做三轮泄露审计（判据：任一机密字段被 44 个可见字段线性重构的 R^2 不超过 PJM 轮廓的最大值 0.998）：第一轮发现实时电能分量可见时，机密的实时阻塞价格因 LMP 恒等式（总价 = 电能 + 阻塞 + 损耗 + 碳）几乎被精确重构（ $R^2 = 0.996$ ），故移出实时电能分量；第二轮发现三个内部分区实际负荷可见时，机密的系统总负荷被加和恒等式重构到 $R^2 = 0.99998$ ，故换为三个外部平衡区负荷；第三轮发现两列辅助服务出清价全年恒为零（会被预处理当常量列删除，使字段数掉到 42），换为调频里程需求下限。最终最大线性泄露 0.989，轮廓跨度 0.24–0.99，与 PJM 的 0.28–0.998 形态一致。这一过程本身说明：**跨数据集迁移时，字段设计必须做恒等式级的泄露审计，否则“协同发现”可能只是在重新发现会计恒等式。**

复现结果。(1) 方法阶梯同构（图 3(b)）：共享读出 oracle 尾部 0.596，仿射校准 0.758，poly2 字典 0.796，L0 0.931，L1 0.969（三个种子 0.965–0.973）。三阶同构：oracle 0.424，字典 0.581–0.590，L0 0.766，L1 0.788。(2) 高阶认证（图 9）：L1 四阶自选 top-20 认证精确率 $19/20 = 95\%$ ，对照组 $0/20$ ， $p < 0.0001$ ；

五阶 top-21 的估计几乎无偏（结构化均值 0.076 对认证均值 0.075）。(3) 字典失效方向复现：full 字典五阶 top-20 认证 0 个为真，且系统性膨胀 1.7 倍（0.093 对 0.053）。(4) 衰减律复现且更陡（表 3）。(5) 跨种子过滤复现：分离 41 倍，阈值 500 下精确率 100%、召回不损失。

两点实质差异值得写入讨论。其一，CAISO 的衰减更陡：三阶密度是 PJM 的 1.85 倍，但五阶强协同几乎绝迹——协同谱的形状随数据集变化，而“低阶最危险 + 单调衰减”的定性结论稳定。其二，CAISO 上 L1 的单种子精确率高达 95%（PJM 为 48%），字典失效也更温和（无假阳性洪水，仅五阶膨胀）。这提示字典过拟合的幅度与数据的共线结构相关，应当削弱“手工字典必然大规模报假”这一强表述，改为“字典在高阶上的可靠性无保证，须逐数据集认证”。




图 9 CAISO 上 L1 自选候选的重训认证。四阶精确率 19/20，五阶估计几乎无偏；两阶的随机对照组均为 0

6.9 一个零成本基线：协同与共线性

最后报告一个附带发现。在高斯线性假设下，可达 R^2 有闭式 $R_c^2(S) = r^\top R^{-1} r$ (R 为可见字段相关阵、 r 为其与机密字段的相关向量)，据此可零成本算出协同的线性代理。在 CAISO 二阶全空间上，该代理的尾部排序相关为 0.713，已**超过共享读出 oracle** (0.596)；在认证集合上判别“真协同”的 AUC 为三阶 1.000、四阶 0.962、五阶 0.825。这提示协同泄露在很大程度上是**共线性放大**的表现：当可见字段之间高度相关时，其相关阵求逆会放大与机密字段的联合投影。该基线不能取代学出的表示（尾部 0.713 对 0.97），但为“协同为何存在”提供了一个可解释的机制假说，也是一个便宜的预筛选器。

7 讨论

7.1 方法学教训

本文的结论链条中有三处“先错后纠”，其修正过程各产出一件可复用的方法学工具，值得单独记录。

(1) **置换检验对差分统计量有结构盲点**。为验证高阶发现的显著性，一个自然做法是打乱机密字段后重扫，看还能否找到同等强度的协同。本文曾以此认定 full 字典的高阶发现为真（置换后假发现率为 0）。但重训认证表明这些发现全假。原因是：打乱后 $v(S)$ 与 $v(T)$ **一起归零**，差分自然消失；而真实数据上两者都有信号时，差分的系统性偏差不会被置换检验暴露。教训是：**对差分统计量，置换检验可以给出误导性的通过**。

(2) **注入实验区分“数据里没有”与“方法找不到”**。当搜索不到强高阶协同时，需要判断是数据本身稀疏还是估计器失明。做法是人工注入已知强度的合成协同信号，看方法能否找回。本文正是用它推翻了先前“高阶不可能被搜到”的不可能性论证。

(3) **重训认证是唯一裁判**。结构化估计的一切定量结论——强度、密度、排序、显著性——在没有认证前都只是候选。本文的衰减律经历了“断崖 $\rightarrow$ 不衰减 $\rightarrow$ 温和衰减”两次反转，每次反转都由更强的证据推翻更弱的证据。

7.2 局限

(1) φ **不是通用基**。对分布外的合成目标信号，L0/L1 明显不如手工 full 字典 (92 对 56 百分位)，用合成目标增广训练也修不好（容量竞争）。两者互补而非替代，实践中可考虑显式混合。

(2) **单种子候选精确率仍不足** (PJM 48%)，结构化估计只是候选生成器；跨种子过滤在认证样本上修到 100%，但阈值需要前瞻验证。

(3) **高阶密度是估计而非全认证**：四、五阶密度由“估计器超阈计数 $\times$ 认证精确率”外推得到，三阶则有 FDR 的统计保证。

(4) $k \geq 6$ **未解决**：全枚举在六阶起不可行，而反层级协同的存在使 beam 搜索不可靠。候选方向是跨种子一致性引导的采样或遗漏率证书。

(5) **数据口径**：CAISO 的总发电量与联络线功率只有日前计划口径（无实时实测），系统损耗无对应字段，其“运行敏感性”语义弱于 PJM 一档。

(6) 本文的攻击者模型限于监督回归族，未考虑利用时序结构或外部辅助数据的更强攻击者。

8 结论

本文研究了数据推断泄露审计中集合敏感度 $v_c(S)$ 的忠实估计问题。核心发现是：把“集合 $\mapsto$ 敏感度”整体摊销进共享模型时，其误差系统性地集中在最危险的强协同集合上（尾部排序相关由全局的 0.606 坍缩至 0.130），且这一失效源于摊销层次的错配而非训练不足—— $v_c(S)$ 是内层优化的最优值，摊销间隙在“最优解离共享平均解最远”的实例上最大，而协同的差分结构进一步放大了它。据此本文把摊销层次由“值”上移到“表示”，让读出权重按集合闭式重解，在零额外训练下即把尾部排序相关提升至 0.781、最强档低估由 0.124 降至 0.016，性能超过 50 步微调而快 22.4 倍。

在此基础上构建的“摊销扫描—配对 FDR—重训认证”三层管线，使 $k \leq 5$ 的协同发现无需依赖层级性假设，并给出了三项经认证的定量结论：手工多项式字典在高阶上既报假（五阶 441 个强协同认证后无一为真）又漏真；真值版衰减律为 $0.455 \rightarrow 0.196 \rightarrow 0.154$ ，密度每阶降约一个数量级，即最危险的协同是低阶的；跨独立种子的秩一致性可把候选精确率由 45% 提升至 100%。全部结论在第二个电网数据集上完整复现，且两处实质差异（衰减更陡、字典失效更温和）提示协同谱的形状与数据的共线结构相关。

未来工作包括：六阶及以上的可扩展发现、通用基与任务基的显式混合、跨种子过滤阈值的前瞻验证，以及把认证清单转化为最小防护集的组合优化。

参考文献

- [1] Bowen Hu, Rongtao Nie, Yadong Zhou, Sizhe He, Yujie Yang, Yang Liu, Ting Liu, and Xiaohong Guan. IGNN: An inference graph neural network for data sensitivity assessment considering data inference leakage in cyber-physical

- power grid. *IEEE Transactions on Smart Grid*, 2026. DOI: 10.1109/TSG.2026.3667966.
- [2] Brandon Amos. Tutorial on amortized optimization. *Foundations and Trends in Machine Learning*, 16(5):592–732, 2023.
- [3] Neil Jethani, Mukund Sudarshan, Ian Covert, Su-In Lee, and Rajesh Ranganath. FastSHAP: Real-time Shapley value estimation. In *Proceedings of the 10th International Conference on Learning Representations (ICLR)*, Virtual Event, 2022.
- [4] Ian Covert, Chanwoo Kim, and Su-In Lee. Learning to estimate Shapley values with vision transformers. In *Proceedings of the 11th International Conference on Learning Representations (ICLR)*, Kigali, Rwanda, 2023.
- [5] Chris Cremer, Xuechen Li, and David Duvenaud. Inference suboptimality in variational autoencoders. In *Proceedings of the 35th International Conference on Machine Learning (ICML)*, pages 1078–1086, Stockholm, Sweden, 2018.
- [6] Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems 30 (NeurIPS)*, pages 4765–4774, Long Beach, USA, 2017.
- [7] Michel Grabisch and Marc Roubens. An axiomatic approach to the concept of interaction among players in cooperative games. *International Journal of Game Theory*, 28(4):547–565, 1999.
- [8] Justin S. Kang, Landon Butler, Abhineet Agarwal, Yigit Efe Erginbas, Ramtin Pedarsani, Kannan Ramchandran, and Bin Yu. ProxySPEX: Inferring interaction effects from LLM feature attributions. In *Proceedings of the 41st International Conference on Machine Learning (ICML)*, Vienna, Austria, 2024.
- [9] Andrew Ilyas, Sung Min Park, Logan Engstrom, Guillaume Leclerc, and Aleksander Madry. Datamodels: Predicting predictions from training data. In *Proceedings of the 39th International Conference on Machine Learning (ICML)*, pages 9525–9587, Baltimore, USA, 2022.
- [10] Luca Bertinetto, João F. Henriques, Philip H. S. Torr, and Andrea Vedaldi. Meta-learning with differentiable closed-form solvers. In *Proceedings of the 7th International Conference on Learning Representations (ICLR)*, New Orleans, USA, 2019.
- [11] Kwonjoon Lee, Subhansu Maji, Avinash Ravichandran, and Stefano Soatto. Meta-learning with differentiable convex optimization. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 10657–10665, Long Beach, USA, 2019.
- [12] Alessandro Achille, Aditya Golatkar, Avinash Ravichandran, Marzia Polito, and Stefano Soatto. LQF: Linear quadratic fine-tuning. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 15729–15739, Virtual Event, 2021.
- [13] Arthur Jacot, Franck Gabriel, and Clément Hongler. Neural tangent kernel: convergence and generalization in neural networks. In *Advances in Neural Information Processing Systems 31 (NeurIPS)*, pages 8571–8580, Montréal, Canada, 2018.
- [14] Oleg Ivanov, Michael Figurnov, and Dmitry Vetrov. Variational autoencoder with arbitrary conditioning. In *Proceedings of the 7th International Conference on Learning Representations (ICLR)*, New Orleans, USA, 2019.
- [15] Yang Li, Shoaib Akbar, and Junier B. Oliva. ACFlow: Flow models for arbitrary conditional likelihoods. In *Proceedings of the 37th International Conference on Machine Learning (ICML)*, pages 5831–5841, Virtual Event, 2020.

-
- [16] Jiaxuan You, Xiaobai Ma, Daisy Yi Ding, Mykel Kochenderfer, and Jure Leskovec. Handling missing data with graph representation learning. In *Advances in Neural Information Processing Systems 33 (NeurIPS)*, pages 19075–19087, Virtual Event, 2020.
- [17] Yoav Benjamini and Yosef Hochberg. Controlling the false discovery rate: a practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society: Series B*, 57(1):289–300, 1995.