

西安交通大学

硕士学位论文

面向推断泄露威胁的电力数据风险识别
与分级治理方法研究

学位申请人：邢之熠

指导教师：刘杨副教授

学科名称：网络空间安全

2026 年 04 月

Risk Identification and Hierarchical Governance for Power Data against Inference Leakage Threats

A thesis submitted to
Xi'an Jiaotong University
in partial fulfillment of the requirements
for the degree of
Master of Engineering

By
Zhiyi Xing
Supervisor: Associate Prof. Yang Liu
Cyberspace Security
April 2026

硕士学位论文答辩委员会

面向推断泄露威胁的电力数据风险识别 与分级治理方法研究

答辩人：邢之熠

答辩委员会委员：

西安交通大学教授：____ 蔺琛皓 ____ (注：主席)

西安交通大学教授：____ 张佳龙 ____

西安交通大学副教授：____ 范 铭 ____

西安交通大学副教授：____ 刘怡良 ____

西安交通大学副教授：____ 裴红斌 ____

答辩时间：2026 年 05 月 20 日

答辩地点：西安交通大学兴庆校区彭康楼二楼 218 会议室

摘要

随着新型电力系统中数据采集、汇聚与共享程度不断提高，电力数据呈现出多源异构、强关联和持续流动等特征。传统数据分类分级方法难以识别由数据关联关系引发的隐式泄露风险。尤其在推断攻击场景下，攻击者可利用公开数据及先验知识，对高敏感信息进行间接恢复，使原本敏感程度较低的数据在特定条件下具有较高安全风险。因此，如何面向推断泄露威胁开展风险识别，并在此基础上实现更加合理、动态的数据分类分级，已成为电力数据安全治理中的重要问题。

针对电力数据海量多源，且数据间强关联性易引发推断泄露威胁的问题，本文提出面向推断泄露威胁的风险识别方法。首先，面向多源电力数据之间复杂的统计依赖与物理耦合关系，融合 Pearson 相关系数、最大信息系数等多种度量方法，对数据间关联关系进行联合刻画，构建面向推断泄露威胁的数据风险关联图，用于识别由公开数据指向敏感数据的潜在推断路径。随后，进一步引入深度神经网络和图注意力网络，对候选高风险关系的可推断性和结构恢复能力进行验证，实现由统计相关分析到泄露威胁量化评估的转化。最后，探讨了推断泄露威胁下的数据防护方法及其适用性。

针对传统分类分级方法依赖静态规则、难以及时反映风险变化的问题，本文提出了基于知识增强与数据驱动的分级治理方法。首先结合大语言模型与检索增强技术，从安全规范文本和业务文档中抽取结构化分级规则，并利用自编码器和频繁模式挖掘识别高频敏感字段组合，形成对象级初始分级结果；随后，将数据安全等级更新建模为序列决策问题，构建基于强化学习的动态分级模型，综合考虑推断泄露威胁风险、数据可用性、防护成本和合规约束，实现安全等级的自适应调整。

本文围绕电力数据在开放共享环境下面临的推断泄露威胁，引入关联分析方法和神经网络模型，验证了电力数据复杂关联关系向现实泄露能力转化的可能性，并引入检索增强技术和强化学习模型，系统实现了电力数据的动态合理分级，全文形成了“关联挖掘—推断验证—分级治理—系统实现”的技术路线，为复杂数据环境下电力数据的精细化安全治理提供了方法支撑。

关键词：电力数据；数据分类分级；推断攻击；关联分析；强化学习；数据安全

论文类型：应用研究

ABSTRACT

As data collection, aggregation, and sharing continue to increase in new power systems, power data exhibit the characteristics of multi-source heterogeneity, strong correlation, and continuous flow. Traditional data classification and grading methods find it difficult to identify implicit leakage risks caused by inter-data correlations. In particular, under inference attack scenarios, attackers can exploit public data and prior knowledge to indirectly recover highly sensitive information, which causes data with originally low sensitivity to present high security risks under specific conditions. Therefore, how to identify risks under inference leakage threats and, on this basis, achieve more reasonable and dynamic data classification and grading has become an important issue in power data security governance.

To address the problem that power data are massive and multi-source, and their strong inter-data correlations are likely to trigger inference leakage threats, this thesis proposes a risk identification method for inference leakage threats. First, considering the complex statistical dependencies and physical coupling relationships among multi-source power data, the method integrates multiple measures, including the Pearson correlation coefficient and the maximal information coefficient, to jointly characterize inter-data correlations. On this basis, it constructs a data risk correlation graph for inference leakage threats to identify potential inference paths from public data to sensitive data. It then further introduces deep neural networks and graph attention networks to verify the inferability and structural recovery capability of candidate high-risk relationships, thereby enabling the transition from statistical correlation analysis to quantitative assessment of leakage threats. Finally, it discusses data protection methods under inference leakage threats and their applicability.

To address the limitations of traditional classification and grading methods that rely on static rules and fail to reflect risk changes in a timely manner, this thesis proposes a grading governance method based on knowledge enhancement and data-driven modeling. It first combines large language models with retrieval-augmented techniques to extract structured grading rules from security policy texts and business documents, and uses autoencoders and frequent pattern mining to identify high-frequency combinations of sensitive fields, thereby producing object-level initial grading results. It then formulates data security level updating as a sequential decision-making problem and develops a dynamic grading model based on reinforcement learning. This model jointly considers inference leakage threat risk, data availability, protection cost, and compliance constraints, so that adaptive adjustment of security levels can be achieved.

Focusing on inference leakage threats faced by power data in open and shared environments,

this thesis introduces correlation analysis methods and neural network models to verify the possibility that complex data correlations in power systems can be transformed into actual leakage capability. It also introduces retrieval-augmented techniques and reinforcement learning models to systematically realize dynamic and reasonable grading of power data. The overall study forms a technical route of correlation mining, inference validation, grading governance, and system implementation, which provides methodological support for refined security governance of power data in complex data environments.

KEY WORDS: Power system data; Data classification and grading; Inference attack; Correlation analysis; Reinforcement learning; Data security

TYPE OF THESIS: Application Research

*This research was fund in part by the National Natural Science Foundation of China (62293501) and Fundamental Research Funds for the Central Universities.

目 录

摘 要.....	I
ABSTRACT.....	II
1 绪论.....	1
1.1 研究背景与意义.....	1
1.2 国内外研究现状.....	2
1.2.1 推断攻击建模.....	2
1.2.2 隐私风险评估与保护方法.....	3
1.2.3 数据关联分析.....	4
1.2.4 数据分类分级方法.....	5
1.3 研究内容与技术路线.....	7
1.4 论文组织架构.....	9
2 推断泄露威胁与数据分类分级理论基础.....	11
2.1 数据泄露威胁模型与攻击范式.....	11
2.1.1 统一数据泄露威胁模型.....	11
2.1.2 数据泄露攻击范式.....	12
2.2 数据关联性刻画及关联传播机理.....	14
2.2.1 基于相关性分析的数据关联性刻画.....	14
2.2.2 基于图模型的关联传播结构与累积效应.....	17
2.3 数据分类分级方法.....	17
2.4 实验数据集.....	20
2.4.1 电力市场数据集.....	20
2.4.2 仿真数据集.....	21
2.5 本章小结.....	22
3 面向推断泄露威胁的风险识别方法.....	23
3.1 基于多度量关联分析的风险路径发现.....	23
3.1.1 面向推断泄露威胁的数据关联性表征方法.....	23
3.1.2 多度量融合筛选与风险关联图构建.....	26
3.2 基于神经网络的泄露风险量化评估.....	28
3.2.1 通用深度神经网络推断验证模型.....	28
3.2.2 面向拓扑泄露的图注意力网络与物理约束量化模型.....	30

3.3 面向推断泄露威胁的安全防护测试.....	35
3.4 电网数据场景下风险挖掘与威胁量化实验验证.....	37
3.4.1 实验设计.....	37
3.4.2 基于关联分析的风险挖掘验证结果.....	38
3.4.3 基于通用深度神经网络推断模型的威胁量化验证结果.....	40
3.4.4 基于图注意力网络与物理约束量化模型的威胁量化验证结果.....	41
3.4.5 面向推断泄露威胁的安全防护实验.....	43
3.5 本章小结.....	47
4 基于知识增强与数据驱动的分级治理方法.....	48
4.1 基于大语言模型与频繁模式挖掘的初步分级标定.....	48
4.1.1 基于大语言模型的结构化分级规则抽取.....	48
4.1.2 基于自编码器和频繁模式挖掘的数据特征提取.....	50
4.2 基于强化学习的数据安全等级动态更新模型.....	53
4.2.1 状态空间与风险表征.....	54
4.2.2 动作空间与等级决策.....	54
4.2.3 效用函数构建.....	55
4.2.4 基于增强型组相对策略优化算法的策略求解.....	55
4.3 电网数据场景下分级实验验证.....	56
4.3.1 实验设计.....	57
4.3.2 基于大语言模型的结构化分级规则抽取实验.....	58
4.3.3 基于自编码器和频繁模式挖掘的数据特征提取实验.....	59
4.3.4 数据安全等级动态更新模型实验.....	62
4.4 本章小结.....	64
5 基于数据关联的自适应分类分级系统.....	66
5.1 系统简述.....	66
5.2 系统功能模块.....	66
5.2.1 数据标定模块.....	67
5.2.2 关联分析模块.....	68
5.2.3 动态分级模块.....	70
5.3 系统应用.....	72
5.3.1 云南电网应用部署.....	72
5.3.2 榆林零碳智慧园区应用部署.....	73
5.4 本章小结.....	73

目 录

6 结论与展望.....	74
6.1 研究结论.....	74
6.2 研究展望.....	75
致 谢.....	76
参考文献.....	78
攻读学位期间取得的研究成果.....	82
答辩委员会会议决议.....	83
常规评阅人名单.....	84
声明	

CONTENTS

ABSTRACT (Chinese).....	I
ABSTRACT (English).....	II
1 Preface.....	1
1.1 Research Background and Significance.....	1
1.2 Related Work.....	2
1.2.1 Inference Attack Modeling.....	2
1.2.2 Privacy Risk Assessment and Protection Methods.....	3
1.2.3 Data Correlation Analysis.....	4
1.2.4 Research on Data Classification and Grading Methods.....	5
1.3 Research Content and Technical Roadmap.....	7
1.4 Thesis Organization.....	9
2 Theoretical Foundations of Inference Leakage Threats and Data Classification.....	11
2.1 Data Leakage Threat Models and Attack Paradigms.....	11
2.1.1 Unified Data Leakage Threat Model.....	11
2.1.2 Data Leakage Attack Paradigms.....	12
2.2 Characterization of Data Correlation and Correlation Propagation Mechanisms.....	14
2.2.1 Data Correlation Characterization Based on Correlation Analysis.....	14
2.2.2 Graph-Based Correlation Propagation Structure and Cumulative Effects.....	17
2.3 Data Classification and Grading Methods.....	17
2.4 Experimental Datasets.....	20
2.4.1 Electricity Market Dataset.....	20
2.4.2 Simulation Dataset.....	21
2.5 Chapter Summary.....	22
3 Risk Identification Methods for Inference Leakage Threats.....	23
3.1 Risk Path Discovery Based on Multi-Metric Correlation Analysis.....	23
3.1.1 Data Correlation Characterization for Inference Leakage.....	23
3.1.2 Multi-Metric Fusion Screening and Risk Association Graph Construction.....	26
3.2 Quantitative Assessment of Leakage Risks Based on Neural Networks.....	28
3.2.1 General Deep Neural Network-Based Inference Validation Model.....	28
3.2.2 Graph Attention Network with Physical Constraints for Topology Leakage Quantification.....	30
3.3 Security Protection for Inference-Based Data Leakage.....	35
3.4 Experimental Validation of Risk Mining and Threat Quantification in Power Grid Data Scenarios.....	37
3.4.1 Experimental Design.....	37
3.4.2 Validation Results of Risk Mining Based on Correlation Analysis.....	38
3.4.3 Threat Quantification Results Based on the General Deep Neural Network Inference Model.....	40
3.4.4 Threat Quantification Results Based on the Graph Attention Network with	

CONTENTS

Physical Constraints.....	41
3.4.5 Security Protection Experiments for Inference-Based Data Leakage.....	43
3.5 Chapter Summary.....	47
4 Grading Governance Method Based on Knowledge Enhancement and Data-Driven Analysis.....	48
4.1 Preliminary Grading Based on Large Language Models and Frequent Pattern Mining.....	48
4.1.1 Structured Extraction of Grading Rules Based on Large Language Models.....	48
4.1.2 Data Feature Extraction Based on Autoencoders and Frequent Pattern Mining....	50
4.2 Reinforcement Learning-Based Dynamic Updating Model for Data Security Levels	53
4.2.1 State Space and Risk Representation.....	54
4.2.2 Action Space and Grading Decisions.....	54
4.2.3 Utility Function Construction.....	55
4.2.4 Policy Optimization Based on the Enhanced Group Relative Policy Optimization Algorithm.....	55
4.3 Experimental Validation of Grading in Power Grid Data Scenarios.....	56
4.3.1 Experimental Design.....	57
4.3.2 Experiments on Grading Rule Extraction Based on Large Language Models.....	58
4.3.3 Experiments on Data Feature Extraction Based on Autoencoders and Frequent Pattern Mining.....	59
4.3.4 Experiments on the Dynamic Updating Model for Data Security Levels.....	62
4.4 Chapter Summary.....	64
5 Adaptive Classification and Grading System Based on Data Correlation.....	66
5.1 System Overview.....	66
5.2 Functional Modules of the System.....	66
5.2.1 Data Labeling Module.....	67
5.2.2 Correlation Analysis Module.....	68
5.2.3 Dynamic Grading Module.....	70
5.3 System Applications.....	72
5.3.1 Deployment in Yunnan Power Grid.....	72
5.3.2 Deployment in the Yulin Zero-Carbon Smart Park.....	73
5.4 Chapter Summary.....	73
6 Conclusions and Future Work.....	74
6.1 Research Conclusions.....	74
6.2 Future Work.....	75
Acknowledgements.....	76
References.....	78
Achievements.....	82
Decision of Defense Committee.....	83
General Reviewers List.....	84
Declarations	

绪论

研究背景与意义

随着信息技术与能源系统的融合不断加深，电力系统正向数字化、网络化和智能化方向持续发展^[1]。先进量测装置、调度自动化系统以及能源互联网平台的应用，使系统运行过程中持续产生大量数据，主要包括实时运行数据、设备状态数据、电力市场交易数据和碳排放核算数据等。这些数据广泛应用于电力调度优化、负荷预测、设备运维、能源管理及碳交易等业务环节，逐步成为支撑电力系统安全稳定运行和能源结构优化的重要基础资源^[2]。电力系统的信息物理深度耦合特征也使数据在系统运行、控制决策和安全保障中的作用进一步凸显^[3]。

在数据驱动的决策模式下，电力数据的流动性和共享程度不断提高，其属性也由传统的内部生产要素转变为跨部门、跨系统乃至跨区域流通的关键资源^[4]。与此同时，高频共享和多主体协同显著扩大了数据暴露范围。一旦敏感信息泄露，不仅会影响电力企业的经济利益，还可能对电网运行安全及能源市场秩序造成不利影响。因此，在保障数据可用性的前提下实现有效的数据安全保护，已成为电力系统数字化转型过程中需要重点解决的问题。

传统的数据安全防护主要针对未经授权访问和直接泄露行为，如数据窃取、非法复制和网络入侵等，通常可通过访问控制、加密存储和日志审计等手段加以防范。然而，在多源数据融合与开放共享环境下，即使敏感数据本身受到严格保护，攻击者仍可能利用公开数据或低敏数据，通过分析和建模间接推断高敏信息。这类基于数据关联和统计模型的新型攻击方式通常称为数据推断攻击。与直接泄露相比，该类攻击不依赖对敏感数据的直接获取，而是利用多源数据之间的统计相关性和结构依赖关系，通过数据挖掘或机器学习方法推断隐含信息，具有隐蔽性强、检测困难和责任界定复杂等特点，对现有数据安全体系提出了新的要求^[5]。

从攻击过程来看，数据推断攻击一般经历三个阶段：首先收集可获取的公开或低敏数据作为辅助信息；随后通过统计分析或深度学习方法挖掘数据之间的关联结构；最后构建推断模型对目标敏感信息进行预测或重建。当推断结果达到一定精度时，即可认为敏感信息已在实质上发生泄露^[6]。

电力系统作为复杂工程系统，其数据在来源、结构和应用方式上具有明显区别于一般信息系统的特征^[7]。这些特征在提升系统运行效率的同时，也增加了数据推断泄露威胁的风险。总体来看，电力数据主要存在以下几方面的特征及潜在安全隐患。

其一，多源异构且规模庞大的数据结构为推断攻击提供了充足的信息基础。电力

数据覆盖发电、输电、配电和用电等多个环节，既包括来自数据采集与监视控制系统（Supervisory Control And Data Acquisition, SCADA）与同步相量测量装置（Phasor Measurement Unit, PMU）的高频时序数据，也包括设备运维记录、电力市场交易数据、气象数据及碳排放核算数据等多类型信息^[8]。不同数据在采样频率、格式和语义层级上存在明显差异，形成典型的多源异构环境。持续积累的大规模数据为攻击者提供了丰富的辅助信息，使其能够通过跨源融合提取隐含特征，从而提高推断模型的准确性。

其二，电力数据之间的物理约束与业务联系较强，为推断攻击提供了可利用路径。电力系统运行受到功率平衡方程、电网拓扑结构及调度约束等因素影响，各类变量之间存在明确的函数关系和拓扑依赖^[9]。例如，节点功率、线路潮流与电压幅值之间具有确定性关系，用户负荷又与生产活动及气象条件密切相关。上述由物理机理和业务流程共同形成的关联，使攻击者能够通过有限的观测数据推断出难以直接获取的信息，进而形成跨系统的潜在泄露路径。

其三，开放共享与多主体协同的使用模式进一步扩大了潜在的推断攻击面。在电力市场化改革和能源互联网发展的背景下，电力数据需要在调度机构、发电企业、售电公司及第三方服务机构之间频繁交换，以支持电力交易、需求响应及碳排放核算等业务^[10]。同时，为满足监管要求和市场透明度需求，部分运行和交易数据还需以统计或汇总形式对外发布。该类共享机制在提高运行效率的同时，也使攻击者能够整合多来源数据，构建更完整的数据视图，从而提高推断攻击的成功概率。

综上所述，电力数据在推断泄露威胁场景中的主要安全风险可归结为数据层面的多源异构性、关联层面的物理-业务强耦合性以及使用层面的开放共享范式三个维度的耦合作用。现有以访问控制和静态分类分级为核心的数据安全方法，难以刻画数据之间的隐式关联关系，也缺乏对动态攻击环境的适应能力。

因此，有必要开展面向推断泄露威胁的数据安全风险识别与分级治理研究，通过分析多源数据之间的关联结构和推断路径，对潜在风险进行量化评估，并据此实现自适应的数据分级治理。该研究对提升数据开放环境下的安全防护能力、保障能源基础设施安全以及维护电力市场秩序具有重要意义。

国内外研究现状

围绕推断泄露威胁风险评估与数据安全分级治理，国内外学者已开展了大量研究，相关工作主要集中在推断攻击建模、隐私风险评估与保护方法、数据关联分析以及数据分类分级方法等方面。

推断攻击建模

随着机器学习与数据分析技术在各行业中的广泛应用，研究者逐渐发现，模型在训练与推断过程中可能泄露与训练数据相关的敏感信息，从而引发推断攻击。围绕推断攻击的攻击模型、攻击能力评估以及隐私保护机制，国内外学者开展了大量研究。

在推断攻击类型研究方面，Yang 等人对深度学习模型反演攻击及其防御方法进行了系统综述，指出模型反演攻击已从早期依赖置信度输出的恢复方法，逐步发展为结合生成模型、特征约束与优化策略的多类攻击框架，说明模型输出与内部表征中可能蕴含可被利用的敏感信息^[11]。在此基础上，Liu 等人针对标签仅可见场景开展研究，提出基于条件扩散模型的标签驱动反演方法，发现即使攻击者无法获取完整置信度向量，仅凭预测标签也可能恢复与训练分布高度相似的代表性样本^[12]。

在成员推断攻击研究方面，Hu 等人对该领域进行了系统梳理，指出攻击者可利用模型输出分布、损失差异及决策边界特征判断样本是否参与过模型训练，并总结了黑盒、白盒及生成模型场景下的多类攻击路径^[13]。进一步地，Van Breuge 等人围绕合成数据场景提出 DOMIAS 方法，发现局部过拟合会显著增强成员推断攻击效果，尤其会提高对少数样本和异常样本的识别能力^[14]。Leemann 等人则从白盒攻击评估角度出发，提出 f -Membership Inference Privacy 分析框架，指出基于梯度统计特征的似然比攻击能够更直接地刻画成员推断风险，并可用于评估不同训练机制下的隐私泄露程度^[15]。

尽管现有研究在推断攻击模型构建方面取得了显著进展，但大多数工作主要关注机器学习模型层面的隐私泄露问题，而对多源业务数据之间关联关系所导致的推断泄露威胁的风险关注不足。在电力系统等复杂工程场景中，敏感信息往往并非通过单一模型输出泄露，而是通过跨数据域的关联传播逐步暴露。因此，有必要在现有模型隐私保护研究基础上，进一步考虑多源数据关联结构与系统级推断路径，从整体层面评估与防护数据推断泄露威胁的风险。

隐私风险评估与保护方法

随着推断攻击手段不断演化，隐私保护研究已由单纯关注“如何防止泄露”逐步转向“如何评估风险并实施针对性防护”的综合研究路径。现有研究表明，数据推断泄露威胁并非仅由数据直接暴露引起，更常源于模型输出、训练机制以及多源数据关联所共同形成的间接推断能力。因此，围绕隐私风险评估与保护方法，学术界一方面致力于构建可量化的风险分析框架，另一方面不断探索兼顾数据可用性与隐私安全的防护技术体系。

在隐私风险评估方面，秦臻等对人工智能模型安全攻击与防御策略进行了系统归

纳,指出模型输出向量、参数信息、梯度信息等都可能成为推断攻击的利用对象,模型反演攻击与成员推断攻击等攻击方式已成为隐私泄露研究中的典型问题^[16]。王继民等在控制系统隐私保护综述中进一步指出,隐私泄露问题已由传统信息系统扩展到控制系统、信息物理系统及智能电网等复杂环境,系统中的敏感状态、行为特征和运行参数都可能在数据共享与协同控制过程中被间接恢复^[17]。这表明,隐私风险评估的研究对象已从静态数据本身扩展至数据流转过程、模型运行机制和系统交互关系,风险分析视角也由单点式识别逐步转向面向系统过程的综合评估。

针对电力数据的隐私风险评估,现有研究进一步揭示了高频运行数据所具有的显著推断敏感性。邓晓平等在非侵入式负荷监测研究综述中指出,仅凭总表采集数据即可辨识用户用电设备类别、运行状态及能耗使用情况,这意味着即使经过一定程度聚合处理的电力数据,仍可能暴露用户设备使用习惯与行为模式^[18]。庞博等围绕智能电网数据聚合问题开展研究,指出智能电表的大规模部署虽然提高了电网运行感知能力和调度效率,但也显著增加了通过负荷曲线对个人生活规律进行识别和推断的风险,并据此提出了相应的数据聚合隐私保护方案^[19]。此外,张辉等在面向源网荷的智能化数据协同推断技术综述中指出,随着源网荷多主体、多环节数据的持续融合,跨机构数据协同虽然增强了系统分析能力,但也放大了敏感信息在不同环节间被关联推断的可能性,因此亟需引入跨域隐私计算框架和敏感信息保护机制^[20]。这些研究进一步说明,电力数据隐私风险并非单纯来源于单条数据记录,而是深刻嵌入于多源数据融合、业务协同和系统联动的整体过程之中。

为应对推断攻击带来的隐私风险,学术界提出了多种隐私保护技术,其中差分隐私仍被认为是最具理论保障的代表性方法之一。Demelius 等人对近年差分隐私在集中式深度学习中的应用进行了系统综述,指出差分隐私已广泛用于抵御成员推断、数据重构及相关隐私攻击,并在隐私保护与模型可用性之间形成了较为清晰的权衡框架^[21]。Pan 等人进一步总结了差分隐私与深度学习结合的主要技术路线,发现通过在训练过程中引入噪声扰动、梯度裁剪及隐私预算控制,能够在一定程度上削弱模型对训练样本的记忆效应,从而降低推断攻击成功率^[22]。

在智能电网与电力数据隐私保护研究中,近年来相关工作主要集中在高频负荷数据与智能电表数据的推断风险防护。Kua 等人对智能电表隐私保护技术进行了综述,指出细粒度用电数据可能被用于推断用户生活习惯、设备使用行为及活动模式,因此有必要从数据聚合、匿名化和对抗强弱攻击者等多个层面构建系统化保护机制^[23]。Hafeez 等人进一步研究了差分隐私在智能电网负荷监测与计费场景中的应用,提出增强型抗串谋差分隐私模型,发现通过分裂噪声抵消机制可以在保证计费与负荷监测准确性的同时,提高对隐私推断与串谋攻击的抵抗能力^[24]。

综上所述，现有研究已经在隐私保护机制设计和风险评估方法构建方面积累了较为丰富的成果。一方面，差分隐私等方法为模型训练和数据发布提供了较为成熟的技术支撑；另一方面，面向推断攻击的风险评估研究也逐步从单一模型、单一攻击形式扩展到复杂系统、多类攻击面和多场景融合条件下的综合分析。然而，现有工作仍存在两方面不足：其一，多数研究聚焦于模型层面或局部业务场景，对多源电力数据之间的关联传播机制关注不足；其二，现有风险评估结果往往停留在攻击效果分析或隐私强度描述层面，尚未形成与实际安全分级、防护策略调整直接衔接的统一框架。因此，如何在复杂电力业务场景下，将数据关联关系、推断能力评估与隐私保护策略协同起来，构建面向系统级推断泄露威胁的风险评估与治理方法，仍是值得进一步深入研究的问题。

数据关联分析

在数据推断泄露威胁场景中，攻击者通常并非依赖单一数据项直接恢复敏感信息，而是借助多源数据之间的统计关联、结构依赖与语义联系，逐步逼近目标变量。因此，如何刻画数据变量之间的相关性与依赖结构，进而评估其可能诱发的隐私泄露风险，已成为隐私风险分析研究的重要基础。围绕数据关联分析国内外学者开展了大量研究。

早期研究多采用皮尔逊（Pearson）相关系数、斯皮尔曼（Spearman）相关系数等传统统计方法刻画变量间关系。这类方法计算过程相对简单、结果具有较强可解释性，适用于线性相关或单调相关场景，但面对多源异构数据中普遍存在的非线性耦合、局部依赖和复杂交互时，表达能力仍然有限。周叶青等在非线性相依数据关联分析综述中指出，传统相关分析难以充分揭示复杂数据中的高阶依赖关系，因而需要结合距离相关系数以及最大信息系数等方法，对变量之间更一般的相依结构进行刻画^[25]。

为克服线性相关度量的局限，研究者逐步将信息论方法引入关联建模。互信息（Mutual Information, MI）由于能够度量随机变量之间的一般统计依赖关系，已被广泛应用于特征选择、变量筛选与风险识别等任务。马健等人提出互信息与 Copula 熵之间的等价关系，证明了多变量互信息可通过 Copula 熵进行统一表达，从而为复杂分布条件下的依赖关系建模提供了新的理论工具^[26]。在具体应用层面，刘磊等以径流序列分析为对象，采用基于 Copula 熵的非线性相关性度量方法构建复杂网络，研究发现该方法能够较好识别传统线性指标难以揭示的隐含关联关系，说明信息论方法在复杂系统关联分析中具有较强适用性^[27]。与此同时，Reshef 等人提出了最大信息系数（Maximal Information Coefficient, MIC），能够在大规模数据集中发现多种函数形式的关联关系，并对线性与非线性关系进行统一度量^[28]。该方法通过自适应网格划分估计变量之间的最大互信息，在复杂数据结构中表现出良好的鲁棒性与泛化能力，因此

被广泛应用于生物信息学与工程数据分析等领域。

随着机器学习技术的发展,研究者进一步将关联分析与隐私风险评估结合起来,提出从模型记忆能力、样本可区分性和推断成功率等角度度量数据泄露风险。Song 和 Mittal 对机器学习模型隐私风险进行了系统评估,提出样本级隐私风险评分方法,研究发现不同样本面临的成员推断风险具有明显异质性,细粒度风险刻画能够更准确反映个体样本的泄露脆弱性^[29]。这一研究表明,隐私风险并非仅是模型整体属性,还与样本分布位置、泛化误差和特征表征方式密切相关。

综上所述,现有研究已在数据关联分析方法方面形成了较为丰富的研究基础,研究路线也由传统线性相关分析逐步扩展到基于信息论、复杂网络与机器学习的非线性关联建模。然而,已有工作仍多聚焦于单一数据集、单一模型,对多源电力数据之间复杂关联结构的系统描述仍显不足,尤其缺乏将关联强度、推断能力与安全等级直接衔接起来的统一分析框架。基于此,如何面向电力业务场景构建“关联分析—风险度量—等级映射”一体化方法,仍是后续研究需要重点解决的问题。

数据分类分级方法

数据分类分级是数据安全治理中的基础性问题,其核心任务是依据数据的重要程度、敏感属性及其泄露、篡改或滥用后可能造成的影响,对数据进行类别划分和等级判定,并据此实施差异化保护。随着数据要素价值不断凸显,分类分级的研究重点已由早期的安全管理工具,逐步扩展到制度治理、合规落实、数据流通与价值释放协同推进的综合治理议题。近年来,围绕分级原则、评估指标、自动化方法与行业适配路径,国内外学术界与产业界开展了大量探索。

从制度层面看,《中华人民共和国数据安全法》于 2021 年正式确立数据分类分级保护制度,明确要求依据数据在经济社会发展中的重要程度及其遭受破坏、泄露、非法利用后可能造成的危害程度实施分类分级保护,并同步建立风险评估、信息共享和监测预警机制^[30]。此后,GB/T 43697—2024《数据安全技术 数据分类分级规则》从国家标准层面对分类分级的原则、框架、方法和流程进行了系统规范,标志着我国分类分级工作由原则性制度要求进一步转向可执行的技术规则^[31]。与此同时,公共数据^[32]、科学数据^[33]、能源数据^[34]等细分领域标准也在近年陆续推出,说明分类分级正在由通用规则走向行业细化与场景适配。

从研究内容看,现有数据分类分级方法仍以规则驱动路径为主,即围绕数据所属业务域、描述对象、使用用途、影响范围和危害后果等因素开展人工判定或半自动判定。严炜炜等系统梳理了我国数据分类分级的研究趋势、政策标准与企业实践,指出当前研究已初步形成以重要性、敏感性和危害后果为核心的分析框架,但整体上仍以

政策遵循和实践落地为主要导向^[35]。商希雪和韩海庭则从治理规范角度指出，当前分类与分级在制度适用上仍存在交叉与混用现象，分类往往承载业务管理和权益配置功能，而分级更多服务于安全保障目标，这也决定了现有方法在实践中往往更偏向静态规则和制度映射^[36]。总体而言，传统方法具有可解释性强、便于合规执行的优势，但在面对海量、多源、异构数据时，也容易出现人工成本高、更新滞后、粒度较粗和场景迁移能力不足等问题。

为提高分类分级效率与精度，近年来研究者开始将自然语言处理、知识抽取和机器学习方法引入相关任务。Li 等提出基于大语言模型的工业数据自动分类分级方法，反映出大模型已开始被用于提升工业数据语义理解与自动识别能力^[37]。Lai 等进一步提出面向分类分级标准文本的自动解析方法，能够从标准文档中抽取层级关系和安全级别属性，并构建可供机器理解的图结构表示，以缩小制度文本与实际执行之间的落差^[38]。Li 等则面向结构化敏感数据提出基于隐私偏好的分类分级方法，指出现有方法存在泛化能力有限、效率偏低和依赖静态规则等问题，并尝试通过互信息、聚类和关联规则等手段增强场景适应能力^[39]。与此同时，电力领域近年的研究也开始关注复杂业务场景中的多源异构数据分类分级问题，李新家等提出结合决策树与模糊控制的分类分级方法，以提高复杂业务条件下分级的准确性和执行效率。可以看出，数据分类分级方法正在由单纯依赖专家经验和规则库的静态判定，逐步转向“规则+知识+学习”融合的智能化路径。

在电力行业，数据分类分级研究与制度建设呈现出更强的场景依赖性。电力企业数据覆盖发、输、变、配、用及市场交易等多个环节，既关系电网安全稳定运行，也关系市场秩序与公共服务保障，因此数据分类分级已成为行业数据治理的重要基础^[40]。现有研究中，既有从企业视角构建数据来源、业务领域与安全属性三维分类框架的方法，也有围绕电力行业数据分类分级安全管理实践展开的应用总结^[41]；此外，还有研究专门面向电网企业提出分类分级策略，反映出行业分类分级正在从一般原则走向企业级、业务级实施^[42]。制度层面上，2024 年公布、2025 年施行的《电力监控系统安全防护规定》进一步强调电力监控系统应落实等级保护和关键信息基础设施保护制度，坚持“安全分区、网络专用、横向隔离、纵向认证”的总体原则，并强化态势感知、动态评估和备用应急措施^[43]。2025 年印发的《能源行业数据安全管理办法（试行）》则将能源行业数据划分为一般、重要、核心三级，并要求编制、审核、更新重要数据目录，体现出行业监管已开始强调分类分级与动态管理、监测预警相结合^[44]。

综上所述，现有研究已在制度框架、标准体系、自动化方法和行业实践等方面取得了较为丰富的成果，但仍存在三方面不足。其一，现有方法大多仍以数据本体语义、元数据属性和静态规则为主要依据，对数据之间的隐式关联关系和可推断性关注不足，

难以识别低敏数据在汇聚、关联和建模后反推出高敏信息的风险。其二，多数研究仍偏重一次性定级，缺乏对风险状态时变演化的持续感知与动态调整机制。其三，分类分级结果与后续访问控制、脱敏共享、异常监测和分级防护策略之间的联动仍不够紧密。基于此，如何在现有分类分级研究基础上进一步引入数据关联分析、推断风险识别与动态更新机制，构建能够适应复杂电力场景的数据分级方法，已成为该方向值得深入研究的重要问题。

研究内容与技术路线

基于上文对电力数据开放共享场景下面临的数据推断泄露威胁、传统分类分级方法存在的主要不足以及相关研究现状的分析，本文围绕“风险识别—威胁量化—分级治理—系统实现”这一主线，分别对推断泄露威胁下多度量关联驱动的风险路径发现、基于神经网络的风险量化评估，以及基于知识增强与数据驱动的分级治理方法展开研究。本文的研究内容框架如图 1-1 所示，包含本文的研究基础、关键方法以及最后的系统实证三个层次内容，介绍本文的主要研究工作。




图 1-1 本文研究内容框架

研究内容一：面向推断泄露威胁的风险识别方法

围绕电力数据多源异构、强物理耦合和业务关联紧密的特点，本文首先分析公开数据、低敏数据与高敏感数据之间潜在的统计依赖和推断关系，研究面向推断泄露的数据关联性表征方法。在此基础上，融合 Pearson 相关系数、Spearman 相关系数和最大信息系数三种关联度量，对不同数据对象之间的关联关系进行联合刻画，构建有向

加权的数据风险关联图，识别由公开数据指向敏感数据的潜在推断路径，为后续泄露威胁验证与风险量化提供候选关系和结构基础。针对仅依赖统计相关分析难以直接反映攻击者真实推断能力的问题，进一步研究候选高风险关系的可推断性验证与泄露威胁量化方法。对于一般敏感变量，构建通用深度神经网络推断模型，评估公开数据对敏感信息恢复的支撑能力；对于电网拓扑等结构化敏感目标，构建融合图注意力网络与物理约束的拓扑泄露量化模型，对结构恢复能力和现实攻击价值进行验证。在此基础上，基于公开共享数据域现有防护机制，分析数据加噪、数据掩码和数据混淆三类信息干扰方法对推断攻击的抑制效果，评估不同防护策略防护推断泄露威胁的能力。

创新点：提出了面向推断泄露威胁的多度量关联分析方法，将相关性分析结果统一纳入风险筛选框架，并通过构建有向风险关联图实现对潜在推断路径的结构化表征，增强了对隐含高风险关系和复杂传播链条的发现能力。构建了由“统计关联—模型验证—攻击评估”组成的泄露威胁量化框架，将相关性分析结果进一步转化为可验证、可度量的推断能力评估。

研究内容二：基于知识增强与数据驱动的分级治理方法

针对传统数据分类分级方法依赖静态规则、过度依赖人工经验、难以及时响应风险变化的问题，本文研究面向推断泄露威胁的分级治理方法。首先，面向安全规范文本、工程文档和业务资料等非结构化信息，结合大语言模型与检索增强技术，研究结构化分级规则抽取方法，将分散在文本中的分类依据、分级条件和敏感字段信息转化为可计算、可调用的结构化规则。其次，针对电力数据字段维度高、敏感性往往体现为多字段联合暴露的问题，利用自编码器和频繁模式挖掘方法识别高频敏感字段组合，形成对象级初始分级结果。最后，针对静态分级结果难以反映推断风险动态变化的问题，将数据安全等级更新建模为序列决策问题，构建基于强化学习的动态分级模型，综合考虑推断风险、数据可用性、防护成本和合规约束，实现数据安全等级的自适应调整，从而形成由初步标定到动态更新的分级治理方法体系。

创新点：提出了融合知识增强与数据驱动的初步分级标定方法，将大语言模型的规则抽取能力与检索增强机制结合起来，实现了由非结构化安全文本到结构化分级规则的自动转换，提升了初始分级依据的可解释性和一致性。将自编码器与频繁模式挖掘结合，引入高频敏感字段组合识别机制，使初始分级不仅依赖单字段规则判断，而且能够反映多字段联合暴露带来的潜在风险。进一步构建了面向推断风险的动态分级模型，将推断风险、可用性损失、防护成本和合规要求统一纳入等级更新过程，实现了由静态规则驱动向风险感知驱动的分级治理扩展。

研究内容三：基于数据关联的自适应分类分级系统实现

在前述风险识别、威胁量化与分级治理方法研究基础上，本文进一步面向电力数据安全治理实际需求，设计并实现了基于数据关联的自适应分类分级系统。系统以数据标定、关联分析和动态分级为核心功能模块，完成从数据接入、规则匹配、风险识别、等级调整到结果反馈的闭环处理流程。其中，数据标定模块负责对待分析数据进行接入、解析、存储和初始分级；关联分析模块负责量化不同数据对象之间的关联关系与潜在推断风险；动态分级模块根据风险变化对数据安全等级进行修正和更新。在此基础上，系统在云南电网、榆林零碳智慧园区等实际场景中开展部署与应用验证，检验所提方法在真实电力数据环境中的可行性、稳定性和工程适应性。

创新点：构建了面向电力数据安全治理的自适应分类分级系统，实现了风险识别方法、动态分级方法与系统功能模块之间的统一集成，形成了从数据接入到等级更新的闭环实现路径。通过在实际电力业务场景中的部署应用，验证所提方法具备一定的工程落地能力，为面向推断泄露威胁的电力数据精细化安全治理提供系统实现方案。

论文组织架构

本文围绕电力数据开放共享环境下的数据推断泄露威胁的风险识别与分级治理问题展开研究，按照“理论基础—风险量化—分级治理—系统实现”的总体思路组织全文，共分为六章，各章内容安排如下。

第一章为绪论。本章介绍论文的研究背景与研究意义，梳理推断攻击建模、隐私风险评估与保护方法、数据关联分析以及数据分类分级方法等方面的国内外研究现状，在此基础上明确本文的研究内容、技术路线和主要创新点。

第二章为推断泄露威胁与数据分类分级理论基础。本章从理论层面对后续研究涉及的关键问题进行说明，主要包括数据泄露威胁的模型与攻击范式、数据关联性刻画及关联传播机理、数据分类分级方法的基本框架，并对后续实验所使用的电力市场数据集和仿真数据集进行介绍，为全文的方法设计与实验分析提供理论和数据支撑。

第三章为面向推断泄露威胁的风险识别方法研究。本章围绕“风险识别—威胁量化—安全测试”展开，首先利用多度量关联分析方法挖掘多源电力数据之间的潜在推断关系，构建风险关联图；随后结合深度神经网络和融合物理约束的图注意力网络，对候选高风险关系的可推断性和结构恢复能力进行验证；最后测试数据加噪、数据掩码和数据混淆等防护方法在电网场景的防护效果。

第四章为基于知识增强与数据驱动的分级治理方法。本章针对传统静态分级方法在复杂场景下适应性不足的问题，首先利用大语言模型、检索增强、自编码器和频繁模式挖掘完成数据对象的初步分级标定；在此基础上，将安全等级更新建模为序列决策问题，构建基于强化学习的动态分级模型，实现面向推断风险的数据安全等级自适

应调整，并通过实验验证所提方法的有效性。

第五章为基于数据关联的自适应分类分级系统。本章在前述方法研究基础上，设计并实现面向电力数据安全治理的自适应分类分级系统，介绍系统的总体架构、功能模块和实现流程，并结合云南电网、榆林零碳智慧园区等实际应用场景，说明系统的部署方式与应用效果，验证本文研究的工程可行性。

第六章为结论与展望。本章对全文研究工作进行总结，归纳本文在推断泄露威胁的风险识别、安全防护、动态分级和系统实现等方面的主要结论，并对后续可进一步深入的研究方向进行展望。

推断泄露威胁与数据分类分级理论基础

本章目的是给出与本文研究内容和所提算法理论相关的背景研究与领域现状，首先介绍了现有数据泄露威胁特别是推断泄露威胁的相关理论，其次介绍了数据关联性刻画及关联传播机理的相关内容，然后介绍了数据分类分级方法的研究框架，最后依次介绍了在后续两章实验验证部分中所使用的电网数据集。

数据泄露威胁模型与攻击范式

在电力系统数据安全研究中，数据泄露已不再局限于传统的非法访问与直接窃取，而是逐渐演化为由数据关联、模型推断与多源信息融合共同驱动的复杂风险过程。由于电力数据具有多源异构、强物理耦合和业务关联紧密等特征，不同类型数据之间往往存在可传播、可推断的内在联系，使得部分低敏或公开数据在特定条件下也可能成为恢复敏感信息的关键线索。因此，有必要从统一建模的角度系统刻画数据泄露的形成机制，并进一步归纳其典型攻击范式，为后续推断泄露机理分析与风险量化评估奠定理论基础。

统一数据泄露威胁模型

数据泄露威胁模型是刻画数据在采集、传输、存储与使用过程中潜在安全风险的重要理论基础，其核心在于描述攻击者能力、可获取信息以及攻击目标之间的关系。在电力系统多源数据环境下，由于数据种类复杂、业务耦合度高，数据泄露不仅可能来源于直接的数据访问，还可能通过跨数据域的关联推断实现，因此有必要构建适用于电力数据场景的统一泄露威胁模型。

从系统视角出发，电力数据泄露威胁模型通常由三部分构成：数据资源集合、攻击者能力模型以及泄露目标定义。数据集合可表示为：

$$D = \{ D_{pub}, D_{pri} \} \quad 323 \setminus * \text{ MERGEFORMAT } (-)$$

其中， D_{pub} 表示可公开获取或低敏级别的数据，如电力负荷数据、市场交易信息与气象数据等； D_{pri} 表示高敏感数据，如电网拓扑结构、机组运行状态及用户用电行为等。攻击者的目标是在不直接访问 D_{pri} 的情况下，通过对 D_{pub} 的分析推断出敏感信息。

因此，数据泄露过程可统一表示为：

$$\hat{y} = F(D_{pub}, K, \theta) \quad 424 \setminus * \text{ MERGEFORMAT } (-)$$

其中, $\hat{y}$ 为攻击者对敏感信息 $y \in D_{pri}$ 的估计结果, K 表示攻击者掌握的先验知识, θ 为推断模型参数。当满足 $|y - \hat{y}| < \delta$ 时, 可认为敏感信息已被有效恢复, 构成数据泄露。

在该模型中, 攻击者能力主要体现在三个方面: 数据获取能力、先验知识能力与建模分析能力。其中, 先验知识通常来源于系统运行机理与领域知识, 例如电力系统中的潮流方程与功率平衡约束; 建模能力则体现为利用统计分析与机器学习方法对数据进行关联建模与预测。模型反演攻击表明, 模型输出中包含的统计信息可用于重建训练数据中的敏感属性^[45]; 成员推断攻击则通过分析模型行为判断特定数据是否参与训练, 从而间接泄露隐私信息^[46]。上述机制说明, 即使敏感数据本身不可见, 仍可能通过模型或数据关联结构被恢复。

数据泄露攻击范式

在统一威胁模型基础上, 根据攻击路径与信息获取方式的不同, 数据泄露威胁可划分为以下三类典型攻击范式。

1) 窃取泄露威胁

窃取泄露威胁是指攻击者通过未授权访问、系统入侵或权限滥用等方式直接获取敏感数据。其攻击过程可表示为:

$$y = F_s(D_{pri}) \quad 525 \setminus * \text{ MERGEFORMAT } (-)$$

其中, F_s 表示数据窃取操作。

该类攻击不依赖复杂推断过程, 其风险主要来源于访问控制失效与数据保护机制缺陷。数据泄露事件统计表明, 权限配置错误与内部数据滥用是导致敏感数据直接暴露的重要原因^[47]。在电力系统中, 该类威胁通常表现为非法获取调度数据、电网结构信息或用户用电记录, 其影响范围直接且严重。

2) 推断泄露威胁

推断泄露威胁通过分析公开数据与低敏数据之间的统计依赖关系, 对敏感信息进行间接恢复, 其本质属于反问题求解过程。攻击者基于公开数据 D_{pub} 与先验知识 K , 构建推断模型 F_i , 实现:

$$\hat{y} = F_i(D_{pub}, K) \quad 626 \setminus * \text{ MERGEFORMAT } (-)$$

信息论中互信息刻画了随机变量之间的依赖程度, 表明在存在统计关联的情况下, 一个变量可用于推断另一个变量的信息内容^[48]。电力系统中, 运行变量之间受物理规律约束, 形成强耦合关系, 例如负荷、电压与潮流之间存在确定性关联, 使得部分敏感变量可以通过观测数据进行估计。此外, 高频电力负荷数据能够反映用户行为模式

与设备使用特征，从而构成对隐私信息的间接泄露路径^[49]。可将这部分有关联的敏感数据与公开数据之间的关系建模表示为：

$$x = S(y) + e \quad 727 \backslash * \text{MERGEFORMAT} (-)$$

其中， $y \in D_{pri}$ ， $x \in D_{pub}$ ， S 为系统模型， e 为噪声项，该关系决定了敏感数据与公开数据之间存在可推断性。

在推断泄露威胁场景中，根据攻击者所掌握信息的完整程度不同，推断过程可进一步抽象为三类典型问题^[5]。首先，状态估计问题是指在已知系统模型 S 以及观测到的公开数据 x 的条件下，对敏感变量 y 进行估计，其本质是利用系统的已知映射关系恢复不可观测状态。该问题通常可表示为如下优化形式：

$$\hat{y} = \arg \min_y |x - S(y)|^2 \quad 828 \backslash * \text{MERGEFORMAT} (-)$$

在电力系统中，该类问题通常表现为基于测量数据对节点电压、相角等电网运行状态的反演过程。

参数辨识问题描述的是在已知公开数据 x 以及状态变量或结构信息等部分敏感信息的条件下，对系统模型参数或映射算子 S 进行反演的过程。该问题本质上属于模型反推，其数学形式可表示为：

$$\hat{S} = \arg \min_S |x - S(y)|^2 \quad 929 \backslash * \text{MERGEFORMAT} (-)$$

在电力系统中，该类问题通常表现为基于运行数据对网络参数、设备特性或市场机制参数的识别过程。

盲源分离问题对应于信息最不完备的场景，即仅观测到公开数据 x ，同时系统状态 y 与系统模型 S 均未知。在此情况下，需要对状态变量与系统模型进行联合估计，其优化问题通常表示为：

$$(\hat{y}, \hat{S}) = \arg \min_{y, S} |x - S(y)|^2 + R(y, S) \quad 10210 \backslash * \text{MERGEFORMAT} (-)$$

其中， R 为正则化项，用于引入先验约束以缓解问题的不适定性，并提高解的稳定性和可解释性。在电力系统中，该类问题通常表现为在未知网络结构与参数条件下，对系统运行状态进行联合恢复的过程。

在推断泄露威胁中，推断问题通常具有不适定性，其求解需要依赖先验知识或数据驱动方法进行约束。该过程可通过最优化形式统一表示为：

$$\min |L(x, \hat{S}(y)) + R(y)| \quad 11211 \backslash * \text{MERGEFORMAT} (-)$$

其中， L 为损失函数，表示预测值 $\hat{S}(y_0)$ 和真实值 x_0 之间的误差。

推断泄露威胁具有隐蔽性强、难以检测等特点，是当前数据安全研究的重点问题。

3) 组合泄露威胁

在实际复杂系统中，攻击者往往结合多种信息来源与攻击手段实施数据泄露，即通过直接获取部分数据，再结合推断模型恢复更多敏感信息，其过程可表示为：

$$\hat{y} = F(D_{pub} \cup D_{pri}, K, \theta) \quad 12212 \setminus * \text{MERGEFORMAT } (-)$$

其中， D_{pri} 为部分已获取的敏感数据。差分隐私理论指出，当攻击者能够融合多次查询结果或多源数据时，隐私泄露风险将随信息叠加而累积增长^[50]，该攻击模式通过多源数据融合与多阶段推断逐步逼近真实敏感信息，其信息增益 Q 可表示为：

$$Q(y; D_1, D_2, \dots, D_n) \geq Q(y; D_i) \quad 13213 \setminus * \text{MERGEFORMAT}$$

(-)

其中， $D_i \in D_{pub}$ ，说明多源数据融合能增强推断能力。

在电力系统中，攻击者可以利用公开市场数据、部分内部数据以及系统运行知识构建联合推断模型，对关键运行状态进行高精度重建。这种跨数据源、多阶段的攻击方式使数据泄露呈现出关联传播与逐步逼近的特征。

综上，电力系统中的数据泄露威胁已由传统的直接获取模式演变为以数据关联与模型推断为核心的复杂攻击形式，并进一步发展为多源信息融合的复合攻击模式。现有以访问控制为核心的数据安全模型难以刻画数据之间的隐式关联与推断路径，因此有必要在统一威胁模型基础上引入数据关联结构与推断能力分析，为后续推断泄露机理建模与风险量化提供理论支撑。

数据关联性刻画及关联传播机理

基于相关性分析的数据关联性刻画

在数据分类分级与风险识别过程中，数据关联性的准确刻画是揭示潜在风险传播关系和隐含推断通道的重要基础。对于多源异构数据而言，不同数据项之间往往并非孤立存在，而是在业务逻辑、统计特征和系统运行机制的共同作用下形成复杂的依赖关系。尤其在电力系统场景中，运行状态、市场交易、网络结构及调度行为等多类数据相互耦合，导致某些表面上并不敏感的数据在与其他数据联合分析后，可能暴露出更高层次的敏感信息。因此，从数据间相互依赖的角度出发，对其关联性进行定量刻画，是识别潜在推断风险和支撑后续安全分级的重要前提。

相关性分析是一类用于描述变量之间统计依赖程度的经典方法，其基本思想在于通过考察一个变量变化时另一个变量的响应规律，衡量二者之间是否存在稳定的协同

变化关系。若两个变量之间具有较强的相关性，则说明它们在样本空间中并非独立分布，一个变量的变化在一定程度上能够反映另一个变量的变化趋势。对于数据安全问题而言，这种统计上的关联关系意味着公开数据可能携带关于敏感数据的间接信息，从而构成推断泄露威胁风险的基础。因而，相关性分析不仅能够用于发现数据项之间的显式联系，还能够为后续推断模型构建提供候选变量筛选依据。

从机理上看，相关性分析关注的是变量之间的协同变化特征，即两个变量在样本观测下是否表现出一致、相反或更一般意义上的变化趋势。当一个变量增大时，另一个变量也倾向于增大，则二者表现为正相关；当一个变量增大而另一个变量倾向于减小时，则表现为负相关；若两者变化之间缺乏稳定的对应关系，则相关性较弱。需要指出的是，相关性并不等同于因果关系，但在数据关联性刻画中，相关性能够有效反映变量间潜在的信息耦合程度，因而适合作为数据关联识别的基础工具。根据变量关系形式的不同，相关性分析既可以用于描述线性依赖，也可以用于刻画非严格线性但具有稳定顺序关系的单调依赖。

为兼顾不同类型变量关系的刻画需求，本文选取 Pearson 相关系数、Spearman 相关系数和最大信息系数作为数据关联性分析的主要方法。

1) Pearson 相关系数

Pearson 相关系数主要用于刻画两个变量之间的线性相关程度，其本质是对协方差进行标准化处理后的结果。该系数取值范围为 $[-1, 1]$ 。当其值接近于 1 时，说明两个变量之间具有较强的正线性相关关系；当其值接近于 -1 时，说明两个变量之间具有较强的负线性相关关系；当其值接近于 0 时，则说明两个变量之间线性相关性较弱。

设数据项 D_i 和 D_j 在 n 个样本上的观测序列分别为 $\{X_i^{(t)}\}_{t=1}^n$ 和 $\{X_j^{(t)}\}_{t=1}^n$ ，则 Pearson 相关系数可表示为：

$$w_{ij}^{(P)} = \frac{\sum_{t=1}^n (X_i^{(t)} - \bar{X}_i)(X_j^{(t)} - \bar{X}_j)}{\sqrt{\sum_{t=1}^n (X_i^{(t)} - \bar{X}_i)^2} \sqrt{\sum_{t=1}^n (X_j^{(t)} - \bar{X}_j)^2}} \quad 14214 \setminus *$$

MERGEFORMAT (-)

其中， $\bar{X}_i$ 和 $\bar{X}_j$ 分别表示样本序列的均值。

Pearson 相关系数形式简单、计算效率高、结果直观，适用于大规模数据的快速关联筛查。在电力数据分析中，若两个变量之间存在较明显的同步波动或反向线性变化关系，则 Pearson 相关系数能够较为准确地反映其关联强度。然而，该方法主要针对线性关系设计，当变量之间存在明显的非线性耦合或局部变化特征时，Pearson 相关系数的刻画能力会受到一定限制。

2) Spearman 相关系数

Spearman 相关系数是一种基于样本秩次的非参数相关性度量方法，主要用于描述两个变量之间的单调关系。与 Pearson 相关系数直接作用于原始数值不同，Spearman 相关系数首先将样本值转换为秩次，再考察两个秩序列之间的一致性程度。因此，该方法对异常值和非正态分布具有较好的适应性，更适合描述变量间虽不满足严格线性关系、但整体变化趋势一致的情形。

设 $rg(x_i^{(t)})$ 和 $rg(x_j^{(t)})$ 分别为 $x_i^{(t)}$ 和 $x_j^{(t)}$ 在各自样本序列中的秩次，则 Spearman 相关系数可表示为：

$$w_{ij}^{(S)} = \frac{\sum_{t=1}^n (rg(x_i^{(t)}) - \overline{rg(x_i)}) (rg(x_j^{(t)}) - \overline{rg(x_j)})}{\sqrt{\sum_{t=1}^n (rg(x_i^{(t)}) - \overline{rg(x_i)})^2} \sqrt{\sum_{t=1}^n (rg(x_j^{(t)}) - \overline{rg(x_j)})^2}} \quad 15215 \setminus *$$

MERGEFORMAT (-)

当样本中不存在并列秩时，上式可进一步化简为：

$$w_{ij}^{(S)} = 1 - \frac{6 \sum_{t=1}^n (rg(x_i^{(t)}) - rg(x_j^{(t)}))^2}{n(n^2 - 1)} \quad 16216 \setminus * \text{MERGEFORMAT}$$

(-)

相较于 Pearson 相关系数，Spearman 相关系数不要求变量之间满足严格线性关系，只要两个变量之间存在稳定的单调变化趋势，便能够给出较合理的关联刻画。因此，在电力数据中一些受边界约束、饱和效应或阶段性运行机制影响的数据关系分析中，Spearman 相关系数通常具有更好的适用性。但需要注意的是，该方法主要反映秩次上的一致性，对于更复杂的非单调关系，其刻画能力仍然有限。

3) 最大信息系数

在相关性分析中，Pearson 相关系数主要用于刻画线性依赖关系，Spearman 相关系数主要用于描述单调相关关系，但对于更一般形式的非线性关联，这两类指标的刻画能力均存在一定局限。为识别复杂函数关系、分段关系以及其他隐含依赖结构，Reshef 等基于信息论中互信息的思想提出了最大信息系数（Maximal Information Coefficient, MIC），用于在大规模数据中发现变量之间的新型关联关系^[28]。该方法的核心思想是，不预先限定变量关系的具体函数形式，而是通过对二维样本散点进行不同尺度的网格划分，搜索在各类划分条件下归一化互信息的最大值，从而对变量间关联强度进行统一度量。

从信息论角度出发，数据之间的关联性可通过随机变量之间的信息依赖关系进行描述。设敏感变量 Y 有 n 个可能取值，其中每个取值的概率为 $p(y_i) = p_i, i = 1, \dots, n$ ，则可以定义 Y 的信息熵 H 为：

$$H(y) = - \sum_y p(y) \log p(y) \quad 17217 \backslash * \text{MERGEFORMAT} (-)$$

在观测到公开数据 x 条件下时，条件熵为：

$$H(y|x) = - \sum_y \sum_x p(y,x) \log p(y|x) \quad 18218 \backslash * \text{MERGEFORMAT}$$

(-)

在这样的背景下， y 和 x 的互信息为：

$$I(y;x) = H(y) - H(y|x) = \sum_{y,x} p(y,x) \log \frac{p(y,x)}{p(y)p(x)} \quad 19219 \backslash *$$

MERGEFORMAT (-)

熵作为反映变量不确定性的变量，互信息 $I(y;x)$ 表示由于 x 的发生 y 的不确定性减少的程度，如图 2-2 所示。而条件熵 $H(y|x)$ 表示了变量 y 在 x 发生情况下的不确定性，因此互信息可以反映 y 和 x 间的相关性。对于多变量情况，其联合互信息为 $I(y; x_1, x_2, \dots, x_n)$ ，该值通常大于任一单变量信息量。




图 2-2 互信息示意图

在此基础上，对数据项 D_i 和 D_j 在 n 个样本上的观测序列 $\{x_i^{(t)}\}_{t=1}^n$ 和 $\{x_j^{(t)}\}_{t=1}^n$ ，进行给定的 $a \times b$ 网格划分，接着在每个划分的网格区域内计算其互信息，找出所有划分的

最大互信息 $I_{i,j}(a,b) = \frac{\max I_{ij}(a,b)}{\log \min\{a,b\}}$ ，通过在满足网格复杂度约束 $ab < GB(n)$ 条件下中求最大值可以得到 D_i 和 D_j 最大信息系数 MIC：

$$\text{MIC}_{i,j} = \max_{ab < GB(n)} I_{ij}(a,b) \quad 20220 \backslash * \text{MERGEFORMAT} (-)$$

其中， $GB(n)$ 为网格划分细度，通常取 $GB(n) = n^{0.6}$ 。由于 $0 \leq I_{i,j}(a,b) \leq \log \min\{a,b\}$ ，因此 $0 \leq \text{MIC} \leq 1$ 。当 MIC 接近于 1 时，表明两个变量之间存在较强的统计依赖；当其接近于 0 时，则说明两个变量之间缺乏显著关联。MIC 通过将变量的联合分布与独立分布进行比较来计算相关性，计算中的互信息衡量了两个变量之间的信息传递量。与传统相关系数相比，MIC 不依赖于特定关系形式假设，因而更适合用于发现复杂非线性

性耦合、阈值响应以及局部结构显著的数据关联关系。尤其在电力系统场景下，受潮流约束、市场机制、调度策略和运行边界条件等多重因素共同影响，不同数据项之间往往呈现出非线性、多阶段和隐变量驱动的复杂依赖特征。对此，MIC 能够在更一般的意义上揭示数据间的潜在关联，为后续的数据关联筛查和风险识别提供补充依据。

需要说明的是，MIC 的优势主要体现在对复杂关系形式的适应能力上，而非对所有场景均优于传统相关性指标。因此，在实际应用中，通常将其与 Pearson 相关系数、Spearman 相关系数结合使用，从线性关系、单调关系和一般非线性关系三个层面对数据关联性进行综合刻画，以提高关联识别的完整性与稳健性。

基于图模型的关联传播结构与累积效应

为了刻画多源数据之间的复杂关系，可将电力系统建模为有向图： $G=(V,E)$ ，其中 V 表示节点集合， E 表示边集合。

若边 $(i,j) \in E$ 存在连接，表示变量 x_i 对 x_j 存在信息影响。在该图结构中，推断泄露路径可表示为一条有向路径： $P: x_{i_1} \rightarrow x_{i_2} \rightarrow \cdots \rightarrow y$ ，路径上的数据关联强度 w 可表示为边权的累积效应：

$$w(P) = \prod_{(i,j) \in P} w_{ij} \quad 21221 \backslash * \text{MERGEFORMAT} (-)$$

其中， w_{ij} 表示变量之间的关联强度。设变量间存在关联的强度阈值为 τ ，则当存在路径 P 使得 $w(P) > \tau$ 时，则说明该路径为存在显著的推断泄露风险的路径。

在多源数据融合环境下，推断泄露具有明显的累积效应。随着可观测数据维度的增加，敏感信息的不确定性持续降低，其信息增益呈现非线性增长趋势。对应地，针对敏感信息的推断精度不断提高。该过程说明，多源数据融合将显著放大推断攻击能力，使得原本低敏的数据在组合条件下转化为高风险数据。

数据分类分级方法

从方法论上看，数据分类分级并不是单纯的标签归类，而是一个“数据对象识别—类别判定—风险评估—保护映射”的统一过程。其中，分类强调按照业务属性、语义内容、来源场景和处理目的对数据进行归属；分级则强调依据数据在发生泄露、篡改、破坏或被非法利用后的潜在危害，确定其保护强度。面向电力数据的分类分级，本质上是合规约束、业务语义与安全风险共同作用下的综合决策过程。

电力场景下数据具有业务强相关、点多线长、深度关联、负面清单分布稀疏的特点，单靠人工盘点难以支撑大规模分类分级，分类模型需要同时吸收语义、业务和关

联信息。设待处理数据集为 $D = \{x_1, x_2, \dots, x_n\}$ ，对任意数据对象 d_i ，构造其综合特征向量：

$$z_i = [z_i^{sem}, z_i^{meta}, z_i^{biz}, z_i^{ctx}] \quad 22222 \backslash * \text{MERGEFORMAT} (-)$$

其中， z_i^{sem} 表示字段名称、文本描述等语义特征， z_i^{meta} 表示表结构、数据类型、来源系统等元数据特征， z_i^{biz} 表示业务环节、部门归属、流程位置等业务特征， z_i^{ctx} 表示共享范围、使用场景、访问主体等上下文特征。分类过程 C_i 可抽象为：

$$c_i = \arg \max_{k \in C} (c = k | z_i) \quad 23223 \backslash * \text{MERGEFORMAT} (-)$$

其中， C 为预定义的数据类别集合，如运行数据、交易数据、用户数据、设备数据、日志数据等。该过程能够兼容结构化表数据、半结构化日志数据和非结构化文档数据。

在完成类别判定后，分级通常先进行一次静态初始标定。若以影响对象、影响范围、影响程度和合规约束作为基本评价维度，可定义初始分级得分为：

$$s_i^{(0)} = \omega_1 a_{1i} + \omega_2 a_{2i} + \omega_3 a_{3i} + \omega_4 a_{4i} \quad 24224 \backslash * \text{MERGEFORMAT} (-)$$

(-)

其中， a_{1i} 表示对国家安全、公共利益或个人/组织权益的影响对象， a_{2i} 表示影响范围， a_{3i} 表示危害程度， a_{4i} 表示法规或行业规范约束强度， $\omega_1, \omega_2, \omega_3, \omega_4$ 为对应权重。进一步可将其映射为离散安全等级：

$$g_i^{(0)} = \psi(s_i^{(0)}), g_i^{(0)} \in \{1, 2, 3, 4\} \quad 25225 \backslash * \text{MERGEFORMAT} (-)$$

本文后续采用四级标度，故 $g_i^{(0)} \in \{1, 2, 3, 4\}$ ，分别对应公开、一般、重要和核心四个等级^[44]。该类方法的优点在于可解释性强、便于制度落地，尤其适合作为分类分级体系的初始基线。

现有数据分类分级方法大致可以分为三类。第一类是规则与知识驱动方法，主要依赖法规标准、负面清单、关键词、正则表达式、专家规则库和元数据映射来完成分类分级^[38]；第二类是数据驱动方法，将敏感识别视为分类或聚类问题，利用监督学习、聚类分析和关联规则挖掘自动发现敏感属性^[39]；第三类是知识增强智能方法，通过知识图谱、大语言模型和标准文本解析，把规范文件中的分类原则和分级规则自动转化为机器可执行知识^[37]。对于数据驱动方法，记编码后的特征表示为 z_i ，则聚类型初筛可写为：

$$c_i = \arg \min_k \|z_i - \mu_k\|_2^2 \quad 26226 \backslash * \text{MERGEFORMAT} (-)$$

其中， $k \in C$ ， μ_k 表示第 k 个聚类中心点。则基于频繁模式的关联发现可用支持度 $\sup$

和置信度 conf 分别表示为：

$$\sup(A \Rightarrow B) = \frac{\text{count}(A \cup B)}{N} \quad 27227 \backslash * \text{MERGEFORMAT} (-)$$

$$\text{conf}(A \Rightarrow B) = \frac{\text{count}(A \cup B)}{\text{count}(A)} \quad 28228 \backslash * \text{MERGEFORMAT} (-)$$

其中， A 和 B 分别表示前件项集和后件项集， count 表示项集在数据集中出现的次数， N 为样本总数或事务总数。

然而，仅依据直接危害进行静态定级，仍难以反映数据在多源关联条件下的真实安全风险。数据是否敏感与领域场景、上下文关系以及可获得的辅助信息密切相关^[51]，看似低敏感的数据在与外部知识、公开数据或模型输出结合后，可能间接暴露高敏感信息^[52]。因此，可在传统初始分级分数基础上引入推断风险项：

$$\Gamma_i = \max_{y \in D_{\text{pri}}} w(x_i, y) \quad 29229 \backslash * \text{MERGEFORMAT} (-)$$

其中， $w(x_i, y)$ 可由互信息或预测准确率等关联强度指标给出。于是，风险增强后的综合分级得分可写为：

$$s_i = \alpha s_i^{(0)} + \beta \Gamma_i, \quad \alpha, \beta > 0 \quad 30230 \backslash * \text{MERGEFORMAT} (-)$$

其中， α 和 β 分别为初始定级权重和风险强度权重，进一步映射为最终安全等级：

$$g_i = \psi(s_i) \quad 31231 \backslash * \text{MERGEFORMAT} (-)$$

这意味着：即使某数据对象本体上并不高度敏感，只要它与高敏感目标之间存在强推断关系，其安全等级也应被动态抬升。

进一步地，在电力场景中，公开数据的可获得程度、攻击者掌握的辅助知识、系统运行状态以及数据共享边界都具有显著时变性^[53]，因此分级不应停留在“一次定级、长期不变”的静态模式，而应建模为一个随时间演化的动态决策过程。记时刻 t 的系统状态为：

$$S_t = [z_t, \Gamma_t, e_t, j_t] \quad 32232 \backslash * \text{MERGEFORMAT} (-)$$

其中， z_t 为数据对象当前特征， Γ_t 为推断风险， e_t 为环境噪声， j_t 为防护成本或可用性约束。若将等级调整动作表示为 b_t ，则有：

$$b_t \in J \quad 33233 \backslash * \text{MERGEFORMAT} (-)$$

其中， J 为数据等级操作集合。为了平衡安全性与可用性，可定义阶段奖励 r_t 为：

$$r_t = U_t - \lambda_1 W_t - \lambda_2 X_t \quad 34234 \backslash * \text{MERGEFORMAT} (-)$$

其中， U_t 表示数据可用收益， W_t 表示泄露或推断风险损失， X_t 表示防护开销， λ_1, λ_2

为权衡系数。于是动态分级目标 M 可表述为：

$$M = \max_b E \left[\sum_{t=0}^T \gamma^t r_t \right] \quad 35235 \backslash * \text{MERGEFORMAT} (-)$$

其中， $\gamma \in (0,1]$ 为折扣因子。

综上，数据分类分级并非静态的标签赋值过程，而是涵盖数据识别、类别归属、风险评估与保护决策的系统性任务。现有规则与知识驱动方法、数据驱动方法以及知识增强智能方法，为大规模数据治理提供了不同实现路径，但传统以直接危害评估为核心的静态分级方式，仍难以充分刻画多源关联条件下的真实安全风险。尤其在电力系统场景中，数据之间存在显著的业务耦合、物理约束和时变交互特征，因此有必要在初始分类分级基础上进一步引入推断风险建模与动态调整机制，以实现更加符合实际安全态势的精细化分级保护。

实验数据集

为验证本文所提出的数据风险识别与分级防护方法的有效性，实验采用了两类具有代表性的数据集：一类为来源于 PJM（Pennsylvania-New Jersey-Maryland Interconnection）电力市场的真实电力市场运行数据，主要用于多源异构电力数据间的关联分析、风险路径识别以及动态分级策略验证；另一类为基于标准电力系统测试案例构建的仿真数据集，主要用于拓扑推断、推断攻击模拟及防护效果评估。本节将依次对两个数据集进行介绍

电力市场数据集

本文采用的真实数据集来源于 PJM 电力市场^[54]。该数据集来源于美国中大西洋地区能源市场，包含 39 类电力数据字段，覆盖发电、辅助服务、系统运行信息以及节点边际电价等多个维度；每一类数据均包含 8762 个小时级观测值，时间跨度为 2023 年 1 月 1 日至 2024 年 1 月 1 日，能够较完整地反映一年周期内电力市场与系统运行状态的动态变化。该数据集具有明显的多源异构特征，具体信息见表 2-1。

该数据集同时包含市场层、运行层和潮流层信息，能够充分体现电力系统中多维数据之间的耦合关联；其次，小时级长时间序列数据使得关联分析方法能够在足够样本量下得到稳定结果；最后，节点电价、潮流、负荷、容量等变量之间天然存在物理约束和经济调度关系。因此，该数据集适用于本文研究低敏感公开数据推断高敏感关键数据的风险问题。

表 2-1 PJM 电力市场数据集介绍

数据序号	数据类别	数据描述
------	------	------

D1-D8	日前辅助服务市场数据	该数据源包含辅助服务的日前市场数据，包括发电能力和价格等
D9-D15	发电数据和损失数据	该数据源包含 PJM 可用发电容量数据，包括通过 PJM 可靠性定价模型容量市场承诺的总经济数据和紧急最大发电报价以及总发电量，以及每天的每小时 PJM 发电和特高压损失数据。
D16-D24	PJM 调节区域初步结算数据	该数据源包含 PJM 调节市场的每小时结算数据。
D25-D27	实际/计划汇总潮流数据	该数据源包含每条联络线每小时的潮流实际值、计划值以及被动交换潮流。
D28-D31	负荷数据	该数据源包含估算的综合每小时负荷数据、计量的综合每小时负荷数据、初步的综合每小时负荷数据以及历史预测的综合每小时负荷数据。

表 2-1 PJM 电力市场数据集介绍（续）

数据序号	数据类别	数据描述
D32-D39	节点边际价格数据	该数据源包含所有母线位置（包括聚合点）的每小时实时和日前电能市场节点边际价格数据。

仿真数据集

除真实市场数据外，本文还采用了基于标准电力系统测试案例构建的仿真数据集，用于验证拓扑推断与推断攻击场景下的风险识别与防护效果。该仿真数据主要基于新英格兰 39 节点 345kV 系统，利用开源软件 Matpower 构建。该系统包含 39 个系统节点、10 个发电节点和 46 条传输线路，是电力系统拓扑辨识和攻击仿真研究中常用的标准测试系统之一^[55-57]。




图 2-3 新英格兰 39 节点 345kV 标准系统图

为模拟实际负荷随时间变化的运行特征，研究中引入了 2012 年 Global Energy Forecasting Competition (GEFC2012) 公布的负荷数据^[58]，对其实时负荷进行归一化处理后提取负荷波动趋势，再与系统有功功率基值相乘，生成新英格兰 39 节点系统的实时有功功率数据。

本数据集保留了电力系统拓扑结构清晰、物理机理明确的特点，又能够通过时变负荷注入反映实际运行过程中状态量随时间演化的动态特征。因此，该数据集适合用于验证本文所提出方法在拓扑推断、敏感结构恢复和推断攻击建模中的有效性，也能够为风险识别结果的可解释性分析以及不同安全防护策略的对比评估提供可控、可复现的实验环境。相较于 PJM 真实市场数据，仿真数据更便于在已知拓扑和运行参数条件下开展机理分析与攻击验证。

本章小结

本章围绕电力数据推断泄露威胁风险与分类分级，系统梳理了后续研究所需的理论基础与关键技术。首先，从数据安全视角分析了数据泄露威胁模型，重点阐释了推断泄露威胁风险的基本范式、实现机制及其在多源数据融合环境下的传播特征，说明数据关联关系是敏感信息恢复和风险扩散的重要基础；其次，归纳了传统线性相关分析与非线性关联度量方法的基本原理及适用范围，为后续多度量融合的关联分析方法提供了理论依据；再次，梳理了规则驱动、数据驱动和知识增强等主流分类分级方法，并指出现有方法在动态适应性、可解释性和推断风险感知方面仍存在不足；最后，对

实验所采用的电力市场数据集和仿真数据集进行了说明，为后续方法验证提供了数据支撑。总体而言，本章从威胁模型、关联分析与分类分级技术三个层面构建了统一的理论框架，为第三章开展风险识别研究和第四章构建动态分级模型奠定了基础。

面向推断泄露威胁的风险识别方法

本章面向电力数据开放共享环境下的推断泄露威胁问题，围绕“风险识别—威胁量化—安全防护”三个层次展开研究，构建由关联挖掘、推断验证与信息干扰防护组成的方法框架。首先，从公开数据与业务运行等隐私数据之间的统计依赖、信息耦合及电网物理机理出发，利用多度量关联分析识别可能支撑敏感信息恢复的高风险传播路径；其次，结合通用深度神经网络、图注意力网络及物理约束模型，对候选关联关系的可推断性、结构恢复能力与现实攻击价值进行量化评估，判断其是否足以支撑敏感变量重构、拓扑恢复及攻击实施；最后，针对公开共享数据域中的推断泄露威胁，测试数据加噪、数据掩码和数据混淆三类信息干扰防护方法，并通过电网场景实验分析不同策略在数据可用性、隐私保护性与攻击抑制效果之间的权衡。与仅停留于相关性分析或单一模型验证的研究不同，本章形成了从潜在风险发现、泄露能力验证到防护效果评估的完整分析链条，为后续数据安全等级动态更新与差异化防护策略设计提供方法基础。




图 3-4 面向推断泄露威胁的风险识别与安全防护研究总体框架

基于多度量关联分析的风险路径发现

面向推断泄露威胁的数据关联性表征方法

在电力系统中，推断泄露威胁的传播路径通常源于多类数据之间由物理规律与业务机制共同构建的内在关联关系。其中，电网运行遵循的潮流方程刻画了功率、节点电压与网络结构之间的约束关系，使得部分系统状态可以通过观测变量反向推导；电力市场运行过程中，电价与供需关系之间存在映射机制，使市场数据能够反映系统运行特征；同时，用户侧负荷曲线与用电行为之间具有稳定的统计关联，使得行为特征能够通过负荷数据间接揭示。上述多维度关联关系相互交织，构成了推断泄露威胁的基础传播路径，并为攻击者从可观测数据逐步逼近敏感信息提供了可能。本节首先从信息不确定性降低的角度，论证数据关联性与数据推断可能性之间的内在关系。

在互信息基础上, 由于公开数据 x 会使敏感数据 y 的不确定减少, 该不确定性的减少量可用于衡量面向数据推断的数据关联性, 由 x 推断 y 和由 y 推断 x 通常属于不同问题, 即数据推断具有方向性, 因此面向数据推断的数据关联性也应该是有向的。那么由 x 推断 y 的数据关联性可表示为 $T(y|x)$ 。

$$T(y|x) = \frac{I(y;x)}{H(y)} \quad 37337 \backslash * \text{MERGEFORMAT} (-)$$

其中, $T(y|x)$ 的物理含义为已知数据 x 减少数据 y 的不确定性占数据 y 总不确定性的比例。由于 $0 \leq I(y;x) \leq H(y)$, 因此 $T(y|x) \in [0,1]$ 。相应地, 由 y 推断 x 的数据关联性表示为 $T(x|y)$ 。

由于攻击者获取数据中包含的其他数据信息是有限的, 其能用于减少其他信息的不确定度也是有上界的, 该上界的安全意义是攻击者推断能达到的最准情况。当推断的最准情况较差时, 攻击者无论使用什么样的推断方法, 都无法准确推断出与获取数据相关的其他数据。

费诺不等式提供了数据推断问题中推断误差与信息熵的关系^[59]。用 y 表示待推断的随机变量, y 的取值空间为 Y , 攻击者观测到与 y 相关的随机变量为 x 。假设攻击者想要通过数据 x 推断与之相关的数据 y 的估计值 $\hat{y}$, 则 $y \rightarrow x \rightarrow \hat{y}$ 构成马尔可夫链, 对于 $y \rightarrow x \rightarrow \hat{y}$, 有 $I(y;x) \geq I(y;\hat{y})$, 则 $H(y|\hat{y}) \geq H(y|x)$ 。令 P_e 表示推断错误概率, 即 $P_e = p\{\hat{y} \neq y\}$, 费诺不等式如下:

$$H(P_e) + P_e \log |Y| \geq H(y|\hat{y}) \geq H(y|x) \quad 38338 \backslash * \text{MERGEFORMAT} (-)$$

MERGEFORMAT (-)

由于 $H(P_e) \leq 1$, 那么上述不等式可以放缩为:

$$P_e \geq \frac{H(y|x) - 1}{\log |Y|} \quad 39339 \backslash * \text{MERGEFORMAT} (-)$$

费诺不等式给出了推断错误概率的下界, 表示无论攻击者使用什么推断方法, 都无法达到更高的推断精度。该下界主要与条件熵 $H(y|x)$ 以及未知量 y 的取值空间相关。条件熵越大, 表示获知 x 后 y 剩余的不确定性越大, 则推断错误概率的下界越大。未知量 y 的取值空间越大, 表示攻击者更有可能在全部取值范围内推断出 y 的取值, 因此推断错误概率的下界越小。下面证明本文提出的数据关联性 $T(y|x)$ 与费诺不等式的关系。

令 $P_c = p\{\hat{y} = y\}$ 表示推断正确概率, 由费诺不等式可知:

$$P_c = 1 - P_c \leq 1 - \frac{H(y|x) - 1}{\log |Y|} \quad 40340 \backslash * \text{MERGEFORMAT} (-)$$

由于均匀分布是 Y 在取值空间 Y 上的最大熵分布，即 $H(y) \leq \log |Y|$ ，因此：

$$\begin{aligned} P_c &\leq 1 - \frac{H(y|x) - 1}{\log |Y|} = \frac{\log |Y| - H(y|x) + 1}{\log |Y|} \\ &\leq \frac{\log |Y| - H(y|x) + 1}{H(y)} = \frac{\log |Y| + 1}{H(y)} - \frac{H(y) - I(y;x)}{H(y)} \\ &= \frac{\log |Y| + 1}{H(y)} - 1 + T(y|x) \end{aligned} \quad 41341 \backslash *$$

MERGEFORMAT (-)

得出 $P_c \leq \frac{\log |Y| + 1}{H(y)} - 1 + T(y|x)$ 。其中， $\frac{\log |Y| + 1}{H(y)} - 1$ 只与数据 Y 自身的概率分布有关。因此，当数据关联性 $T(y|x)$ 越大，攻击者推断正确概率的上界越大，说明数据关联性能反应出数据推断的可能性。

与此同时，不同数据之间通过物理规律与业务逻辑形成复杂的关联网络，使得数据推断呈现出逐步传播的特征。该过程可表示为：

$$P: x_i \rightarrow x_j \rightarrow \cdots \rightarrow y \quad 42342 \backslash * \text{MERGEFORMAT} (-)$$

其中， P 为推断泄露路径，即敏感信息并非由单一变量直接推断，而是通过多级关联逐步逼近。

设数据关联关系可表示为函数映射 $x_j = f_y(x_i)$ ，其中 f_{ij} 表示 x_i 与 x_j 的映射过程，则多级传播过程可表示为：

$$y = f_k(\cdots f_{23}(f_{12}(x_1))) \quad 43343 \backslash * \text{MERGEFORMAT} (-)$$

该表达说明，攻击者可通过构建多层映射关系，实现从可观测数据到敏感数据的逐步逼近。

在电力系统场景下，数据生成过程同时受到网络结构、潮流约束、市场机制以及调度行为等多重因素影响，变量间关系往往呈现出线性、单调性与复杂非线性并存的特征。若仅依赖单一相关性指标进行筛选，容易造成高风险关联关系的遗漏，从而影响后续风险路径识别的完整性与准确性。

基于上述考虑，本文选取了 Pearson 相关系数、Spearman 相关系数以及 MIC 作为候选变量对关联强度的联合刻画指标。其中，Pearson 相关系数用于描述变量间的线性依赖程度，Spearman 相关系数用于刻画变量间的单调相关关系，MIC 则用于识别更一般形式的非线性依赖。三者分别对应不同类型的统计结构，具有较强的互补性，采

用三种度量联合分析的方式，对变量对的关联强度进行多维刻画，可以在保证风险挖掘的效率同时尽可能降低风险漏检概率，为后续风险关联图构建与高风险传播路径筛选奠定基础。三种关联度量的适用性比较如表 3-2 所示。

表 3-2 关联度量在推断泄露风险发现中的适用性比较

度量方法	刻画对象	优势	局限性	适用场景
Pearson 相关系数	线性相关	计算简单、解释直观、适合大规模快速筛选	对非线性关系不敏感，易低估复杂耦合风险	连续运行量之间的线性波动分析
Spearman 相关系数	单调相关	对异常值较稳健，可识别非线性但单调的依赖关系	难以识别非单调、分段或周期性关系	趋势一致但非严格线性的变量关系分析
最大信息系数	一般非线性相关	可识别多类复杂函数型依赖，适合发现隐性耦合关系	计算复杂度相对较高，结果受样本规模影响较明显	多源异构电力数据中的高风险候选关系发现

多度量融合筛选与风险关联图构建

在获得 Pearson 相关系数、Spearman 相关系数和 MIC 等多种关联度量后，还需要进一步将不同度量结果转化为可支持风险传播分析的统一表征。其原因在于不同关联指标对应不同类型的统计依赖结构，若仅依据单一指标进行筛选，容易导致候选风险边识别不完整，进而影响后续风险路径挖掘的准确性。基于此，本文对多种关联度量进行归一化处理，并通过加权融合构造变量对之间的综合关联强度，以形成统一的风险筛选依据。

设 d_i 与 d_j 表示数据集 D 中任意两个数据项，定义二者之间的综合关联强度为 w_{ij} 。在对不同关联度量进行同尺度归一化后，可将综合关联强度表示为：

$$w_{ij} = \omega_1 |w_{ij}^{(P)}| + \omega_2 |w_{ij}^{(S)}| + \omega_3 MIC_{ij} \quad (44344 \setminus * MERGEFORMAT)$$

(-)

其中， $w_{ij}^{(P)}$ 和 $w_{ij}^{(S)}$ 分别表示数据项 d_i 与 d_j 之间的 Pearson 相关系数和 Spearman 相关系数， MIC_{ij} 表示二者之间的最大信息系数， ω_k 为各关联度量对应的权重系数。

上述融合方式的物理含义在于通过对多种相关性信息进行联合表征，将变量对之间可能存在的线性、单调性及复杂非线性依赖统一映射为单一的关联强度指标 w_{ij} 。与传统统计分析更关注显著性检验不同，推断泄露威胁的风险识别更强调是否存在可被攻击者利用的信息耦合关系。

在此基础上，设 τ 为关联强度筛选阈值，则候选风险边集合可定义为：

$$E_{\text{cand}} = \{(d_i, d_j) | s_{ij} \geq \tau, d_i, d_j \in D\} \quad 45345 \setminus * \text{MERGEFORMAT}$$

(-)

即当数据项 d_i 与 d_j 之间的综合关联强度不低于预设阈值 τ 时，将该变量对纳入候选风险边集合；否则，将其视为低风险或无显著风险的变量对。通过阈值筛选，可在保留主要风险关联的同时抑制弱相关边的大量引入，从而降低后续路径分析的复杂度。

基于候选风险边集合，可进一步构建数据风险关联图。设数据风险关联图记为：

$$G_{\text{cor}} = (V, E, W) \quad 46346 \setminus * \text{MERGEFORMAT} (-)$$

其中， V 为节点集合，每个节点对应一种数据实体、数据类别或数据特征； E 为边集合，表示节点之间存在潜在的数据推断关联； W 为边权集合，用于表征各边对应的关联强度。对于任意边 $E_{ij} \in E$ ，其权重为 w_{ij} ，即边权直接由数据项 d_i 与 d_j 的综合关联强度给出。边权越大，表示从源节点到目标节点之间潜在的推断耦合越强，对应的风险传播能力也越高。

需要说明的是，风险关联图本质上是一个有向加权图。其有向性来源于推断问题本身的方向性，即数据推断通常表现为由已观测数据推断未知敏感数据的过程，而非无差别的双向替代关系。对于具有明确物理机理或业务逻辑的数据对，边的方向可由先验知识直接确定。例如，在电力系统场景中，由节点边际电价到阻塞分量、由阻塞分量到传输分布因子、再由传输分布因子到网络拓扑结构，均具有较明确的方向性，其对应边的指向可依据系统机理给出。对于方向暂不明确但存在高强度耦合的数据对，则可在后续推断验证阶段，通过单向预测、双向回归或重构误差比较等方式进一步判定边的实际方向，从而提高风险关联图的真实性与可解释性。

从结构上看，风险关联图将原本分散的数据关联分析结果转化为统一的图结构表达，使数据间关联关系的挖掘问题转化为图上边连接关系的识别问题，使数据敏感程度与推断风险的评估问题转化为节点重要性与路径传播能力的分析问题。图中节点表示不同数据实体，节点的初始敏感程度可由前期数据分类分级或初步风险标定结果给出；边及箭头表示数据间可能存在的推断关系及其方向；边权及边的粗细则反映该推断关系的强弱。由此，风险关联图不仅能够直观表示不同数据之间的耦合状态，还能够为跨数据推断路径发现提供统一载体。

在完成图构建后，为支持路径级风险分析，还需要定义从公开数据到敏感数据的传播路径强度。设 P 表示从公开数据集合 D_{pub} 中某一数据项出发，最终到达敏感数据 $d_s \in D_{\text{pri}}$ 的一条推断路径，即：

$$P = (d_{i_0}, d_{i_1}, \dots, d_{i_k}) \quad 47347 \setminus * \text{MERGEFORMAT} (-)$$

其中, $d_{i0} \in D_{pub}$, $d_{iL} = d_s \in D_{pri}$, 且对任意 $l=0,1,\dots,L-1$, 均有 $(d_{il}, d_{i,l+1}) \in E$, 则路径 P 的关联强度可定义为路径上各边权的乘积, 即:

$$w_{cor}(P) = \prod_{l=0}^{L-1} w_{i_l, i_{l+1}} \quad 48348 \setminus * \text{MERGEFORMAT} (-)$$

由于 $w_{i_l, i_{l+1}} \in [0,1]$, 因此该定义能够有效体现路径中的短板效应, 即只要路径中存在某一条较弱的边, 则整体路径强度会显著衰减。这一特征与推断泄露威胁的实际过程相符: 敏感信息的逐级恢复依赖于每一级关联关系的持续有效传递, 只要中间某一环节的信息支撑不足, 整条路径的可利用性便会明显下降。相比于简单求和形式, 乘积式定义更适合用于识别真正具备连续传播能力的高风险路径。

进一步地, 若考虑不同路径长度之间的可比性, 也可采用几何平均形式对路径强度进行归一化表示, 即:

$$\bar{w}_{cor}(P) = \left(\prod_{l=0}^{L-1} w_{i_l, i_{l+1}} \right)^{\frac{1}{L}} \quad 49349 \setminus * \text{MERGEFORMAT} (-)$$

其中, $\bar{w}_{cor}(P)$ 更适合用于不同长度路径的横向比较, 而 $w_{cor}(P)$ 更适合作为风险累积意义下的先验强度度量。考虑到本文更关注推断风险在多级传播过程中的整体衰减特征, 因此后续分析采用 $w_{cor}(P)$ 所定义的乘积式路径强度作为先验风险值。

需要强调的是, 基于多度量融合所构建的风险关联图并不直接等同于最终的泄露结论, 其本质上是一个高风险候选空间。某条边或某条路径只有在后续推断验证中能够支撑敏感数据的有效重构时, 才能认定其具有真实的泄露威胁。数据风险关联图如图 3-5 (a) 所示。

此外, 风险关联图还具有动态可扩展性。随着业务场景变化、新数据类型接入或已有数据敏感程度调整, 图结构中的节点、边及边权均可相应更新。例如, 当节点边际电价数据由于能够进一步推断更高敏感度的系统参数而导致其风险上升时, 可相应提高该节点的初始敏感程度, 如图 3-5 (b) 所示; 当新的业务数据或交易数据进入系统时, 则可在图中增加对应节点, 并依据新的关联分析结果补充相关边及边权, 如图 3-5 (c) 所示。由此, 风险关联图能够适应开放共享环境下电力数据结构和风险形态的动态演化, 为后续持续性的风险监测与分级防护提供支撑。




图 3-5 数据风险关联图示意

基于神经网络的泄露风险量化评估

多度量关联筛选的主要作用在于从大量变量关系中识别具有潜在风险的候选关联，但该过程所反映的仍然是统计意义上的相关性，而非敏感信息可被实际恢复的能力。对于推断泄露威胁而言，风险是否真实存在，取决于攻击者能否利用可获取的数据构建有效映射，并据此实现对敏感信息的稳定推断。换言之，只有当公开数据在一定模型和约束条件下能够支持敏感变量的重构或敏感结构的识别时，相关关系才具有现实攻击意义。基于此，本节引入神经网络模型，对候选关联关系的可推断性进行进一步验证，并在此基础上建立面向推断型泄露的风险量化方法。

与一般预测任务相比，推断型泄露风险评估所关注的重点并不局限于模型拟合精度本身，而更强调模型输出对于敏感信息恢复能力的刻画。一方面，模型结果应具有明确的可验证性，即能够借助平均绝对误差（MAE）等指标评估敏感信息是否能够有效推断；另一方面，模型构建还应与具体场景的机理特征保持一致。特别是在电力系统中，节点电价、线路阻塞状态、潮流分布以及网络拓扑之间存在显著的物理耦合关系，若仅采用脱离机理约束的纯数据驱动模型进行拟合，虽可能获得较高的数值精度，但其结果往往缺乏充分的物理解释性与场景迁移能力。

基于上述考虑，本节在构建通用深度神经网络（Deep Neural Network, DNN）推断验证模型的基础上，进一步结合图注意力网络（Graph Attention Networks, GAT）对结构化关联信息进行建模，并引入物理约束损失函数刻画电网运行机理，以形成适用于拓扑泄露与敏感信息恢复分析的泄露风险量化模型。

通用深度神经网络推断验证模型

对于 3.1 节经多度量关联分析筛选得到的候选高风险变量对，仅凭统计关联强度尚不足以判断其是否具有现实攻击价值。推断泄露威胁风险判断的关键在于判断攻击者是否能够基于公开数据构建有效的映射关系，并据此实现对敏感信息的稳定恢复。

因此，在候选风险边识别之后，还需要进一步引入推断模型，对候选关联的可利用性进行验证。为此构建通用 DNN 推断验证模型，将关联分析得到的候选高风险变量对转化为具体的单向推断任务，并通过模型学习能力评估其是否足以支撑敏感信息恢复。

设候选高风险变量对集合为：

$$O_H = \{o_1, o_2, \dots, o_k\} \quad 50350 \backslash * \text{MERGEFORMAT} (-)$$

其中， $o_k = (d_i, d_j)$ 表示一个由数据项 d_i 推断数据项 d_j 的任务。对于任意候选任务 o_k ，记其输入特征为 x_k ，目标输出变量为 y_k ，其中 x_k 既可以表示单一公开变量，也可以表示由公开变量及其时序上下文、派生统计量和辅助特征共同构成的输入向量。基于此，可定义从输入特征到敏感变量估计值的非线性映射为：

$$\hat{y}_k = f_{\theta}(x_k) \quad 51351 \backslash * \text{MERGEFORMAT} (-)$$

其中， f_{θ} 表示参数为 θ 的 DNN 映射函数， $\hat{y}_k$ 表示对变量 y_k 的估计结果。

考虑到候选变量对的推断验证任务本质上属于监督学习问题，建立前馈式深度神经网络作为通用验证模型。网络结构包括输入层、两个隐藏层以及输出层，其中输入层接收公开数据及其上下文特征，隐藏层分别由包含 128 与 256 个神经元进行训练，激活函数则采用 ReLU 函数以增强模型对复杂非线性关系的表达能力。输出层则根据任务类型进行相应设计，当目标变量为连续型敏感数据时，输出层采用线性映射以生成回归估计值；当目标变量为离散标签或状态类别时，输出层可进一步扩展为分类形式。

对于连续型敏感变量，本文采用决定系数 R^2 作为主要验证指标，以衡量模型对目标变量变化的解释能力。对于候选任务 o_k ，其决定系数定义为：

$$R_k^2 = 1 - \frac{\sum_{t=1}^{n_k} (y_k^{(t)} - \hat{y}_k^{(t)})^2}{\sum_{t=1}^{n_k} (y_k^{(t)} - \bar{y}_k)^2} \quad 52352 \backslash * \text{MERGEFORMAT} (-)$$

其中， n_k 表示任务 o_k 对应的样本数， $y_k^{(t)}$ 表示第 t 个样本的真实值， $\hat{y}_k^{(t)}$ 表示模型输出的估计值， $\bar{y}_k$ 表示目标变量 y_k 的样本均值。

决定系数 R_k^2 越接近于 1，说明输入公开数据对敏感变量具有较强的解释能力，候选关联关系越可能转化为有效推断；反之，当 R_k^2 接近于 0 甚至为负时，表明虽然候选变量对在统计意义上具有一定关联，但这种关联不足以支持稳定的敏感信息恢复。在此基础上，本文在关联筛选阈值 τ 外，还设置有最小推断能力阈值 ϕ ，对于任意候

选变量对 (d_i, d_j) ，若其同时满足 $w_{ij} \geq \tau$ 且 $R_k^2 \geq \delta$ ，则可将其判定为具有现实攻击价值的高风险泄露边；若仅满足 $w_{ij} \geq \tau$ 而 $R_k^2 \leq \delta$ ，则说明该变量对虽具有统计关联，但尚不足以支撑稳定推断，更适宜归入统计相关但难以直接利用的中风险边。由此，多度量关联筛选与 DNN 推断验证共同构成了候选风险边识别与风险等级划分的双重依据。

将统计层面的综合关联强度与模型层面的推断精度进行融合，定义单边推断风险指数为：

$$\Gamma_{ij} = w_{ij} R_k^2 \quad 53353 \setminus * \text{ MERGEFORMAT } (-)$$

该指标能够同时反映两个方面的信息：其一，变量对在统计上是否具有足够强的依赖关系；其二，这种依赖关系在模型意义下是否能够被有效利用。因而， Γ_{ij} 越大，说明该变量对越可能构成真实的推断泄露边。

当研究对象不是连续变量，而是离散状态、类别标签或结构关系时， Γ_{ij} 式中的 R_k^2 可替换为适当的分类性能指标，例如分类准确率或成功推断概率。对于更一般的攻击成功判定问题，若设 ε_0 为可接受的推断误差阈值，则可将攻击成功事件定义为估计误差不超过该阈值，即 $|y - \hat{y}| < \varepsilon_0$ 。相应地，成功推断概率可表示为：

$$p_{\text{succ}} = p(|y - \hat{y}| < \varepsilon_0) \quad 54354 \setminus * \text{ MERGEFORMAT } (-)$$

其中， p_{succ} 描述了攻击者在给定容忍误差范围内成功恢复敏感信息的概率。当 p_{succ} 较高时，说明相关公开数据已具备较强的敏感信息恢复能力，因而对应的泄露风险更高。

从方法体系上看，通用 DNN 推断验证模型与前述多度量关联筛选共同构成了筛选—验证的两阶段风险识别框架。前者侧重从大规模变量关系中快速定位潜在高风险候选边，后者则通过深度学习模型检验这些候选边是否具有真实可利用性。与传统将统计相关性直接视为风险强度的做法相比，该方法能够更好地区分数据对之间存在关联与能够推断之间的差异，从而提高泄露风险识别结果的准确性与工程可信度。

对于电力系统数据而言，这种通用 DNN 验证思路具有较好的适用性。一方面，深度神经网络能够利用其非线性表征能力识别复杂变量关系，为多源异构数据的推断验证提供统一模型；另一方面，该模型可作为后续专用风险量化模型的基础框架，在此基础上进一步融入图结构建模和物理约束损失，以支持更复杂的拓扑泄露、阻塞识别以及关键参数恢复等推断任务。

面向拓扑泄露的图注意力网络与物理约束量化模型

对于一般敏感变量，3.2.1 节所构建的通用 DNN 推断验证模型能够从输入数据到

目标敏感信息之间学习非线性映射关系，并据此评估候选关联是否具有现实可利用性。然而，电网拓扑泄露问题与一般回归或分类任务存在本质差异。拓扑结构并非单一标量或独立标签，而是由节点、支路及其连接关系共同构成的图结构对象；同时，节点边际电价、阻塞分量、功率传输分布因子以及网络导纳矩阵之间存在明确的物理耦合关系，若仅采用不含结构先验的黑箱模型进行拟合，虽然可能获得较高的数值精度，但其结果往往缺乏足够的物理解释性与场景迁移能力。基于此，本文针对拓扑泄露评估任务，在通用 DNN 验证框架基础上，引入图注意力网络与物理约束损失函数，构建面向拓扑泄露的专门量化模型，以 GAT 对节点间动态依赖进行表征，再通过全连接解码器预测边存在概率，并在损失函数中融入经济调度约束和地理统计约束，以提升推断结果的真实性与可解释性，模型架构如图 3-6 所示。




图 3-6 面向拓扑泄露的 GAT 与物理约束量化模型架构

电网拓扑可表示为有向图 $G_{top} = (V, E)$ ，其中 $V = \{v_1, v_2, \dots, v_N\}$ ， E 为边集合， N 为节点总数。对于任意节点 $v_i \in V$ ，其输入特征记为 x_i ，可由节点时序电价数据、阻塞信息、已知拓扑局部信息以及节点空间属性等共同构成。节点时序电价数据作为核心节点特征输入 GAT 模型，以反映不同节点在运行过程中所携带的经济关联信号；与此同时，部分已知支路连接状态和地理位置可作为先验条件，用于约束候选连接关系的可行范围。

为刻画拓扑推断过程中节点间的非对称依赖关系，采用图注意力网络对图结构数据进行编码。设节点 v_i 的初始特征向量为 z_i ，则首先通过线性变换将输入映射到新的表示空间：

$$z_i^{(1)} = Wz_i + a$$

55355* MERGEFORMAT (-)

其中， $\mathbf{W}$ 为待学习的权重矩阵， $\mathbf{a}$ 为偏置向量，对于节点 v_i 及其一阶邻居节点 $v_j \in N(v_i)$ ，定义二者之间的注意力系数为：

$$\alpha_{ij} = \frac{\exp(\text{LeakyReLU}(\mathbf{a}^T [\mathbf{W}\mathbf{z}_i \parallel \mathbf{W}\mathbf{z}_j]))}{\sum_{k \in N(v_i)} \exp(\text{LeakyReLU}(\mathbf{a}^T [\mathbf{W}\mathbf{z}_i \parallel \mathbf{W}\mathbf{z}_k]))} \quad 56356 \setminus *$$

MERGEFORMAT (-)

其中， $\parallel$ 表示向量拼接操作， α_{ij} 则表示节点 v_j 对节点 v_i 表征更新的权重。利用归一化后的注意力权重，可对邻域信息进行加权聚合，得到节点 v_i 的更新表示：

$$\mathbf{z}_i' = \sigma \left(\sum_{j \in N(v_i)} \alpha_{ij} \mathbf{W}\mathbf{z}_j \right) \quad 57357 \setminus * \text{MERGEFORMAT} (-)$$

其中， σ 表示非线性激活函数。与固定邻域聚合方式不同，GAT通过可学习的注意力权重实现对不同邻居节点贡献度的自适应分配，能够更精确地刻画电网中由功率传输、阻塞传播和价格联动所形成的异质结构关系，注意力机制示意如图 3-7 所示。本文进一步采用多头注意力机制，以在不同子空间中并行学习节点间交互模式，从而在模型表达能力与训练开销之间取得较好平衡。




图 3-7 注意力机制示意图

在获得节点嵌入表示后，为实现未知支路连接关系的判别，本文进一步构建基于节点对的解码模块。对于任意候选节点对 (v_i, v_j) ，将其嵌入表示进行拼接，并输入全连接神经网络，输出边存在概率：

$$\hat{y}_{ij} = f_{\phi}(\mathbf{z}_i \parallel \mathbf{z}_j) \quad 58358 \setminus * \text{MERGEFORMAT} (-)$$

其中， f_{ϕ} 表示参数为 ϕ 的解码函数， $\hat{y}_{ij} \in [0, 1]$ 表示节点 v_i 与 v_j 之间存在拓扑连接的预测概率。当 $\hat{y}_{ij}$ 高于给定阈值时，判定对应节点对之间存在支路连接；反之，则判定为不存在连接关系。由此，拓扑泄露问题被转化为图上的链路预测问题，而模型输出的边存在概率则构成面向拓扑恢复能力的直接量化结果。

考虑到真实电网拓扑通常较为稀疏，负样本数量远大于正样本数量，若直接对全部节点对进行训练，容易导致类别不平衡和计算冗余。针对这一问题，本文引入基于节点度和节点距离的负采样策略，以提高训练效率并增强模型对物理可行连接关系的辨识能力。具体而言，节点度较低且距离拓扑中心较远的节点，更有可能不与其他节点形成直接支路连接，因此其被采样为负样本的概率可适当提高。设节点 V_i 与中心节点 V_c 的欧氏距离为：

$$dis(i,c) = \sqrt{(X_i - X_c)^2 + (Y_i - Y_c)^2} \quad 59359 \setminus * \text{MERGEFORMAT}$$

(-)

其中， (X_i, Y_i) 和 (X_c, Y_c) 分别表示节点 V_i 与中心节点 V_c 的空间坐标，通过结合节点度与空间距离构造负样本，可使训练样本更加符合电网拓扑的客观分布特征，从而减少不合理负样本对模型学习过程的干扰。

仅依赖链路预测误差进行训练，虽然能够学习节点对之间的连接模式，但仍不足以保证推断结果满足电网运行机理。为此，本文进一步在标准监督损失基础上引入物理约束项，将公开数据与拓扑结构之间的耦合规律转化为正则项嵌入训练目标。设基本预测误差记为均方误差项 L_{MSE} ，则总体损失函数可表示为：

$$L = L_{MSE} + \omega_1 L_1 + \omega_2 L_2 + \omega_3 L_3 \quad 60360 \setminus * \text{MERGEFORMAT} (-)$$

其中， $\omega_1, \omega_2, \omega_3 \geq 0$ 为权重参数， L_1, L_2, L_3 分别表示电价经济惩罚项、节点度惩罚项和线路长度惩罚项。下面说明三类惩罚项设计

1) 电价经济惩罚项

拓扑泄露之所以能够在公开数据条件下发生，其根本原因在于电网拓扑结构并不是孤立存在的，而是通过潮流计算、经济调度与市场出清过程嵌入到节点电价、阻塞状态等可观测数据之中。在现行电力市场运行机制下，主要采用直流潮流模型进行电价计算，节点边际电价、线路阻塞信息与电网拓扑之间存在由物理规律和市场机制共同决定的关联路径，攻击者正是依赖这一关联路径，才能由公开数据逐步逼近网络拓扑。

在直流潮流近似下，设去除平衡节点后的节点有功注入向量为 $\mathbf{P}$ ，电压相角向量为 $\boldsymbol{\theta}$ ，则系统满足： $\mathbf{P} = \mathbf{B}\boldsymbol{\theta}$ ，其中， $\mathbf{B}$ 为仅考虑支路电抗的节点导纳矩阵。进一步地，若以 $\mathbf{A}$ 表示网络关联矩阵，以 $\mathbf{D}$ 表示由支路电抗构成的对角矩阵，则导纳矩阵可写为 $\mathbf{B} = \mathbf{A}^T \mathbf{D} \mathbf{A}$ 。这表明节点导纳矩阵本质上由拓扑连接关系与线路参数共同决定。对于线路潮流向量 $\mathbf{f}$ ，有 $\mathbf{f} = \mathbf{D} \mathbf{A} \boldsymbol{\theta}$ ，结合潮流方程可进一步得到 $\mathbf{f} = \boldsymbol{\Gamma} \mathbf{P}$ ，其中 $\boldsymbol{\Gamma}$ 为功率传输分布因子矩阵。

由此，电网拓扑首先通过 $\mathbf{A}$ 和 $\mathbf{D}$ 决定导纳矩阵 $\mathbf{B}$ ，进一步影响功率传输分布因子矩阵 $\mathbf{\Gamma}$ ，最终计算得到潮流分布和阻塞状态，即：

$$\mathbf{B}^T = \mathbf{\Gamma}^T \mathbf{A}^T \mathbf{D} \quad 61361 \backslash * \text{MERGEFORMAT} (-)$$

该式进一步说明，导纳矩阵、功率传输分布因子矩阵与网络连接结构之间存在可逆意义上的耦合关系，因此一旦攻击者能够从公开数据中估计出阻塞价格或潮流分布特征，就有可能逆向逼近支路连接关系。

在经济调度层面，节点边际电价由能量价格、阻塞价格和网损价格共同组成。在直流潮流模型下，若忽略网损因素，则节点边际电价中的阻塞分量可被视为拓扑泄露的关键中介变量。节点阻塞价格 λ_i 与线路影子价格 τ_{ij} 之间满足线性关系，而阻塞价格又与导纳矩阵之间满足耦合关系。潮流约束的目标函数可以描述为：

$$\tilde{\mathbf{p}}^* = \arg \min_{\tilde{\mathbf{p}}} \mathbf{c}^T \tilde{\mathbf{p}} \quad 62362 \backslash * \text{MERGEFORMAT} (-)$$

满足约束：

$$\underline{\mathbf{p}} \leq \tilde{\mathbf{p}} \leq \bar{\mathbf{p}} \quad 63363 \backslash * \text{MERGEFORMAT} (-)$$

$$\tilde{\mathbf{p}}^T \mathbf{1} = 0 \quad 64364 \backslash * \text{MERGEFORMAT} (-)$$

$$-\bar{\mathbf{f}} \leq \tilde{\mathbf{\Gamma}} \tilde{\mathbf{p}} \leq \bar{\mathbf{f}} \quad 65365 \backslash * \text{MERGEFORMAT} (-)$$

其中，式(3-27)表示发电出力约束， $\underline{\mathbf{p}} \in \mathbf{R}_+^N$ ， $\bar{\mathbf{p}} \in \mathbf{R}_+^N$ 表示节点注入节点功率的下界和上界；式(3-28)表示功率平衡约束，式(3-29)为线路潮流约束， $\bar{\mathbf{f}} \in \mathbf{R}_+^L$ 表示各条线路的线路容量。

通过直流潮流计算和约束说明，虽然攻击者并不直接掌握敏感拓扑信息，但节点电价等公开数据中已经隐含了由拓扑结构传递而来的物理约束信息。基于这一机理，本文在损失函数中引入电价经济惩罚项，以约束预测拓扑与公开电价信号的一致性。

当预测得到的邻接矩阵 $\mathbf{A}$ 与线路电抗向量 $\mathbf{X}$ 不能与阻塞价格 λ_i 保持协调时，应增加额外惩罚。因此可定义电价经济惩罚项为：

$$L_1 = \mathbf{A}^T \text{diag}(\mathbf{X}) \mathbf{A} \lambda_i \quad 66366 \backslash * \text{MERGEFORMAT} (-)$$

该项越小，说明推断得到的拓扑在经济调度机理下越合理；反之，则说明模型虽然可能在数值上得到某种连接结果，但该结果难以被公开电价与阻塞信号所支持。因而，电价经济约束实际上是将公开价格数据中隐含的拓扑信息显式转化为模型训练中的物理正则，从而使拓扑泄露量化不再停留于纯粹的数据拟合层面，而能够体现经济运行机理的约束作用。

2) 节点度惩罚项和线路长度惩罚项

除了经济调度路径之外，电网拓扑还表现出明显的地理统计特征。真实电网在长

期建设和运行过程中，不仅要满足潮流传输与经济运行要求，同时还受到区域布局、输电成本、站点分布等现实条件约束，因此其拓扑结构通常具有较稳定的统计规律，例如节点数与线路数之间近似线性相关、平均节点度落在相对稳定的区间、平均线路长度具有显著的空间约束特征等^[60]。正是这些统计规律，使得地理信息能够作为拓扑推断中的重要辅助先验。本文将地理约束简化为节点度约束和线路长度约束，以方便模型训练。

对于节点度约束，真实电网中不同节点的连接度虽然不完全相同，但整体上服从相对稳定的统计分布，不会出现大面积过度连接或过度稀疏的异常结构。因此，在拓扑推断中，可通过约束预测节点度与平均节点度之间的偏差，抑制不符合实际网络结构的连接模式，将节点度惩罚项表示为：

$$L_2 = \sum_{i \in V} |\hat{k}_i - \langle k \rangle| \quad 67367 \backslash * \text{MERGEFORMAT} (-)$$

其中， $\hat{k}_i$ 表示节点 v_i 的预测节点度， $\langle k \rangle$ 表示系统平均节点度。该项实质上体现了电网拓扑在连通性和复杂度上的统计约束。

对于线路长度约束，真实输电线路的建设受到地理距离和工程成本的共同影响，因此节点间连接通常具有空间邻近性，过长或不合理跨越的支路在真实电网中出现概率较低。基于这一事实，可用线路长度偏差刻画预测拓扑与地理分布的一致性，将线路长度惩罚项表示为：

$$L_3 = \sum_{(i,j) \in E} |\hat{l}_{ij} - \langle l \rangle| \quad 68368 \backslash * \text{MERGEFORMAT} (-)$$

其中， $\hat{l}_{ij}$ 表示节点 v_i 与节点 v_j 之间的预测线路长度， $\langle l \rangle$ 表示系统平均线路长度。该项并不意味着所有线路长度都必须接近平均值，而是通过惩罚显著偏离空间规律的连接关系，使推断结果更符合实际电网的空间布局特征。

综合来看，GAT 编码器负责从节点时序特征中提取结构相关表示，链路解码器负责输出候选连接关系的存在概率，而物理约束损失则负责将经济调度规律与地理统计规律嵌入学习过程。三者共同构成拓扑泄露量化模型框架。对于拓扑泄露评估而言，若模型能够在较高灵敏度（True Positive Rate，TPR）和较低误判率（False Positive Rate，FPR）条件下准确恢复未知支路连接，则说明公开数据已经携带了足够强的拓扑可推断信息，对应拓扑泄露风险较高；反之，若模型即使在引入物理约束后仍无法有效恢复支路连接，则说明现有公开数据尚不足以支撑高置信度的拓扑重构。

进一步将拓扑推断模型输出的边存在概率与前述关联筛选结果相结合，定义候选拓扑边 (v_i, v_j) 的拓扑泄露风险指数为：

$$\Gamma_{ij}^{(\text{topo})} = w_{ij} \hat{y}_{ij} \quad 69369 \setminus * \text{MERGEFORMAT } (-)$$

其中, w_{ij} 为 3.1 节得到综合关联强度, $\hat{y}_{ij}$ 表示 GAT 与物理约束模型输出的边存在概率。若研究对象为完整路径或局部拓扑子图, 则可进一步对边级风险进行累积, 形成面向局部结构泄露或全网拓扑泄露的综合风险指标。由此, 拓扑泄露风险不再仅由统计关联度决定, 而是同时考虑了结构化建模下的实际可恢复程度, 更能反映攻击者在公开数据条件下逆向重构网络结构的真实能力。

面向推断泄露威胁的安全防护测试

在完成风险识别与威胁量化之后, 本文进一步测试面向推断泄露威胁的安全防护方法。与传统以阻止非法访问为目标的数据安全防护不同, 推断泄露威胁的关键特征在于, 攻击者并不需要直接获取高敏感数据, 而是可以利用公开数据、低敏感数据及其关联关系, 通过统计分析、优化求解或机器学习方法间接恢复目标敏感信息。因此, 仅依赖传统访问限制策略, 难以有效应对此类威胁。面向推断泄露威胁的防护, 应在保障数据可用性的前提下, 削弱公开信息对敏感信息的可推断能力, 从而降低攻击者重建关键结构和运行状态的成功率。

当前数据安全防护体系主要由多类技术共同构成, 覆盖数据采集、传输、存储、使用、共享、删除和销毁等全生命周期, 以保障数据的机密性、完整性和可控性。总体来看, 现有防护技术可归纳为访问控制技术、信息干扰技术和密码学技术三类^[61]。访问控制技术通过制定访问策略和权限边界, 通常采用基于角色的访问控制或基于属性的访问控制模型, 并结合零信任架构实现细粒度权限管控, 以确保只有授权主体能够接触相关信息。信息干扰技术则通过匿名化、扰动或差分隐私等方式对原始数据实施受控修改, 使攻击者难以准确恢复真实信息。密码学技术主要包括联邦学习、安全多方计算 (MPC) 和同态加密 (HE) 等, 其目标是在不暴露原始数据内容的前提下完成联合计算与协同分析, 实现“数据可用不可见”。除此之外, 数据水印与溯源技术也可作为安全防护的重要补充, 通过在敏感数据中嵌入隐形标识, 对数据泄露后的传播路径和责任主体进行追踪, 增强数据流通过程的可审计性与可追责性。

从防护对象来看, 电力系统中的数据域大体可划分为公开共享数据域和受限使用数据域两类。公开共享数据域主要对应开放发布、上链共享、跨组织交换或对外披露的数据, 其主要风险在于攻击者可以直接获取公开信息, 并结合外部先验知识与数据关联关系实施推断攻击。受限使用数据域则主要对应内部分析、跨主体协同建模或受控交换的数据, 其风险集中体现在数据流通与联合计算过程中敏感信息被间接恢复或泄露。考虑到本文研究重点是推断泄露威胁, 且前文风险识别与量化分析主要围绕公

开数据引发的推断路径展开，因此本节将防护研究重点放在公开共享数据域，主要考察信息干扰技术对推断攻击效果和数据可用性的影响。

对于公开共享数据域而言，数据一旦向市场主体、监管对象或社会公众开放，攻击者便可以在合法或半合法条件下获取相关信息。在这种场景下，防护的关键已不再是单纯阻止访问，而是通过对公开数据实施受控处理，降低其被关联分析和逆向推断的能力。所谓信息干扰，是指在尽可能保持数据业务可用性的前提下，对数据内容、暴露范围或结构语义进行适度调整，以削弱攻击者从公开信息中恢复真实敏感结构的能力。由于信息干扰会在不同程度上改变原始数据，因此其防护效果需要从数据可用性和隐私保护性两个维度进行综合评价。

基于公开共享数据域中推断泄露的特点，本文选取数据加噪、数据掩码和数据混淆三类典型信息干扰技术开展实验分析。

1) 数据加噪

数据加噪是指在原始数据中叠加满足特定分布的扰动项，以在统计意义上隐藏真实取值，降低攻击者对关键参数和敏感结构的精确恢复能力。该方法的主要特点在于，不直接删除原始信息，而是通过引入随机扰动削弱局部精确性，使攻击者即使能够获得数据，也难以获得高置信度的推断结果。数据加噪通常能够较好保留数据的整体变化趋势与统计特征，因此适用于需要持续公开、但又不宜暴露精确运行状态的应用场景，如电力市场公开数据、运行统计指标和部分汇总发布信息。在推断防护语境下，数据加噪的核心作用在于提高攻击模型输入的不确定性，破坏公开数据与敏感目标之间的稳定映射关系。

2) 数据掩码

数据掩码是指通过降低部分敏感信息的公开比例，或者对关键字段进行遮蔽、替换、截断和比例压缩等处理，限制攻击者获得完整信息的能力。与数据加噪主要针对数值精度进行扰动不同，数据掩码更强调对信息暴露范围的控制，其本质是通过减少可观测维度和细节粒度，削弱攻击者建立有效推断模型所需的数据基础。对于电力数据而言，掩码方式尤其适用于对部分关键字段、关键节点和敏感属性进行选择性的隐藏，从而在保留业务主干信息的同时，抑制局部敏感信息的过度暴露。其优势在于实现方式相对直接，且便于与现有数据发布规则结合，但若掩码比例过高，也可能对数据分析、状态研判和业务应用造成较大影响。

3) 数据混淆

数据混淆是指通过伪装、替换、位置变换或构造虚假节点信息等方式，主动干扰攻击者对实体属性、空间位置和关联关系的识别过程。与数据加噪和数据掩码相比，数据混淆不仅作用于数值本身，还会改变数据所承载的结构语义，因此更适用于保护

空间布局、节点位置、连接关系和网络拓扑等强结构化信息。在电力系统场景中，若攻击者的推断目标不仅是某一具体数值，而是网络关系、拓扑结构或关键设备间的隐含联系，仅依靠简单的数值扰动往往难以达到理想效果，此时通过改变结构表达方式和关联呈现形式实施混淆，能够更有效地破坏攻击者的推断链条。数据混淆的优势在于对结构型推断攻击具有更强抑制作用，但同时也更容易影响数据语义一致性，因此需要在保护强度与业务可解释性之间进行权衡。

综上，面向推断泄露威胁的安全防护，不应仅停留于访问限制和静态隔离，而应结合公开数据在关联传播中的作用机制，有针对性地削弱其推断价值。本文将公开共享数据域作为重点对象，选取数据加噪、数据掩码和数据混淆三类信息干扰技术开展防护实验，分别从数值扰动、信息暴露控制和结构语义破坏三个层面抑制攻击者的推断能力，并以数据可用性和隐私性作为统一评价指标。该部分研究为后续比较不同干扰策略在拓扑隐私保护中的适用性与有效性奠定了基础，也为面向推断泄露威胁的差异化安全防护提供了实验依据。

电网数据场景下风险挖掘与威胁量化实验验证

为验证前文所提出方法在电网数据场景中的有效性与适用性，本节从风险挖掘验证、威胁量化验证以及防护效果分析三个层面开展实验研究。首先，通过多度量关联分析检验所构建的风险识别方法能否从多源异构电力数据中发现潜在的高风险关联关系与推断传播路径；其次，进一步借助通用深度神经网络和融合物理约束的图注意力网络模型，评估候选关联关系对敏感变量恢复和拓扑结构重构的支撑能力；最后，在此基础上引入数据加噪、数据掩码和数据混淆等信息干扰手段，考察不同防护策略对推断攻击效果、拓扑隐私保护性以及数据可用性的影响。通过上述实验，本节旨在从统计关联、模型推断到攻击可利用性和防护抑制效果等多个层面，对本章所构建的方法框架进行系统验证。

实验设计

本节实验采用 2.4 节所述的 PJM 电力市场数据集与 Matpower 仿真数据集进行实验。

在风险挖掘实验中，Matpower 仿真数据集用于验证数据关联分析能力，该部分在新英格兰 39 节点系统生成的数据集上进行实验，所用数据类别包括节点负荷、节点电价、线路潮流和节点相角四类，每类数据包含 2000 条数据样本，用以验证面向推断的数据关联性指标能否有效揭示不同变量之间的潜在推断关系；随后进一步在 PJM 电力市场数据集上进行扩展验证，原始数据经字段筛选和时间字段剔除后，最终用于

实验建模的有效字段为 39 类，覆盖发电、输电、市场交易等多个业务环节，时间跨度为 2023 年 1 月至 2024 年 1 月。

在威胁量化实验中，Matpower 仿真数据集用于验证结构化敏感目标泄露风险的拓扑推断场景，主要依据新英格兰 39 节点系统案例展开。负荷时序由 GEFC2012 负荷数据构造，以 1 小时为间隔生成 744 个样本作为测试集；同时在基准网络基础上生成 200 组差异化拓扑，用于训练和验证注意力网络模型。拓扑推断实验中，假定攻击者已知 70% 真实拓扑、节点电价、线路容量和线路影子价格，而未知节点电压和线路潮流信息，并能够获取节点地理位置信息。该设定较好反映了公开数据条件下的现实攻击场景。

在防护效果分析中，Matpower 仿真数据集用于引入数据加噪、数据掩码和数据混淆三类信息干扰方法，分别从数值扰动、信息暴露控制和结构语义破坏三个层面抑制攻击者的推断能力，综合考察不同防护策略在数据可用性、拓扑隐私保护性和攻击抑制效果之间的权衡关系。

基于关联分析的风险挖掘验证结果

为验证多度量关联分析在电网数据风险挖掘场景下的适用性，首先利用节点负荷、节点电价、线路潮流和节点相角进行数据关联计算实验，其中节点负荷和节点电价属于开放程度较高的数据，线路潮流和节点相角则对应更高敏感等级。由于大量电力状态量和量测量为连续值，实验中先采用 K-Means 方法对数据进行离散化处理，再通过费诺不等式计算不同数据类别之间的推断关联性矩阵。结果如表 3-3 所示。

表 3-3 费诺不等式电力数据关联性矩阵

已知量\推断量	节点负荷	节点电价	线路潮流	节点相角
节点负荷	1	0.6019	0.5649	0.3203
节点电价	0.3028	1	0.3524	0.2517
线路潮流	0.5543	0.7046	1	0.4034
节点相角	0.3127	0.5038	0.3835	1

结果表明，在线路潮流和节点电价、节点负荷等变量之间，存在较高的关联程度；节点相角与线路潮流、节点电价之间也表现出较强耦合关系。这说明在电网运行场景中，即便公开数据本身敏感程度较低，也可能通过物理耦合关系间接携带高敏感信息。

在此基础上，本文进一步引入 MIC 对上述关联关系进行验证。结果如表 3-4 所示。

表 3-4 MIC 电力数据关联性矩阵

已知量\推断量	节点负荷	节点电价	线路潮流	节点相角
节点负荷	1	0.9712	0.8158	0.7123
节点电价	0.7348	1	0.7602	0.64368
线路潮流	0.9489	0.8689	1	0.7535
节点相角	0.7864	0.8156	0.8944	1

结果显示，在引入 2000 条样本后，节点负荷与节点电价、线路潮流与节点负荷、节点相角与线路潮流等变量对的 MIC 数值均保持在较高水平，整体上显著高于基于费诺不等式关联性矩阵所呈现的线性或弱非线性关系强度。这一结果表明，MIC 在捕获电力数据中的复杂非线性依赖方面具有较高敏感性，能够有效补充传统统计量的不足。特别是对由潮流约束、功率平衡和网络结构共同决定的数据关系，仅依赖 Pearson 或 Spearman 等单一指标，容易低估潜在的推断风险，而多度量联合分析则更有利于保留具有攻击价值的候选风险边。

进一步地，本文在真实电碳数据集上对 39 类有效字段进行 MIC、Spearman 和 Pearson 联合分析，取关联数据阈值为 0.7 可以识别出多组高关联变量对，结果如表 3-5 所示。

表 3-5 PJM 数据联合关联性矩阵

数据名称		MIC 数值	Spearman 系数数值	Pearson 系数数值
计划潮流	非计划潮流	0.9999	1	1
市场出清价格	封顶后的市场出清价格	0.9936	1	1
经济最大容量	紧急最大容量	0.9475	0.9911	0.9624
调频市场容量出清价格	调频市场容量出清价格补偿总额	0.8794	0.9783	0.9850
调频市场性能出清价格	调频市场性能出清价格补偿总额	0.8751	0.9623	0.9177
辅助服务所需容量	总兆瓦容量	0.8082	0.6469	0.6709
系统电能价格	节点边际电价	0.7888	0.9637	0.9479
平均每小时初步负荷	历史负荷	0.7634	0.9638	0.9726
总兆瓦容量	非同步备用兆瓦分配容量	0.7608	0.5922	0.7546
发电总兆瓦数	平均每小时初步负荷	0.7552	0.9546	0.9562
系统日前电能价格	日前总节点边际电价	0.7463	0.9078	0.8619

	数据名称	MIC 数值	Spearman 系数数值	Pearson 系数数值
紧急最大容量	已承诺总容量	0.7384	0.0110	0.0129
经济最大容量	已承诺总容量	0.7251	0.0303	0.0165

结果表明，“计划潮流—非计划潮流”、“市场出清价格—封顶后的市场出清价格”、“经济最大容量—紧急最大容量”等变量对在三类指标下均表现出较强依赖，说明这些变量之间存在较稳定的显式关联；而“紧急最大容量—已承诺总容量”、“经济最大容量—已承诺总容量”等变量对则表现出 MIC 较高但 Pearson 系数、Spearman 系数接近于零的现象，说明其关联主要体现为复杂非线性结构，传统线性度量难以有效识别。代表性数据对的多度量相关性比较如图 3-8 所示，该结果与前文关于多度量融合必要性的理论分析相吻合。




图 3-8 代表性数据对的多度量相关性比较

基于通用深度神经网络推断模型的威胁量化验证结果

在完成关联筛选后，本文进一步采用通用 DNN 推断模型验证这些候选关联关系是否具有现实可利用性，并引入自回归积分移动平均模型（Autoregressive Integrated Moving Average Model，ARIMA）和支持向量回归模型（Support Vector Regression Model，SVR）作为基线进行对比，通过决定系数值判断模型效果，决定系数阈值为 0.7。从表 3-6 可以看出，在识别出的 13 组高关联数据对中，DNN 模型对其中 10 组提供了较好的量化验证效果，而 ARIMA 和 SVR 分别仅对 5 组和 7 组具有较强验证能力。由此可见，尽管传统时间序列模型和支持向量回归模型在部分变量对上也能捕获

一定依赖关系，但对于多源异构电力数据中复杂的非线性耦合关系，深度神经网络仍表现出更好的表征与拟合能力。

从具体结果看，诸如“计划潮流—非计划潮流”、“市场出清价格—封顶后的市场出清价格”等变量对在 DNN、ARIMA 和 SVR 下均表现出接近 1 的拟合结果，说明这类变量对之间存在高度稳定的映射关系，公开或低敏感数据一旦泄露，极易导致对应敏感变量被准确恢复。与此同时，一些在关联分析阶段已表现出较强复杂依赖的变量对，如“调频市场容量出清价格—调频市场容量出清价格补偿总额”、“平均每小时初步负荷—历史负荷”等，在 DNN 模型下仍获得较高决定系数，而 ARIMA 与 SVR 的验证效果则相对较弱，进一步说明 DNN 更适合作为本章威胁量化的二次验证工具。

另一方面，也存在部分在 MIC 指标下较高、但在 DNN 验证阶段精度较低的变量对，如“总兆瓦容量—非同步备用兆瓦分配容量”等。这表明统计关联并不必然等同于高可利用性风险，部分变量对虽存在潜在耦合关系，但尚不足以支撑稳定推断。该现象也从实验角度说明，将多度量关联筛选和神经网络推断验证设计为串联结构是必要的：前者负责高效缩小候选空间，后者负责判断候选关系是否具有现实攻击价值。

表 3-6 推断模型电力数据关联性矩阵

数据名称		DNN 模型	ARIMA 模型	SVR 模型
计划潮流	非计划潮流	1	0.9972	0.9981
市场出清价格	封顶后的市场出清价格	0.9999	0.9948	0.9963
经济最大容量	紧急最大容量	0.9335	0.9315	0.9146
调频市场容量出清价格	调频市场容量出清价格补偿总额	0.9698	0.6534	0.6812
调频市场性能出清价格	调频市场性能出清价格补偿总额	0.8537	0.6887	0.7315
辅助服务所需容量	总兆瓦容量	0.7257	0.6129	0.6584
系统电能价格	节点边际电价	0.8955	0.9186	0.9342
平均每小时初步负荷	历史负荷	0.9166	0.6641	0.6953
总兆瓦容量	非同步备用兆瓦分配容量	0.2954	0.5538	0.6187
发电总兆瓦数	平均每小时初步负荷	0.8982	0.6835	0.9041
系统日前电能价格	日前总节点边际电价	0.7332	0.9012	0.8874
紧急最大容量	已承诺总容量	0.3413	0.0289	0.0417
经济最大容量	已承诺总容量	0.4224	0.0361	0.0534

基于图注意力网络与物理约束量化模型的威胁量化验证结果

为进一步验证本章方法在结构化敏感目标上的适用性，实验将研究对象从一般变量对扩展到电网拓扑这一典型高敏感结构信息。在已知新英格兰电力 39 节点系统 70% 拓扑结构、节点电价、线路容量、线路影子价格，未知节点电压和潮流信息的条件下，结合电网节点地理信息，用生成的训练集数据进行 GAT 模型训练，推断全系统的拓扑连接情况。本文中取时间序列特征维度为 200，激活函数的阈值为 0.01，设置的学习率为 0.001，模型迭代次数为 64 次。单次推断结果如图 3-9 所示。

实验结果表明，在常规场景下，当最优分类阈值取 0.4574 时，GAT 模型在 46 条待测线路中正确识别 44 条，仅漏检 2 条线路，误判 3 条线路，对应 TPR 为 0.92、FPR 为 0.17。该结果说明，GAT 模型可以在较高准确率和较低误判率情况下，实现电网拓扑的有效恢复。




图 3-9 新英格兰电力 39 节点系统拓扑推断单次结果图

本文同时将 GAT 模型与多层感知器（Multi-Layer Perceptron, MLP）、通过固定规则（均值）处理邻居信息的传统图神经网络（Graph Neural Network, GNN）和基于拉普拉斯矩阵进行节点特征聚合的图卷积网络（Graph Convolutional Network, GCN）3 种模型作为基线对比，同时引入 HyperGCN^[62]和 Transformer 图神经网络（Graph Transformer Networks, GTN）^[63]作为对比，保持其他因素不变，验证所提出模型的有效性和优越性，性能对比结果如图 3-10 与图 3-11 所示。




图 3-10 不同模型的拓扑推断 ROC 曲线图




图 3-11 不同模型在 39 节点拓扑推断任务上的性能比较图

实验结果表明，GAT 模型的平均绝对误差（Mean Absolute Error，MAE）为 0.0732，AUC（Area Under Curve）为 0.94，均优于其他对比模型。这表明，对于具有明显图结构特征和邻域异质性的拓扑恢复任务，图注意力机制能够更有效地刻画节点间非对称依赖关系，并在电价经济约束和地理统计约束的共同作用下，获得更符合电网运行机理的推断结果。

在此基础上，本文进一步利用推断得到的拓扑结构构造虚假数据注入攻击（False Data Injection Attack，FDIA）向量，以验证拓扑泄露结果的现实攻击价值。实验中，根据节点与攻击点的欧式距离定义攻击影响因子，并据此生成攻击向量，在不同电网对错误数据的检测（Bad Data Detection，BDD）阈值下实施 FDIA，尝试产生误导性的电力系统状态估计结果^[64]。BDD 阈值代表了数据检测的灵敏度，阈值小易触发告警误报；阈值大则可能放过真实故障，降低系统可靠性。在本文场景中，BDD 阈值通过结合系统特性和卡方统计原理进行归一化计算确定，在显著性水平 0.05 的情况下，BDD 阈值推荐设置为 2.33^[65]。FDIA 成功率结果如图 3-12 所示




图 3-12 不同模型的 FDIA 成功率图

结果表明，利用本文模型恢复的拓扑结构能够完全绕过 BDD 机制，在不同的检测能力下实现隐蔽的 FDIA。

面向推断泄露威胁的安全防护实验

为评估不同信息干扰策略对推断泄露威胁的抑制效果，本文围绕 39 节点拓扑推断实验所用到的 Matpower 仿真数据开展安全防护实验，重点考察数据加噪、数据掩码和数据混淆三类方法在“数据可用性—拓扑隐私性”之间的权衡关系。由于信息干扰技术会直接或间接引起原始数据的信息损失或表达变化，因此，防护效果不能仅从隐私增强角度进行评价，还需要同时考虑数据在业务应用中的保真程度。

本文采用公开数据误差刻画原始数据的可用性。设干扰后数据与原始数据之间的百分比误差为 e ，则数据可用性可由误差的补值 $1/(e+1)$ 进行定义，用以表征公开数据在施加干扰后的保真程度。与此同时，本文以推断模型对目标拓扑重建结果的 MSE 作为拓扑隐私性的度量指标。MSE 越大，说明攻击者利用公开数据恢复真实拓扑的难度越高，对应的拓扑隐私保护效果越强。因此，数据可用性与拓扑隐私性分别从业务保留能力和攻击抑制能力两个方面反映安全防护方法的综合性能，并共同作为本节实验的核心评价指标。

1) 数据加噪

在数据加噪实验中，本文对公开电价添加均值为 0，标准差分别为 0.001、0.005、0.01、0.05、0.1、0.5、1 的拉普拉斯噪声。数据加噪实验结果如图 3-13 所示。




图 3-13 数据加噪实验结果

实验结果表明，随着噪声强度逐步增大，拓扑隐私性整体呈上升趋势，即攻击者基于公开电价推断电网拓扑的难度不断提高。然而，这一过程伴随着公开电价可用性的明显下降。当噪声标准差超过 0.01 后，虽然拓扑隐私性有所提升，但数据可用性已出现较大幅度衰减。进一步分析可知，数据加噪虽然能够有效破坏攻击模型所依赖的数值精确性，但其防护效果主要建立在对原始信息进行持续扰动的基础上，因此采用数据加噪难以做到数据可用性和拓扑隐私性均大于 50% 的平衡。

2) 数据掩码

在数据掩码实验中，通过降低输入训练模型的已知拓扑信息比例实现数据掩码，已知拓扑信息比例分别为 90%、70%、50%、30% 和 10%。数据掩码实验结果如图 3-14 所示。




图 3-14 数据掩码实验结果

实验结果表明，随着已知拓扑信息比例降低，攻击者能够利用的结构先验不断减少，拓扑隐私性随之逐步提升。当已知拓扑信息比例低于 50% 后，拓扑隐私性显著上升，说明此时攻击者已难以依赖公开数据与有限拓扑信息的结合推断出完整的电网拓扑结构。与数据加噪相比，数据掩码并不直接扰动数值本身，而是通过控制敏感信息

的暴露范围削弱攻击者的推断基础，因此在保护效果与业务保真之间表现出更好的平衡性，采用数据掩码基本能保证 50%信息可用同时拓扑隐私性大于 50%的平衡。

3) 数据混淆




图 3-15 数据混淆实验结果

在数据混淆实验中，通过混淆不同数量的节点，隐藏对应节点地理位置及其相关节点电价等信息，随机生成等同于混淆节点数量的随机节点信息训练，混淆节点数量分别为 1、5、10、20、30。数据混淆实验结果如图 3-15 所示，混淆 10 节点后的拓扑对比如图 3-16 所示。




图 3-16 10 节点位置混淆拓扑对比图

实验结果表明，数据混淆对拓扑推断攻击具有较强抑制作用。在 39 节点系统中，当混淆节点数量超过 5 个后，拓扑隐私性显著提升，说明攻击者基于公开数据恢复网络结构的能力受到明显削弱。与此同时，此时数据可用性仍可保持在 70%以上，整体表现优于数据加噪方法。当混淆节点数量进一步增加并超过 10 个后，虽然拓扑隐私性继续增强，但信息可用性开始明显下降。这表明，数据混淆能够在一定范围内同时保持较高的数据可用性和较强的拓扑隐私保护效果，但过强的混淆程度同样会对数据

的业务可用性造成不利影响。

为进一步验证数据干扰防护策略的效果，本文在拓扑推断数据集结果基础上，同样引入 FDIA 作为安全测试手段，评估不同防护措施对实际攻击可利用性的抑制效果。本文分别对公开数据施加数据加噪、数据掩码和数据混淆三类信息干扰处理，然后基于处理后的数据重新进行拓扑推断，并利用推断得到的拓扑结果构造 FDIA 攻击向量，分别在 BDD 阈值为 1、2 和 5 的条件下统计攻击成功率。实验结果如表 3-7 所示。

表 3-7 不同干扰技术下 FDIA 成功率

干扰技术		BDD 阈值		
		1	2	5
数据加噪 (噪声标准差)	0.005	63%	100%	100%
	0.05	0%	13%	57%
	0.5	0%	0%	0%
数据掩码 (掩码比例)	0.1	27%	100%	100%
	0.5	0%	0%	0%
	0.9	0%	0%	0%
数据混淆 (节点混淆数)	1	80%	100%	100%
	5	0%	0%	0%
	10	0%	0%	0%

通过实验验证，在未进行充分干扰时，攻击者仍可利用推断得到的拓扑实施较高成功率的 FDIA；而随着原始数据干扰强度增加，FDIA 成功率逐步下降，说明公开数据的推断可利用性被有效削弱，拓扑泄露对电力系统的现实威胁随之降低。具体而言，数据加噪在弱噪声条件下对攻击抑制作用有限，当噪声标准差提升至 0.05 及以上时，攻击成功率明显下降；数据掩码在掩码比例达到 0.5 后，可在不同检测阈值下基本阻断攻击；数据混淆则表现出较强的结构防护能力，当混淆节点数达到 5 个时，即可将 FDIA 成功率压低至 0。该结果说明，不同干扰策略在攻击防护层面的有效性存在明显差异，其中数据混淆对结构型泄露威胁的抑制能力最为突出。

从防护机理上看，三类干扰方式分别对应不同的抑制路径。数据加噪通过改变数值精度削弱攻击者对系统运行特征的准确把握；数据掩码通过限制关键信息暴露比例切断攻击所依赖的部分结构链条；数据混淆则通过构造虚假节点和伪结构关系直接干扰攻击者对拓扑的重构过程。因此，在面向公开数据域的分级防护实施中，数据掩码具有操作简便、部署成本较低的优点，而数据混淆则在保持较高信息可用性的同时，对拓扑隐私保护和攻击抑制表现出更强优势。不过，实验也表明，更高强度的保护往往伴随着更大的数据可用性损失，公开数据的隐私性与可用性难以同时达到较高水平，这说明推断泄露威胁的防护本质上仍然面临隐私—效用权衡问题。

综合上述实验结果可以看出，本章提出的风险识别、威胁量化与防护分析在电网

数据场景下具有较好的适用性、层次一致性和现实解释力。首先，在关联挖掘阶段，基于多度量的关联分析方法能够有效识别传统线性指标难以揭示的潜在高风险关系，尤其在刻画复杂非线性耦合和隐式依赖方面表现出明显优势。其次，在推断验证阶段，DNN 与 GAT 模型的实验结果表明，这些候选关联并非仅停留于统计相关层面，而是能够进一步支撑对敏感变量和敏感结构的高精度恢复，从而验证了关联风险向实际推断能力转化的可能性。再次，在攻击可利用性验证阶段，基于推断结果构造的 FDIA 实验进一步表明，前述识别出的高风险关系不仅具有可推断性，而且已经具备现实攻击意义，能够对系统运行安全造成实质性威胁。

本章小结

本章围绕电力数据开放共享场景下的数据推断泄露威胁，构建了由风险识别、威胁量化与安全防护组成的一体化分析框架：首先，通过融合 Pearson 相关系数、Spearman 相关系数与 MIC，对多源电力数据中的线性、单调及复杂非线性依赖关系进行联合刻画，构建面向推断泄露的风险关联图，实现高风险候选关系与传播路径的识别；其次，分别引入通用深度神经网络和融合物理约束的 GAT，对候选关联的可推断性、结构恢复能力及现实攻击价值进行量化验证，从而建立由统计相关到模型可推断再到攻击可利用的完整证据链；最后，针对公开共享数据域中的推断泄露威胁，进一步研究了数据加噪、数据掩码和数据混淆三类信息干扰防护方法，并结合拓扑重构与 FDIA 攻击实验分析不同策略在数据可用性、隐私保护性与攻击抑制效果之间的权衡。本章研究不仅验证了复杂关联关系向现实泄露能力转化的可能性，也为后续面向推断风险的数据安全等级动态更新策略设计提供了方法基础。

基于知识增强与数据驱动的分级治理方法

本章在前文风险识别结果基础上，构建由初步分级标定、动态等级更新和实验验证组成的分级治理方法体系：首先，利用大语言模型和频繁模式挖掘完成初始等级标定，为不同数据对象建立可解释的初始分级依据；其次，引入强化学习方法，根据推断风险、数据可用性和合规约束对安全等级进行动态调整；最后，通过电网数据场景实验验证所提方法在分级有效性、策略稳定性和动态适应性方面的表现。




图 4-17 基于知识增强与数据驱动的分级治理方法研究总体框架

基于大语言模型与频繁模式挖掘的初步分级标定

针对电力数据来源复杂、字段异构且缺乏统一人工标注的问题，仅依赖静态规则匹配或单一字段判断，难以形成稳定、可扩展的初始分级结果。为此，本节围绕初始等级生成问题，构建“规则抽取—特征压缩—频繁模式挖掘—结果映射”的初步分级标定方法。该方法以前述法规标准、工程文档和业务数据为输入，先从非结构化文本中抽取可执行的分级规则，再从结构化数据中识别敏感字段组合模式，最终将规则知识与数据特征共同映射为数据对象的初始安全等级。该方法使初步分级结果既保留制度规则依据，又反映数据对象在实际业务中的联合敏感性，为后续动态等级更新提供合理起点。

基于大语言模型的结构化分级规则抽取

在初步分级标定过程中，首先需要解决的是如何从法规标准、工程报告、业务说明等非结构化文本中提取可用于分类分级的结构化规则。与依赖人工阅读和手工整理的传统方式相比，这类文本往往篇幅较长、专业术语密集，且表达形式不统一，因而规则提取效率较低，也容易受到主观经验影响。若直接将原始文本用于规则匹配，还可能出现字段遗漏、条件歧义和规则粒度不一致等问题。因此，本文将该任务定义为面向领域文本的结构化信息抽取问题，其目标是将原始文本转换为统一的规则单元，为后续初步分级提供可计算的知识依据。

大语言模型在自然语言理解和结构化生成方面具有较强能力，为解决上述问题提供了可行方法。一方面，大语言模型能够识别复杂文本中的实体、属性及其上下文关系；另一方面，结合检索增强生成技术，可以在推理过程中引入外部知识，从而弥补通用模型在专业场景中的知识不足。基于此，本文构建了“模型理解—约束生成—知识校正—结构化输出”的规则抽取流程。该流程以法规条文、工程模板和业务说明等文本为输入，以面向分级任务的结构化规则库为输出。每条规则至少包含对象类别、关键字段、约束条件、风险提示和建议等级等要素，从而将分散于自然语言中的规范要求转化为可检索、可调用、可复用的规则表示。与直接人工整理相比，该流程在保证规则来源可追溯的同时，也有助于提高抽取效率和规则表达的一致性。

从任务特点来看，结构化规则抽取既要求模型具备较强的长文本理解能力，又要求其在字段约束下稳定输出预定格式。当前主流大语言模型架构主要包括 Encoder-only、Decoder-only 和 Encoder-decoder 三类。其中，Encoder-only 更适理解类任务，Decoder-only 更适合开放式文本生成，Encoder-decoder 则适用于输入到输出的序列转换任务^[66]。考虑到本研究任务兼具信息识别与受约束生成两方面特征，模型选型不仅要关注生成能力，还应重视其在专业术语识别、长文本处理和格式化输出方面的稳定性。综合比较后，本文选择综合性能较好的 DeepSeek-R1-Distill-Qwen-32B^[67]作为基础模型，用于完成规则的初步抽取。




图 4-18 DeepSeek-R1-Distill-Qwen-32B 模型架构

在确定模型后，本文进一步通过提示词模板对输出过程进行约束。具体而言，将抽取任务划分为字段定义、约束说明、输出格式和异常处理四个部分，在提示中明确字段含义、允许取值范围以及缺失项处理方式，并统一要求模型以标准 JSON 结构返

回结果。以输变电工程环境影响报告为例，可通过提示明确抽取项目名称、工程地点、电压等级、建设性质、线路长度等关键字段，并限定输出键名和层级关系。这样可将开放式文本生成转化为受控的字段抽取过程，降低冗余内容、格式漂移和字段错配对后续分级的影响。

仅依赖模型参数进行推理，仍难以满足电力领域规则抽取对准确性和一致性的要求。为此，本文引入检索增强生成技术，构建面向电力数据分类分级的知识增强抽取框架。该框架采用“检索—生成—校验”的实现方式：先根据输入文本和待抽取字段生成查询表示，从领域知识库中检索与当前任务最相关的规则片段和示例文档；再将检索结果与原始文本共同输入大语言模型，在外部知识约束下生成结构化规则；最后结合字段完整性和逻辑一致性对输出结果进行检查，以提高规则抽取的稳定性。

知识库主要由两类资源构成。一类是输变电工程环评报告、行业规范和项目模板等标准文档，主要用于提供字段定义、抽取规则和逻辑约束；另一类是人工标注的高质量结构化示例文档，主要用于提供从原文到结构化结果的映射参照。在具体实现中，本文采用嵌入模型对知识文档进行向量化表示，并将其存入向量数据库。对于输入查询，系统首先生成查询向量，再检索知识库中最相关的 Top-K 个片段。例如，在分析“线路长度”字段时，系统可同时获取模板中的提取规则和示例文档中的实际表达方式，随后将检索结果与待分析文本拼接为结构化提示模板，输入大语言模型生成最终结果。

通过上述过程，基于大语言模型的结构化分级规则抽取方法实现了从非结构化文本到结构化规则库的转换。其作用不仅在于提取字段信息，还在于为后续初步分级建立统一的规则表示。输出结果一方面可用于构建敏感字段查找表和类别映射关系，另一方面也可后续频繁模式挖掘提供字段筛选依据和规则先验。总体来看，该方法将非结构化文本中的领域知识转化为可计算、可调用的规则信息，通过模型选型、提示约束和检索增强的协同作用，较为高效地提取出与分类分级相关的关键字段和规则内容，为后续基于频繁模式挖掘的初步分级标定提供了规则基础。

基于自编码器和频繁模式挖掘的数据特征提取

在完成结构化规则抽取后，初步分级标定还需进一步解决两个问题：其一，电力数据字段种类繁多、维度较高，若直接基于原始字段进行判断，容易受到冗余特征和噪声干扰；其二，数据敏感性往往不由单一字段决定，而体现为多个字段在业务语义和使用场景中的联合敏感性。尤其在电力场景中，一些单独看并不敏感的字段，在与其他字段共同出现时，可能形成更高层次的推断风险。为此，本文构建“特征压缩—事务化表示—频繁模式挖掘—敏感映射”的初步分级标定流程，将数据对象的初始分

级问题转化为敏感字段组合模式的识别与量化问题。

该方法的输入为待分级对象的原始字段集合以及上一阶段形成的结构化规则库。首先，利用自编码器对高维字段进行表示学习，提取能够保留关键信息的低维特征表示，以减弱冗余特征对后续分析的干扰；其次，依据规则库中的敏感字段定义和类别映射关系，将每个数据对象转换为面向频繁模式挖掘的项目集；再次，采用 FP-Growth 算法识别高支持度的敏感字段组合，提取具有代表性的联合敏感模式；最后，将频繁模式的覆盖情况、支持度和组合强度映射为对象级敏感特征向量，并据此形成初步分级依据。通过这一过程，初步分级结果既保留了字段层面的制度规则信息，又进一步反映了多字段组合带来的潜在推断风险。

自编码器是一种无监督学习的神经网络架构，可以通过编码—解码机制学习数据的高效低维表示，同时保留原始数据的关键信息。训练时，网络通过反向传播调整参数，使重构输出尽可能接近输入。关键公式体现在重构损失上，通常采用均方误差 (MSE) 衡量差异：

$$L_{MSE} = \frac{1}{n} \sum_{i=1}^n \|x_i - \hat{x}_i\|^2 \quad 71471 \backslash * \text{MERGEFORMAT} (-)$$

其中， x_i 为原始输入， $\hat{x}_i$ 为重构输出， n 为样本数。该损失函数的作用在于约束编码后的低维表示尽可能保留原始数据中的主要信息。对于本文而言，自编码器并不直接用于分类分级，而是作为前置特征学习模块，对原始数据字段进行降维和紧凑表示。通过这一过程，可在后续敏感特征分析前减少噪声字段和无效特征的干扰，提高频繁模式挖掘的效率和稳定性。

在完成特征压缩后，需要将数据对象转换为适合频繁模式挖掘的事务型表示。为此，本文首先依据上一阶段形成的结构化规则库构建敏感数据查找表，用于标识各类字段是否属于敏感字段及其所属类别；然后结合待分级数据表，对每个待分级对象建立对应的敏感字段项目集。这里的待分级对象可以是输电线路、变电站、发电单元或其他业务实体，每个对象包含若干电力系统字段，如有功功率、无功功率、电压幅值、电压相角、节点边际电价、机组出力边界等。

具体而言，设待分级对象集合为 $O = \{o_1, o_2, \dots, o_n\}$ ，对每个对象 o_i ，根据敏感数据查找表判断其包含的字段中哪些属于敏感项，并将这些敏感字段名称组成对应的项目集 T_i 。由此可得到一个由多个项目集构成的敏感数据字典：

$$DIC = [T_1, T_2, \dots, T_n] \quad 72472 \backslash * \text{MERGEFORMAT} (-)$$

其中，每个 T_i 表示对象 o_i 对应的敏感字段集合。通过这一转换，原始数据表被映射为适合频繁模式挖掘的事务型表示，为后续发现高频敏感字段组合奠定基础。

频繁模式挖掘的目标是在敏感数据字典中识别高支持度的敏感字段组合。若某些字段在多个待分级对象中频繁共同出现，则说明这些字段之间可能存在较稳定的业务耦合关系或联合敏感性，其组合更有可能构成值得关注的安全风险特征。基于这一考虑，本文采用 FP-Growth 算法而非逐项枚举搜索，对敏感字段组合进行挖掘，以提高高维电力数据场景下的计算效率，并避免候选项集大量生成带来的计算开销。

首先，基于敏感数据字典建立的频繁模式树（FP-Tree）主要用于后续敏感数据频繁项集的挖掘。该 FP-Tree 的建立首先依赖于项头表的建立，具体做法如算法 4-1 所示。

算法 4-1：项头表构建算法

输入：项目集集合 DIC （敏感数据字典），支持度阈值 SUP_{min}

输出：项头表 TAB 和过滤后的项目集集合 DIC'

1：扫描项目集集合 DIC ，计算每个项目的出现次数

2：对于每个项目，计算支持度 $SUP(a) = \frac{\text{count}(a)}{|DIC|}$ ，其中 $\text{count}(a)$ 表示包含项目 a 的项目集数量

3：删除支持度低于 SUP_{min} 的项目

算法 4-1（续）：项头表构建算法

4：将剩余项目按支持度降序排列，形成项头表 TAB

5：扫描项目集集合 DIC ，对于每个项目集：

6：剔除该项目集中所有不在项头表 TAB 中的项目

7：将剩余项目按支持度降序排列（根据项头表 TAB 的顺序）

8：返回 TAB 和 DIC'

在此基础上，可进一步构建频繁模式树（FP-Tree）。FP-Tree 以根节点为空节点，通过逐个插入过滤后的项目集，实现对高频公共前缀的压缩存储。由于多个项目集往往共享相同的高频前缀，因此，FP-Tree 能够以较低的空间代价表达大规模事务数据中的共现模式，具体做法如算法 4-2 所示。

算法 4-2：FP-Tree 构建算法

输入：项头表 TAB （按支持度降序排列），过滤后的项目集集合 DIC' （每个项目集已按 TAB 排序）

输出：FP-Tree（以 root 为根）

1：初始化 FP-Tree：创建根节点 $root$ ，设置 $root.count = 0$

2：对于 DIC' 中的每个项目集（按索引次序）：

3：设置当前节点 $currentNode = root$

4：对于项目集中的每个项目 $item$ （按 TAB 的顺序）：

```

5:  如果 currentNode 存在子节点 child 且 child.item=item :
6:    则 child.count += 1
7:    设置 currentNode = child
8:  否则:
9:    创建新节点 newNode , 设置 newNode.item = item , newNode.count = 1
10:   将 newNode 添加为 currentNode 的子节点
11:   将 newNode 链接到项头表 L 中项目 item 的节点链表 (即将 newNode 插入链表
    头部)
12:   设置 currentNode = newNode
13:  返回 FP-Tree

```

在得到 FP-Tree 和项头表后, 即可利用 FP-Growth 算法对频繁项集进行挖掘, 如算法 4-3 所示。

算法 4-3: FP-Growth 频繁项集挖掘算法

输入: FP-Tree (已构建的频繁模式树), 项头表 TAB (按支持度降序排列), 支持度阈值 SUP_{min} , 当前前缀项集 prefix (初始为空集)

输出: 所有频繁项集集合 FS

```

1:  如果 FP-Tree 包含仅一条路径, 则:
2:    对于该路径上所有节点的非空组合  $C$  :
3:      生成项集  $\beta = C \cup \text{prefix}$ 
4:      将  $\beta$  加入 FS

```

算法 4-3 (续) : FP-Growth 频繁项集挖掘算法

```

5:  否则:
6:    对于项头表  $TAB$  从底部到顶部的每个项  $i$  (即支持度最低到最高) :
7:      生成新项集  $\beta = \{i\} \cup \text{prefix}$ 
8:      将  $\beta$  加入 FS
9:      构建  $i$  的条件模式基:
10:     初始化条件模式基 CPB 为空集合
11:     通过项头表  $TAB$  找到  $i$  的所有节点, 对于每个节点  $n_i$  :
12:       从  $n_i$  向上遍历路径至根节点, 记录路径  $P$  (排除  $n_i$  自身), 并设置路径  $P$  的计
        数为  $n_i$  的计数
13:       将路径  $P$  及其计数加入 CPB
14:       基于 CPB 构建  $i$  的条件 FP-Tree  $T_i$  :
15:       初始化  $T_i$  为仅包含根节点的树
16:       对于 CPB 中的每条路径  $P$  及其计数  $c$  :

```

-
- 17: 将路径 P 按项头表顺序排序 (支持度降序)
 - 18: 将路径 P 插入 T_i , 插入时每个节点的计数累加^c
 - 19: 删除 T_i 中计数低于 SUP_{min} 的节点, 并更新 T_i 的项头表 TAB_i
 - 20: 如果 T_i 非空, 则:
 - 21: 递归调用 $FP-Growth(T_i, TAB_i, SUP_{min}, \beta)$
 - 22: 返回 FS
-

在得到频繁项集后, 本文进一步将其种类、支持度和对象覆盖关系映射为对象级初步分级依据。一般而言, 若某对象包含的高频敏感组合更多, 或包含支持度更高的敏感模式, 则说明其潜在信息暴露面更广, 对应初始安全等级应相对更高; 反之, 若对象仅包含少量低频敏感组合, 则其初始分级结果可相对较低。换言之, 本文并非依据单个字段直接给出初始等级, 而是综合规则抽取结果、字段共现模式和对象级特征表示形成初步分级结论。通过这种方式, 初步分级标定实现了从单字段静态判断向多字段联合模式识别的转变, 为后续关联分析结果接入和动态等级更新提供了更具结构性和可解释性的初始条件。

基于强化学习的数据安全等级动态更新模型

在完成初步分级标定后, 仍需进一步解决电力数据安全等级随推断风险变化而动态调整的问题。传统分类分级方法通常依据静态规则或预设阈值进行一次性判定, 虽然能够满足一般场景下的合规要求, 但在电力系统这种高度耦合、持续演化的数据环境中, 静态分级结果难以及时反映风险变化。特别是在推断泄露威胁场景下, 低敏感数据与高敏感数据之间的关联关系会随着负荷波动、市场出清和运行方式变化而动态改变, 若仍采用固定等级策略, 容易出现两类问题: 一类是对真实高风险数据保护不足, 导致潜在推断路径未被有效阻断; 另一类是对中低风险数据过度保护, 造成数据流通效率下降和可用性损失。因此, 有必要构建能够根据推断风险和系统效益自适应调整安全等级的动态分级模型。

基于此, 本文将数据安全等级更新问题建模为一个序列决策问题, 引入强化学习方法, 在风险控制、数据可用性与监管合规之间寻求动态平衡。与基于经验规则的人工调整不同, 强化学习方法能够在与环境交互过程中持续优化决策策略, 使等级分配结果能够随数据特征和推断威胁变化而自动调整。考虑到传统深度强化学习方法, 如深度 Q 网络 (Deep Q-Network, DQN) 和近端策略优化 (Proximal Policy Optimization, PPO), 在高维复杂状态空间下仍面临训练稳定性、收敛性和价值估计精度等方面的问题, 其中 DQN 存在过估计偏差风险, 而 PPO 虽通过裁剪机制提升了

训练稳定性，但仍缺乏严格的全局收敛保证^[68]，本文在参考相关研究的基础上，采用增强型组相对策略优化（Group Relative Policy Optimization, GRPO）^[69]算法构建动态更新模型，以提高决策过程的稳定性和鲁棒性。

状态空间与风险表征

设电力系统数据空间为 $D = \{d_1, d_2, \dots, d_N\}$ ，其中， d_i 表示第 i 个数据特征，既可以是物理运行量，也可以是市场结算量或拓扑相关信息。对于任意数据特征 d_i ，其所面临的推断风险由第三节多变量关联分析结果给出。本文利用 MIC 刻画公开数据对敏感目标的最大推断强度，并据此构造特征级风险指数：

$$\Gamma_i = \max_{y \in D_{\text{pr}}} \text{MIC}(d_i, y) \quad 73473 \backslash * \text{MERGEFORMAT} (-)$$

其中， $\Gamma_i \in [0, 1]$ 表示特征 d_i 对敏感集合 D_{pr} 中任一目标变量的最大推断风险。该指标越大，说明该特征越可能构成高价值推断路径。与单纯依赖线性相关系数不同，这一定义能够更好地捕获电力系统中由潮流约束、拓扑耦合和市场机制引起的复杂非线性依赖关系，因此适合作为动态等级更新模型的状态输入。

在此基础上，本文将系统状态定义为由各数据特征的推断风险指数及必要物理上下文共同构成的向量，即：

$$s_i = \{\Gamma_1, \Gamma_2, \dots, \Gamma_N, P_{\text{phys}}\} \quad 74474 \backslash * \text{MERGEFORMAT} (-)$$

其中， P_{phys} 表示描述当前运行环境的物理状态信息，用于反映负荷波动、网络运行方式或市场环境变化对推断风险的影响。由此，动态等级更新问题被转化为一个基于风险状态输入的策略优化问题。

动作空间与等级决策

为与能源行业数据安全规范及电力业务场景中的等级管理要求保持一致，本文将每个数据特征的安全等级划分为四级，记为动作集合： $o_i \in \{1, 2, 3, 4\}$ ，其中， $o_i = 1$ 表示公开，适用于公开可共享的数据； $o_i = 2$ 表示一般，适用于仅限组织内部使用的数据； $o_i = 3$ 表示重要，适用于与系统运行安全密切相关、需实施严格访问控制的数据； $o_i = 4$ 表示核心，适用于涉及关键基础设施、核心运行状态或重大市场敏感信息的数据。对全体数据特征而言，可定义分级决策向量为：

$$A = \{o_1, o_2, \dots, o_N\} \quad 75475 \backslash * \text{MERGEFORMAT} (-)$$

强化学习智能体的任务是在给定系统状态 s_i 的条件下，为每个数据特征分配适当的等级，使整体效用最大化。

效用函数构建

动态等级更新的目标并非单纯追求最高安全等级，而是在满足安全需求和监管基线的前提下，兼顾数据可用性和业务效率。为此，本文构建由安全收益、可用性成本和合规惩罚三部分组成的综合效用函数：

$$U(A) = \sum_{i=1}^N [S_i(o_i, \Gamma_i) - V_i(o_i) - P_i(o_i, \hat{o}_i)] \quad 76476 \setminus *$$

MERGEFORMAT (-)

其中， $S_i(o_i, \Gamma_i)$ 表示对数据特征 d_i 采取等级 o_i 后获得的安全收益； $V_i(o_i)$ 表示因提高保护强度而引入的数据可用性损失； $P_i(o_i, \hat{o}_i)$ 表示违反合规基线时对应的惩罚项， $\hat{o}_i$ 表示监管或制度要求下的最低安全等级。

对于安全收益项，本文采用指数衰减形式描述剩余推断风险随防护等级提升而下降的过程：

$$S_i(o_i, \Gamma_i) = -\beta \Gamma_i e^{-\lambda o_i} \quad 77477 \setminus * \text{MERGEFORMAT (-)}$$

其中， β 表示风险权重系数， λ 表示防护效率衰减系数。该项说明当推断风险 Γ_i 较大时，提升安全等级可显著降低剩余推断风险；而对低风险特征而言，过高的防护等级并不会带来同等规模的边际收益。

为刻画高等级保护带来的可用性损耗，定义可用性成本项为：

$$V_i(o_i) = \eta (e^{\sigma o_i} - 1) \quad 78478 \setminus * \text{MERGEFORMAT (-)}$$

其中， η 表示成本权重， σ 表示开销增长系数。该项说明随着安全等级提高，数据访问控制、脱敏处理和共享限制等措施将显著增加系统开销和业务使用成本。

为保证等级决策不低于制度要求，还需设置合规惩罚项：

$$P_i(o_i, \hat{o}_i) = \begin{cases} \omega(\hat{o}_i - o_i)^2, & o_i < \hat{o}_i \\ 0, & o_i \geq \hat{o}_i \end{cases} \quad 79479 \setminus * \text{MERGEFORMAT (-)}$$

(-)

其中， ω 为惩罚强度参数。该项确保强化学习模型在追求全局效用最大化的同时，不会因为过分压缩可用性成本而突破最低监管基线。

基于增强型组相对策略优化算法的策略求解

考虑到电力数据空间具有高维、异构和非平稳等特点，本文不采用传统启发式规则或单纯的值函数方法，而采用增强型 GRPO 算法进行策略求解。其核心思想是在每一轮训练中，对每个数据特征同时采样一组候选等级动作，通过组内相对优势估计替代显式价值函数，从而减少高维状态下的价值估计偏差，提高策略更新稳定性。该设

计相较于 Actor-Critic 结构，可避免 Critic 网络累积误差，并在高维电力数据场景中表现出更好的收敛性。

具体而言，对状态 s_t 下的特征 d_t ，从当前策略 π_θ 中采样一组动作 $\{o_{i,1}, o_{i,2}, \dots, o_{i,G}\}$ ，计算各动作对应的即时效用 $w_{i,j}$ 。然后利用组内均值和标准差构造相对优势：

$$adv_{i,j} = \frac{w_{i,j} - \mu_G}{\sigma_G + e} \quad 80480 \setminus * \text{MERGEFORMAT} (-)$$

其中， μ_G 和 σ_G 分别表示当前组奖励的均值和标准差， e 为防止分母为零的平滑噪声项。该相对优势不依赖显式状态价值函数，而是通过组内比较得到更稳定的梯度信号，有助于在负荷波动和风险扰动条件下保持策略更新的平滑性。

在策略更新时，目标函数由策略梯度项、KL 散度约束项和熵正则项共同组成。其中，KL 散度项用于限制新策略与参考策略之间的偏移，防止等级分配出现剧烈振荡；熵正则项用于保持一定探索能力，避免模型过早陷入保守策略。总体上，GRPO 通过“组内相对优势估计+参考策略约束+周期同步”的方式，在非平稳风险环境下实现更稳健的等级更新。

从作用机理看，本文构建的动态更新模型实现了从风险感知到等级调整的闭环映射。前文关联分析模块提供特征级风险指数 Γ_i ，用于刻画数据暴露后可能引发的推断路径；本节强化学习模块则根据风险大小、业务代价和监管基线，自动学习最优等级调整策略。相较于静态分级方法，该模型具有三方面优势。

其一，模型能够根据推断风险变化自适应调整等级，而不再依赖固定阈值规则，从而提高分级结果对复杂场景的响应能力。其二，模型通过联合建模安全收益和可用性成本，避免单纯提高安全等级所带来的过度防护问题，更有利于在电力数据共享与隐私保护之间取得平衡。其三，GRPO 采用组相对优势机制和 KL 约束机制，有助于缓解传统强化学习方法在高维异构数据环境中的训练不稳定问题，从而提高等级更新结果的鲁棒性和可解释性。

总体而言，基于强化学习的数据安全等级动态更新模型为初步分级结果提供了持续优化机制，使分级决策能够随着数据关联结构和推断威胁的演化而动态调整，为后续分级防护策略设计和实验验证提供了决策核心。

电网数据场景下分级实验验证

为验证本文所提出分级防护方法的有效性，本节围绕“初步分级是否合理、动态更新是否有效、整体防护是否具备适应性”三个问题开展实验验证。实验内容与前述

方法设计保持对应关系：首先，通过结构化规则抽取实验检验大语言模型从非结构化文本中提取分级规则的准确性、完整性与格式稳定性；其次，通过初步分级标定算法实验验证敏感字段组合模式识别及初始等级映射的可行性；最后，通过数据安全等级动态更新模型实验考察所提强化学习方法在训练收敛性、效用平衡能力以及动态威胁响应方面的表现。通过上述多层次实验，可从规则生成、等级形成到动态调整三个环节对本文分级管理方法进行系统验证。

实验设计

为验证本文所提出的分级治理方法的有效性，实验从结构化规则抽取、敏感特征模式识别和安全等级动态更新三个层面展开。结构化规则抽取关注大语言模型能否从非结构化文本中稳定抽取出分类分级所需的关键字段和约束信息；敏感特征模式识别关注在完成规则抽取后，能否通过特征压缩与频繁模式挖掘识别高频敏感字段组合，并据此形成合理的初始安全等级。安全等级动态更新则关注能否在初始安全等级基础上，依据合理的效用收益对安全等级进行动态更新，确保分级结果满足安全需求。

在结构化规则抽取实验中，选取输变电工程环境影响报告、工程建设说明和项目模板文本作为实验语料，共整理 20 段具有代表性的文本片段，并人工标注项目名称、工程地点、电压等级、建设性质和线路长度 5 个字段，构成小规模验证数据集。为了降低实验复现门槛，知识库由 5 份模板文档和 10 条人工整理的高质量结构化示例组成。实验比较三种抽取方式：一是仅使用大语言模型进行直接抽取；二是加入字段约束和 JSON 输出约束的提示词抽取；三是在提示约束基础上进一步引入检索增强生成机制的知识增强抽取。评价指标采用字段级准确率、JSON 输出有效率和字段完整率。

```
"输变电工程环评报告模板": {
  "基本信息": {
    "项目名称": "格式: '起点省份~终点省份±电压等级类型 (如±800kV) 输电工程', 示例: '甘肃~浙江±800千伏特高压直流输电工程'",
    "工程地点": {
      "起点": "格式: 'XX省XX市XX县+具体设施名称', 示例: '甘肃省武威市民勤县的武威换流站'",
      "终点": "示例: '浙江省绍兴市上虞区的越州换流站'",
      "地理校验": "需包含经纬度坐标 (如东经103°42', 北纬37°58') "
    },
    "时间参数": {
      "投运时间": "格式: YYYY-MM, 示例: '2027-07' (需符合特高压工程3-5年建设周期)"
    }
  },
  "工程参数": {
    "电压等级": "标准表述: '±800kV' (禁止使用'正负800kV'等非规范写法)",
    "线路长度": {
      "总长": "格式: '数字+km', 示例: '2370.1km' (需与地理坐标距离匹配)",
      "特殊段": "需标注大跨越段 (如'白银黄河大跨越2.8km') "
    }
  },
  ...
}
```

图 4-19 结构化文本的标准模板示例

在初步分级标定实验中，首先构造字段级敏感数据查找表，并以线路对象为例建立敏感字段项目集，如表 4-8 所示。在自编码器验证阶段，为保证实验能够快速复

现，在 6 类敏感字段组合的基础上引入少量随机扰动，扩增形成 60 个对象样本，并将字段存在性表示为 0-1 特征向量。采用三层对称自编码器进行压缩表示学习，编码器和解码器结构设置为 6-4-2-4-6，损失函数采用均方误差，优化器为 Adam，学习率设为 0.001，训练轮数为 100。完成特征压缩后，再以 6 个线路对象组成的项目集作为频繁模式挖掘示例，采用 FP-Growth 算法识别高支持度的敏感字段组合，支持度阈值统一设为 50%。最后，根据对象所覆盖的频繁项集及其支持度信息，计算初始分级得分，并映射为对应的初始安全等级。

表 4-8 线路对象的敏感字段项目集

对象	原始敏感字段项目集
线路 1	[端点 1，端点 2，电压等级，线路潮流，线路电阻]
线路 2	[端点 1，电压等级，线路电抗]
线路 3	[端点 2，线路电阻]
线路 4	[端点 1，电压等级，线路电抗，线路潮流]
线路 5	[端点 1，电压等级，线路电抗，线路潮流]
线路 6	[线路电抗]

在安全等级动态更新实验中，采用 2.4 节所述的 PJM 电力市场数据集构建动态决策环境，并以前文关联分析得到的推断风险指数作为状态输入。考虑到动态分级的目标不仅是提高安全性，还需要兼顾数据可用性与制度约束，实验将等级调整过程建模为序列决策问题：智能体根据当前数据特征的风险状态、运行上下文及合规基线选择相应的安全等级动作，并依据综合效用函数获得反馈奖励。为验证所提方法的有效性，实验将增强型 GRPO 与静态分级策略、DQN 和 PPO 两类代表性强化学习方法进行对比，重点考察不同算法在训练收敛速度、策略稳定性、安全收益与可用性成本平衡能力以及动态攻击环境下防护响应效果等方面的差异。

基于大语言模型的结构化分级规则抽取实验

为验证大语言模型的结构化分级规则抽取能力，在结构化规则抽取实验中首先对原始文本进行切分与清洗，保留与项目属性描述直接相关的段落；随后，以人工标注结果作为标准答案，分别采用“直接抽取”“提示约束抽取”和“检索增强抽取”三种方式进行字段提取。对于检索增强方法，系统首先从领域知识库中检索与输入文本最相关的 3 个规则片段或示例文档，再将检索结果与原始文本共同输入大语言模型，要求模型按照统一 JSON 模板输出结构化结果。最后，从字段匹配准确性、输出格式有效性和信息完整性三个方面对实验结果进行统计分析。抽取结果如表 4 -9 所示。

表 4-9 不同规则抽取策略的结果比较

抽取策略	字段级准确率	JSON 有效率	字段完整率
------	--------	----------	-------

直接抽取	79.0%	80.0%	84.0%
提示约束抽取	88.0%	95.0%	91.0%
检索增强抽取	94.0%	100.0%	97.0%

实验结果表明，直接采用大语言模型进行开放式抽取时，虽然能够识别多数显式字段，但在字段边界不清、单位表达不统一和多句跨段描述的场景下，容易出现遗漏或格式不规范的问题。引入提示词约束后，模型对任务目标和输出格式的理解更为明确，字段级准确率由 79.0% 提升至 88.0%，JSON 有效率也明显提高。进一步引入检索增强机制后，字段级准确率达到 94.0%，JSON 输出有效率达到 100%，字段完整率提高至 97.0%。这说明外部知识的引入能够有效弥补模型在专业术语理解和规则一致性方面的不足，使结构化抽取结果更加稳定。

表 4-10 检索增强方法在不同字段上的抽取准确率

抽取字段	准确率
项目名称	100%
工程地点	95%
电压等级	100%
建设性质	90%
线路长度	85%
平均值	94%

从字段层面看，项目名称和电压等级的抽取准确率最高，主要原因在于其表达形式较为固定；相比之下，线路长度和建设性质字段更容易受自然语言表述差异影响，例如“新建双回架空线路折单长度”与“线路总长”在语义上接近，但在字面上并不完全一致。检索增强方法通过引入模板规则和示例文档，显著减少了此类表达差异带来的抽取误差，表明该方法具有较好的工程适配性。

基于自编码器和频繁模式挖掘的数据特征提取实验

为验证自编码器在敏感特征压缩中的有效性，本文在首先 6 类字段组合基础上，通过随机删除和保留部分字段的方式扩增得到 60 个对象样本，并将每个对象表示为 6 维 0-1 特征向量，采用 6-4-2-4-6 的对称网络结构对自编码器进行训练，损失函数为 MSE。训练结果如图 4-20 所示。




图 4-20 自编码器训练结果

实验结果表明，模型在前 40 个训练轮次内损失下降较快，约在第 60 轮后趋于稳定，最终训练集重构误差为 0.013，验证集重构误差为 0.017。该结果说明，自编码器能够在较低维空间中保留原始敏感字段组合的主要结构信息，从而为后续频繁模式挖掘提供更加紧凑、稳定的特征表示。

下面在支持度阈值设为 50%的条件下，对线路对象的 6 个敏感字段项目集进行统计，由此得到项头表，并将各项目按支持度降序排列。结果如表 4 -11 所示。

表 4-11 项目支持度统计及项头表结果

项目	出现次数	支持度	是否保留
端点 1	4	66.7%	是
电压等级	4	66.7%	是
线路电抗	4	66.7%	是
线路潮流	3	50.0%	是
端点 2	2	33.3%	否
线路电阻	2	33.3%	否

在统计结果中，端点 1、电压等级、线路电抗和线路潮流的支持度分别为 66.7%、66.7%、66.7%和 50.0%，均达到阈值要求；端点 2 和线路电阻的支持度仅为 33.3%，因此被过滤删除。经项头表过滤与重排后，各对象对应的项目集如表 4 -12 所示。

表 4-12 线路对象的敏感字段项目集

对象	原始敏感字段项目集
线路 1	[端点 1，电压等级，线路潮流]
线路 2	[端点 1，电压等级，线路电抗]
线路 3	[]
线路 4	[端点 1，电压等级，线路电抗，线路潮流]

线路 5	[端点 1, 电压等级, 线路电抗, 线路潮流]
线路 6	[线路电抗]

在构建 FP-Tree 时, 首先创建空根节点。随后按项目集顺序逐条插入过滤后的事务。对于线路 1, 依次插入“端点 1—电压等级—线路潮流”路径, 并新建对应节点; 对于线路 2, 由于“端点 1—电压等级”路径已存在, 因此仅增加这两个节点的计数, 并在其后新建“线路电抗”节点; 线路 3 为空集, 不参与树构建; 线路 4 和线路 5 插入时, 共享前缀“端点 1—电压等级—线路电抗”, 并在该路径下增加“线路潮流”分支计数; 线路 6 仅包含“线路电抗”, 由于根节点下不存在直接指向“线路电抗”的子节点, 因此在根节点下新建“线路电抗”节点并将其计数置为 1。FP-Tree 构建过程如图 4-21 所示。




图 4-21 FP-Tree 的建立过程示意

至此, 树结构构建完成, 而项头表中“线路电抗”的总计数由路径节点和根节点直连节点共同组成, 总出现次数仍为 4。在上述 FP-Tree 基础上进行频繁项集挖掘, 共得到 11 个满足最小支持度要求的频繁项集。挖掘得到的频繁项集结果如表 4-13 所示。

表 4-13 挖掘得到的主要频繁项集

频繁项集	支持度
[端点 1]	66.7%
[电压等级]	66.7%
[线路电抗]	66.7%
[线路潮流]	50.0%
[端点 1, 电压等级]	66.7%
[端点 1, 线路电抗]	50.0%
[电压等级, 线路电抗]	50.0%
[端点 1, 线路潮流]	50.0%

[电压等级, 线路潮流]	50.0%
[端点 1, 电压等级, 线路电抗]	50.0%
[端点 1, 电压等级, 线路潮流]	50.0%

挖掘结果中，单项频繁项集包括[端点 1]、[电压等级]、[线路电抗]和[线路潮流]；二项频繁项集包括[端点 1, 电压等级]、[端点 1, 线路电抗]、[电压等级, 线路电抗]、[端点 1, 线路潮流]和[电压等级, 线路潮流]；三项频繁项集包括[端点 1, 电压等级, 线路电抗]和[端点 1, 电压等级, 线路潮流]。这些结果表明，端点信息、电压等级与线路参数之间具有较稳定的共现关系，能够共同构成线路对象的敏感结构模式。

为了将频繁项集结果转化为对象级初始分级依据，定义对象 o_i 的初始分级得分为其所覆盖频繁项集支持度之和，即：

$$R_i = \sum_{X \in FS, X \subseteq T_i} SUP(X)$$

81481* MERGEFORMAT (-)

其中， FS 表示频繁项集集合， T_i 表示对象 o_i 的项目集， $SUP(X)$ 表示频繁项集 X 的支持度。为便于比较，对各对象得分进行归一化处理，并按照区间[0,0.1)、[0.1,0.5)、[0.5,0.85)和[0.85,1]分别映射为一级、二级、三级和四级初始安全等级。初始分级结果如表 4-14 所示。

表 4-14 对象初始分级结果

对象	原始得分 R_i	归一化得分	初始等级
线路 1	4.000	0.649	三级
线路 2	4.167	0.676	三级
线路 3	0.000	0.000	一级
线路 4	6.167	1.000	四级
线路 5	6.167	1.000	四级
线路 6	0.667	0.108	二级

根据该规则，线路 1 至线路 6 的归一化得分分别为 0.649、0.676、0、1.000、1.000 和 0.108，对应的初始分级结果分别为三级、三级、一级、四级、四级和二级。可以看出，包含更多高频敏感字段组合的线路 4 和线路 5 获得最高初始等级，而仅包含单一敏感字段的线路 6 等级较低。该结果表明，基于频繁模式的初步分级标定能够有效区分不同对象在字段组合层面的敏感差异，为后续关联分析与动态等级更新提供合理的初始状态。

数据安全等级动态更新模型实验

为验证本文所提动态等级更新模型的有效性，实验采用 2.4 节所述的 PJM 电力市

场数据集进行测试。测试数据涵盖 39 类电力市场与运行特征，包括辅助服务市场数据、发电与损耗数据、调频结算数据、潮流汇总数据、负荷数据以及节点边际电价数据等，并在预处理中去除了时间标识字段。该数据集同时包含运行侧、市场侧与价格侧的多源异构信息，能够较好反映电力数据在开放共享环境下的动态变化特征与复杂关联关系，因此适合作为动态分类分级模型的验证对象。训练收敛曲线对比图如图 4-22 所示，




图 4-22 不同算法训练收敛曲线对比图

首先，从训练收敛特性来看，增强型 GRPO 在总效用曲线上表现出更快的收敛速度和更稳定的训练过程，如图所示。实验结果表明，GRPO 最终稳定在约 -300 的效用平台，明显优于 PPO 和 DQN，两者对应的最终效用水平分别低约 25% 和 50%。同时，在最后 50 个训练周期内，GRPO 的效用波动方差较 PPO 降低了 54.2%。这一结果说明，在高维异构状态空间下，组相对优势估计能够有效削弱样本收益中的整体噪声干扰，而参考策略约束则有助于抑制训练后期的策略震荡，从而使等级更新过程在逼近较优解的同时保持较高稳定性。

在验证了训练过程的收敛性之后，进一步考察不同方法在安全性与可用性之间的权衡能力。安全收益与可用性损耗权衡关系如图 4-23 所示。




图 4-23 安全收益与可用性损耗权衡关系图

由安全收益与可用性损耗权衡关系图可以看出，GRPO 的决策点更多集中于“高安全收益、低可用性成本”的优势区域，其中超过 60% 的样本位于帕累托前沿附近；相比之下，PPO 与 DQN 的决策分布更为分散，且更容易落入“高成本—低收益”或“低成本—低收益”的非优区域。这表明，GRPO 在识别高风险数据特征后，能够针对不同风险水平实施更加细粒度的等级调整，避免将中低风险数据统一提升至高保护等级，因而在满足安全约束的同时，更有利于维持数据共享与流通能力。

在此基础上，进一步比较不同动态更新策略下的最终综合效用。综合效用如图 4-24 所示。实验结果表明，静态基线方法的综合效用得分为 206.6，DQN 为 101.9，PPO 为 178.7，而增强型 GRPO 达到 210.5，为四种方法中的最优结果。该结果说明，静态分级策略虽然能够满足基本治理需求，但由于缺乏对推断风险动态变化的响应能力，其整体效用提升空间有限；传统强化学习方法虽然具备一定的自适应能力，但仍容易受到策略震荡和保守更新偏置的影响，使部分中等风险数据被过度提升等级，进而带来额外的可用性损失。相比之下，GRPO 能够更精细地建立“风险强度—防护等级”之间的非线性映射关系，从而在合规约束与效用优化之间取得更优平衡。




图 4-24 不同动态更新策略下的综合效用对比

除静态风险环境外，为进一步检验模型在复杂威胁条件下的适应能力，实验进一步构造了攻击者在测试中途切换推断策略的动态 FDIA 攻击场景，即通过模拟攻击强度与推断路径随时间演化的方式，考察防御策略对风险突变的响应能力。实验结果如图 4-25 所示。




图 4-25 攻击策略动态演化下的鲁棒性响应曲线

当潜在推断风险发生显著偏移时，GRPO 能够及时调整防护策略，其优化得到的动态防御边界成功覆盖了 90% 的攻击者演化轨迹。同时，在 KL 散度约束机制的作用下，GRPO 的策略调整使 97% 的关键物理特征始终保持在最优保护状态。上述结果表明，本文提出的动态等级更新模型不仅适用于相对稳定的静态风险环境，而且能够在推断路径持续变化、攻击策略不断演化的复杂场景下保持较强的防护连续性和策略鲁棒性。综合来看，增强型 GRPO 在收敛速度、策略稳定性、安全—可用性权衡以及动态威胁适应能力等方面均表现出较为明显的优势，说明其能够较好适应电力数据分级场景中高维、异构、时变的决策特点，从而为安全等级的动态更新提供有效支撑。

本节围绕结构化规则抽取、初步分级标定和安全等级动态更新三个层面，对本文提出的分级防护方法进行了验证。实验结果表明，基于大语言模型并结合提示约束与检索增强的规则抽取方法，能够较为准确、稳定地从非结构化文本中提取分类分级所需的关键字段和约束信息；基于自编码器与 FP-Growth 的初步分级标定方法，能够有效识别对象间高频敏感字段组合，并形成具有区分度的初始安全等级；基于增强型 GRPO 的动态更新模型，则在训练收敛性、安全收益与可用性平衡能力以及动态威胁响应方面均优于静态策略及其他对比方法。总体来看，本节实验从规则生成、等级形成到动态调整三个环节验证了所提方法的有效性，说明该方法能够较好适应电力数据场景下分类分级与动态防护的实际需求。

本章小结

本章面向电力数据分类分级中的静态性、规则依赖性和风险响应滞后等问题，构建了由初步分级标定与动态等级更新组成的分级防护方法框架。首先，利用大语言模型和检索增强机制实现非结构化规则文本向结构化分级知识的转换，并结合自编码器与频繁模式挖掘形成对象级初始分级结果；其次，将数据安全等级调整建模为序列决策问题，引入增强型 GRPO 算法，在推断风险、数据可用性和合规约束之间实现动态权衡；最后，通过电网数据场景实验验证了所提方法在初始分级合理性、动态更新有效性和复杂威胁适应性方面的表现。本章实现了数据分级从静态规则驱动向风险感知与动态优化驱动的转变，为后续分级防护策略落地和系统实现提供了方法基础。

基于数据关联的自适应分类分级系统

系统简述

基于本研究内容，研发了一套基于数据关联的自适应分类分级系统（下称“系统”）。该系统能够对海量、多源数据进行关联分析，并自适应、动态化完成数据的自适应分类与分级处理。系统以关联分析算法和分级标定算法为核心，实现三个核心功能模块：数据标定模块、关联分析模块、动态分级模块。该系统已部署于云南电网、榆林零碳智慧园区等电力系统及其相关能源企业的数据中心，并通过国网陕西电力科学研究院的第三方测试，为数据的安全治理与管控提供关键技术支撑，有效提升数据安全管理水平。

在技术架构方面，系统采用前后端分离的现代化设计理念。前端基于 Vue.js 框架构建响应式用户界面，后端依托 Django 框架提供稳定的 API 服务，并以 MySQL 实现数据的持久化存储，最后依托 Docker 平台实现容器化部署，系统整体部署架构图如图所示。具体而言，系统采用 Vue.js 框架对数据分类分级操作及流程进行可视化设计，用户可通过浏览器访问前端界面，通过交互操作向后端发起数据处理与分类分级请求。后端基于 Python3 及开源 Web 框架 Django 实现算法功能，从而完成对数据的自适应分类分级。然后将数据存入 MySQL 数据库并提供输出。最后系统采用 Docker 容器将数据库、前端、后端分别封装，部署时直接进行云平台部署而无需重新安装配置环境。该架构在保障系统高可用性与可扩展性的同时，也优化了用户使用体验。系统整体设计和功能架构如图 5-26 所示。




图 5-26 系统整体设计和功能架构图

系统功能模块

系统采用模块化设计，将复杂的分类分级流程拆解为三个核心功能模块：数据标定模块、关联分析模块、动态分级模块，各模块之间通过定义清晰的接口实现数据交互与功能协同，形成一个高效、闭环的数据处理流程。

数据标定模块

数据标定模块是系统完成初始分类分级的基础功能模块，也是系统与外部数据交互的主要入口。其核心任务是对待分析的电碳数据进行接入、解析、存储、预处理和结果展示，并结合规则库输出初步标定结果。本节侧重将第四章中面向方法的“规则抽取—敏感特征提取—初步分级标定”进行系统实现，即将上述方法封装为可调用、可视化、可交互的软件功能，使用户能够在统一界面下完成从数据上传到初步分级结果获取的全过程。数据标定模块同时承担数据入口、存储管理和结果可视化三重职责，是整个分类分级系统运行的起点。

从功能结构上看，数据标定模块主要包括数据接入子模块、数据管理子模块、规则匹配子模块和结果展示子模块。数据接入子模块负责接收用户上传的数据文件，并完成格式检查和基础解析；数据管理子模块负责将解析后的数据写入数据库，并维护数据名称、描述、时间范围和字段结构等元信息；规则匹配子模块调用前文构建的分类分级规则库，对上传数据进行类别识别和初始安全等级匹配；结果展示子模块则将数据标定结果以表格、卡片或状态标签等方式反馈给用户。各子模块之间通过后端接口联动，使数据标定过程具备较好的自动化和可追溯性。

在数据接入方面，模块支持 CSV、Excel 等多种格式的数据文件上传，并提供拖拽上传和本地文件选择两种交互方式，以适应不同用户的使用习惯。后端在接收到文件后，首先执行格式校验、字段检查和数据完整性验证，对不符合要求的文件给出提示；对通过校验的数据，进一步完成文件解析和入库。该流程保证了进入后续分类分级环节的数据具有统一的结构和基本质量，为规则匹配和关联分析提供了可靠输入。通过本地文件实现数据接入展示如图 5-27 所示。




图 5-27 文件上传展示图

在数据管理方面，数据标定模块不仅保存原始数据本体，还对数据对象的关键属性进行统一管理，包括数据名称、数据规模、字段结构、时间标签以及后续生成的分类类别和安全等级等信息。数据库设计采用规范化思路，通过主键与外键维持不同表之间的关联关系，并针对时间范围查询和分类检索场景建立复合索引，以提高系统在多源时序数据场景下的访问效率。这样，数据标定模块既是初步分级的处理入口，也是后续关联分析和动态分级的数据基础。

在规则匹配方面，数据标定模块与规则库管理模块协同工作。用户可预先导入分类分级规则文件，系统据此构建字段匹配规则库；当数据文件上传完成后，模块根据字段名称、元数据描述及规则约束，对数据对象执行自动匹配，生成对应的数据类别、预设安全等级和规则来源信息。规则就绪后，用户在数据展示界面点击“智能分类分级”按钮，即可完成数据的初步标定，界面会同步显示数据匹配的类别、预设安全等级以及所应用的规则名称。该设计使规则匹配结果不仅可用于后端计算，也能在前端直接呈现，增强了分级过程的可解释性。系统设计的规则界面展示如图 5 -28 所示。




图 5-28 规则界面展示图

在结果展示方面，数据标定模块采用可视化方式呈现标定后的数据状态。对于尚

未完成分类分级的数据，界面主要显示其名称、描述和基本结构信息；对于已经完成初步标定的数据，则进一步显示其类别标签、预设安全等级及规则来源，并通过颜色编码、状态图标和排序筛选功能帮助用户快速识别高等级数据对象。系统还支持按数据类型、时间范围和安全等级等条件进行查询和筛选，从而满足不同场景下的数据浏览与管理需求。相关功能通过表格、卡片等方式直观展示各数据对象的详细信息，并实时呈现分类类别和分级级别的更新状态。

从交互流程看，数据标定模块的运行过程可以概括为“文件上传—数据校验—数据库写入—规则匹配—结果展示”五个步骤。首先，用户在文件上传界面选择待分析的数据文件；其次，系统完成格式和完整性校验；再次，将通过校验的数据写入数据库并生成基础元信息；随后，用户触发智能分类分级功能，由系统自动执行规则匹配并生成初步标定结果；最后，前端界面动态更新，展示数据类别、预设安全等级和规则名称。该流程实现了数据从原始接入到初步标定结果生成的自动化闭环，也为后续关联分析模块和动态分级模块提供了统一输入。

关联分析模块

关联分析模块是系统完成风险挖掘与等级调整的核心功能模块，其主要任务是在初步标定结果基础上，对不同数据对象之间的统计关联、业务耦合和潜在推断关系进行量化分析，并据此识别可能导致敏感信息泄露的高风险数据对或高风险路径。该模块在系统整体流程中承担着由静态规则匹配向动态风险识别过渡的关键作用。

从功能结构上看，关联分析模块主要包括算法选择子模块、关联计算子模块、结果展示子模块和等级建议子模块。算法选择子模块用于根据数据类型和分析目的选择适当的关联分析方法；关联计算子模块负责对用户指定的数据对执行量化分析，并输出关联强度指标；结果展示子模块将计算结果以图表、数值和状态标签等方式反馈给用户；等级建议子模块则在关联分析结果基础上生成安全等级调整建议，并与动态分级模块形成联动。

在算法支持方面，关联分析模块以统计相关性分析为主，同时兼顾复杂非线性关系识别能力。以第三章研究为基础，系统支持 Pearson 相关系数、Spearman 相关系数和 MIC 等多种关联分析方法。通过多指标联合分析，系统能够较为全面地识别数据间潜在的耦合特征，避免因单一算法的局限而漏检高风险关联关系。

在关联计算流程上，模块首先接收来自数据标定模块的输入数据，包括数据对象的名称、字段结构、初始安全等级以及相应的时间序列或属性特征；随后，系统根据用户选择或默认配置，对指定数据对象执行两两关联分析，计算对应的关联强度指标。对于连续型电力数据，必要时可先采用预处理方法将其转化为适合相关性分析的形式。

例如，对节点负荷、节点电价、线路潮流和节点相角等连续值进行离散化处理，再计算信息相关指标，以便更准确地衡量可推断性。该设计保证了系统能够在实际电力数据场景下对不同类型的数据执行统一而稳定的关联计算。

在结果表达方面，关联分析模块输出的不仅是单一数值，而是包含关联强度、算法类型和风险含义的综合结果集合。对于单个数据对，系统展示其 Pearson 相关系数、Spearman 相关系数、MIC 等指标值，并通过可视化方式突出高关联项；对于多数据对象场景，则进一步构建关联矩阵或关联图，用于直观展示不同数据类别之间的耦合关系。系统设计的关联分析界面展示如图 5-29 所示。




图 5-29 关联分析界面展示图

在系统交互层面，关联分析模块提供了较为友好的算法选择与结果展示界面。用户可在关联分析页面查看各类算法的功能说明，并根据实际需求选择合适的方法执行分析；系统完成计算后，会通过图表和数值方式展示量化结果，同时同步显示数据类别和安全等级的更新状态。该模块能够实时展示关联强度指标，并基于分析结果生成数据分类类别与安全级别的调整建议，从而提高分级决策的透明性和可追溯性。


从系统功能链条上看，关联分析模块在数据标定模块和动态分级模块之间起到桥梁作用。一方面，它以前一模块输出的初始类别和安全等级为输入，分析原有静态分级是否存在被推断突破的风险；另一方面，它将分析结果进一步传递给动态分级模块，为后者提供等级调整所需的风险依据。换言之，关联分析模块实现了从“规则驱动的初步标定”向“风险驱动的动态更新”的过渡，使系统不再停留在基于文本和字段的静态识别，而能够进一步识别数据间复杂的推断耦合关系。

动态分级模块

动态分级模块是系统完成自适应分类分级闭环的核心决策单元，其主要任务是在初步标定和关联分析结果基础上，对数据对象的安全等级进行动态修正和更新。该模块在系统整体流程中承担着由风险发现走向等级修正的关键作用，是实现数据安全等

级由静态判定向动态自适应转变的主要载体。

从功能结构上看，动态分级模块主要包括风险输入子模块、等级更新子模块、结果反馈子模块和历史记录子模块。风险输入子模块负责接收来自关联分析模块的量化结果，包括数据间关联强度、潜在推断路径以及模型验证得到的风险指标；等级更新子模块基于预设规则或学习模型，综合判断原有安全等级是否需要调整；结果反馈子模块将更新后的等级结果返回前端界面，并同步更新数据库中的分级结果表；历史记录子模块则保留等级变化过程、触发依据和更新时间等信息，以保证分级结果的可追溯性和可审计性。通过上述子模块的协同，系统能够将分析结果转化为具体的等级更新决策。系统中通过初步标定后的数据展示如图 5-30 所示。



数据名称	数据描述	数据类别	预设安全等级	匹配规则名称	自适应安全等级	数据更新信息
地区电力调节市场出清结算价格 (RMCCP)	调节市场容量受限的结算单价 (单位: 元/MW...)	交易数据	L2 二级安全	ccp	L0 未匹配	未更新
地区电力市场出清价格 (MCP)	电力现货市场中实时平衡市场的分时段出清价...	交易数据	L2 二级安全	mcp	L0 未匹配	未更新
地区电力市场出清价格 (MCP)	实时交易中最终确定的出清价格 (与计...)	交易数据	L2 二级安全	mcp	L0 未匹配	未更新
地区电力市场节点出清电价 (LMP)	各节点的出清电价 (含能量、阻塞、损耗分...)	交易数据	L2 二级安全	lmp	L0 未匹配	未更新
地区电力系统阻塞分量的价格	因输电容量限制导致的额外电力的价格 (单位: 元/...)	交易数据	L2 二级安全	阻塞	L0 未匹配	未更新
地区电力系统太阳能发电总量	统计周期内, 光伏发电设备的总发电量 (单...	发电数据	L2 二级安全	发电	L0 未匹配	未更新
地区电力系统总发电量	统计周期内, 地区所有电源 (火电、水电、...	发电数据	L2 二级安全	发电	L0 未匹配	未更新
地区电力系统风力发电总量	统计周期内, 风力发电设备的总发电量 (单...	发电数据	L2 二级安全	发电	L0 未匹配	未更新
地区电力系统每小时负荷预测值	未来1小时的每小时负荷预测值 (单位: MW)	系统数据	L2 二级安全	负荷	L0 未匹配	未更新
地区电力系统新能源发电功率	当前时刻风电、光伏等新能源发电设备的总...	系统数据	L2 二级安全	功率	L0 未匹配	未更新
地区电力系统总负荷功率	统计周期内地区电力系统的实时总负荷功率 (...)	系统数据	L2 二级安全	负荷	L0 未匹配	未更新

图 5-30 初步标定后数据界面展示图

在输入机制方面，动态分级模块并不直接处理原始业务数据，而是以前两级模块的输出为基础进行决策。具体而言，模块输入主要包括三类信息：一是数据标定模块给出的初始类别和初始安全等级；二是关联分析模块输出的相关性指标、风险矩阵和高风险数据对识别结果；三是神经网络或推断模型对相关关系可利用性的验证结果。等级动态更新基于关联关系图和泄露风险评估结果，通过模拟攻击者的推断逻辑，计算数据在实际业务场景中被关联还原的敏感程度和可能性，并据此实现安全等级的精准调整。也就是说，动态分级模块的本质是将前端识别到的潜在风险转化为系统可执行的等级修正。

在更新机制上，动态分级模块遵循风险驱动和结果可解释的原则。对于未表现出显著关联风险或推断可利用性较低的数据对象，系统保持其初始安全等级不变；对于那些初始等级较低，但经关联分析和推断验证后显示能够恢复高敏感信息的数据对象，系统则自动提高其安全等级。由此，动态分级不再局限于静态规则匹配，而是建立在风险量化和模型验证基础之上，更能反映数据在实际共享场景中的真实敏感程度。系统中通过更新标定后的新数据展示如图 5-31 所示。

图 5-31 更新标定后数据界面展示图

从实现方式上看，动态分级模块可以支持两种更新模式。第一种为规则驱动模式，即根据预设阈值直接触发等级修正。例如，当某一数据对象与高敏感数据之间的关联强度或推断精度高于设定阈值时，系统自动将其安全等级提升至对应级别。第二种为模型驱动模式，即调用前文构建的动态更新模型，对数据对象的等级调整进行综合决策。

在系统交互层面，动态分级模块通过前端界面向用户提供安全等级更新功能。用户完成关联分析后，可在数据展示页面点击“安全等级更新”按钮，由系统调用动态分级逻辑，对当前数据集执行等级修正。更新完成后，前端界面会显示数据的自适应安全等级、更新依据和变更详情，直观反映哪些数据因推断风险上升而被提升等级，哪些数据保持原有等级不变。

在结果管理方面，动态分级模块不仅输出当前时刻的更新等级，还对每次更新操作进行记录，包括更新前等级、更新后等级、触发原因、关联指标和执行时间等信息。这样做的目的是保证系统具备历史追踪能力，便于后续审计、模型优化和人工复核。对于电碳数据这类具有明显时序性和业务动态性的对象而言，同一数据在不同时期的风险状态可能发生变化，因此保留等级更新历史有助于分析数据风险演化趋势，也为后续安全策略调整和管理决策提供支撑。

从系统整体流程看，动态分级模块实现了分类分级工具由“规则初始标定”向“风险反馈优化”的闭环演进。数据首先在数据标定模块中完成初步类别识别和等级赋值，随后在关联分析模块中识别潜在推断关系和高风险路径，最后由动态分级模块基于这些风险结果修正安全等级。通过这一链条，系统不再停留在基于数据名称、字段和静态规则的一次性判断，而能够结合数据间关联关系和泄露风险变化，对安全等级进行持续更新。

系统应用

目前该数据分类分级系统已经在云南电网、榆林零碳智慧园区等多家电力系统及其相关企业平台进行部署，其分类分级结果作为参考为数据的安全入网应用提供重要支撑。

云南电网应用部署

该系统作为电碳区块链数据安全平台的一个扩展模块，已在云南电网计量中心完成部署并进入实测运行阶段，为云南电网的电碳交易过程数据提供分类分级依据。该系统紧密围绕《能源行业数据安全管理办法（试行）》所确立的数据分类分级（第四条）、目录编制（第九条）与风险评估（第十四条）等核心要求，为能源企业的合规实践提供了关键技术支撑。部署在云南电网计量中心的系统展示如图 5 -32 所示。



图 5-32 部署于云南电网计量中心的系统分级结果

在云南园区的实际运行中，该系统高效处理了约 32 万条电碳交易过程数据，通过深度关联分析，精准识别出包括“节点电价—线路潮流”在内的 13 组具有高推断风险的数据关联对。超过 95%的数据分类准确率与 3 分钟内完成的全量数据分级效率，显著提升了数据安全管理的自动化与精准化水平，为编制符合规范的重要数据目录提供了可靠依据。通过实现数据资源的精准分类与风险动态识别，系统不仅强化了云南地区电碳数据的安全治理能力与风险防控体系，也为跨主体数据共享与合规流转构建了可靠的技术基础，进一步推动了电碳融合市场在安全可信环境下的有序发展。

榆林零碳智慧园区应用部署

该系统作为电能、风能等能源数据的安全入网管控模块，已成功应用于榆林零碳智慧园区管理平台，旨在增强能源数据安全监管的自动化与精细化程度，为能源数据共享与合规使用提供可靠的技术支撑，有效增强数据安全治理能力与风险防控水平。

在实际应用中，该系统高效处理了园区内覆盖“源、网、荷、储”各环节的约

4042 万条实时及历史能源数据。通过多维度智能分析，精准识别出 2712 组类具有高推断风险的数据组合和 17 组具有中推断风险的数据组合。系统运行稳定，数据分类准确率达到 92.7%，为构建安全、可信的零碳智慧能源数据生态，保障关键能源设施的稳定运行与核心商业模式的合规发展，提供了不可或缺的技术基石。部署在榆林零碳智慧园区管理平台的系统展示如图 5-33 所示。




图 5-33 部署于榆林零碳智慧园区的系统主页面

本章小结

本章在前述理论方法研究基础上，面向电力数据安全治理的实际需求，设计并实现了基于数据关联的自适应分类分级系统。系统采用前后端分离与容器化部署架构，构建了数据标定、关联分析和动态分级三个核心功能模块，实现了从数据接入、初步标定、风险挖掘到等级动态修正的闭环处理流程；同时，通过在云南电网和榆林零碳智慧园区等场景中的部署应用，验证了系统在大规模多源能源数据环境下的可用性、稳定性和工程适应性。总体来看，本章将前文提出的风险识别与动态分级方法转化为可落地的软件系统，使数据分类分级由静态规则管理进一步走向面向关联风险的自适应决策，为电力数据安全治理的工程化应用提供了实现路径和实践支撑。

结论与展望

研究结论

本文围绕电力数据在开放共享环境下面临的推断泄露威胁，针对传统分类分级方法在隐式关联识别、推断能力刻画和风险动态响应方面的不足，构建了涵盖关联挖掘、风险量化、动态分级和系统落地的研究框架，系统开展了面向推断泄露威胁的电力数据风险识别与分级治理研究。全文形成了“风险识别—分级治理—系统实现”的技术路线，为复杂数据环境下电力数据的精细化安全治理提供了方法支撑。

在推断泄露威胁的风险识别方面，本文结合电力数据多源异构、物理耦合强和业务关联紧密等特点，融合 Pearson 相关系数、Spearman 相关系数和最大信息系数等多种度量方法，对不同数据对象之间的线性、单调及复杂非线性关联关系进行联合刻画，构建了面向推断泄露的数据风险关联图。在此基础上，进一步引入深度神经网络和融合物理约束的图注意力网络，对候选高风险关系的可推断性和结构恢复能力进行验证，实现了由统计相关分析向泄露威胁量化评估的转化。实验结果表明，多度量关联分析能够较有效地识别潜在高风险数据对，所构建的推断模型能够较准确地评估敏感变量恢复与拓扑泄露风险。这说明，部分公开数据或低敏数据在特定条件下确实可能支撑对高敏信息的重构。本文进一步面向公开共享数据域测试了推断泄露威胁的防护方法。本文将防护重点放在信息干扰技术上，设计并分析了数据加噪、数据掩码和数据混淆三类防护策略。研究表明，更强的防护通常伴随一定的数据可用性损失，因此推断泄露威胁的防护仍需在隐私保护与业务可用性之间进行权衡。

在分级治理方面，针对传统静态分级方法依赖人工经验、难以适应复杂场景的问题，本文提出了基于大语言模型、检索增强、自编码器和频繁模式挖掘的初步分级标定方法，并进一步构建了基于强化学习的数据安全等级动态更新模型。该方法一方面通过解析安全规范文本和业务文档，将分级依据转化为结构化规则，实现初始等级标定；另一方面依据推断风险、数据可用性和防护成本对安全等级进行动态调整，使分级结果能够随环境变化自适应更新。实验结果表明，所提出的动态更新模型在训练收敛性、策略稳定性以及安全收益与可用性平衡能力等方面均优于静态策略及 DQN、PPO 等对比方法，说明风险驱动的动态分级机制能够更准确地反映电力数据安全状态的时变特征。

在系统实现方面，本文在上述研究基础上设计并实现了基于数据关联的自适应分类分级系统，构建了数据标定、关联分析和动态分级三个核心模块，并在云南电网、

榆林零碳智慧园区等实际场景中完成部署应用。系统实现了从数据接入、规则匹配、风险挖掘、等级调整到结果反馈的闭环处理流程，验证了本文方法在真实电力数据环境中的可行性、稳定性和工程适用性。

综上，本文的主要贡献不仅体现在提出了面向推断型泄露的风险识别方法和动态分级模型，还体现在将风险识别、威胁量化和动态分级贯通起来，形成了较为完整的电力数据安全治理链条。研究表明，在多源融合和开放共享背景下，仅依赖静态规则和直接敏感性判断，已难以准确反映数据的真实安全风险；将数据关联、推断能力、防护抑制和动态优化共同纳入分类分级过程，能够更有效地支撑电力数据的精细化安全管理。

研究展望

尽管本文围绕电力数据推断型泄露风险的识别、分级与防护进行了较为系统的研究，并在方法设计、实验验证和系统实现方面取得了一定成果，但受研究条件和应用场景限制，仍有一些问题值得进一步研究。

本文对推断型泄露风险的刻画，主要建立在统计关联分析、神经网络推断验证和拓扑恢复实验基础上，能够较好反映典型场景下电力数据的可推断性。然而，在实际环境中，攻击者通常具备更强的数据融合与知识利用能力，推断过程也可能呈现多阶段、跨域和持续演化等特征。后续可在更复杂的攻击者假设下，进一步研究多源异构数据条件下的推断机理与风险传播过程，从而提高风险评估的真实性和完备性。

在防护测试方面，本文重点分析了数据加噪、数据掩码和数据混淆三类信息干扰方法，并验证了其对拓扑推断和虚假数据注入攻击的抑制效果。总体而言，这些方法能够在一定程度上降低公开数据的推断可利用性，但其防护强度仍主要依赖预设参数，对复杂攻击环境的适应能力仍然有限。后续可进一步研究面向风险变化的动态防护机制，并探索信息干扰方法与访问控制、隐私计算等技术的协同应用，以提高防护策略的针对性和灵活性。

在动态分级方面，本文将等级更新建模为单智能体条件下的序列决策问题，重点考察了推断风险、数据可用性与合规要求之间的平衡关系。但在实际业务场景中，数据提供方、使用方、监管方与潜在攻击者之间往往存在更加复杂的交互关系。今后可结合多智能体强化学习或博弈分析方法，进一步研究多主体参与条件下的动态分级与联合防护问题，以增强模型对复杂开放环境的适应能力。

本文的实验验证主要基于公开电力市场数据和标准仿真算例展开，虽然能够支撑方法有效性分析，但与真实业务环境相比，在数据规模、业务链条和场景复杂度方面

仍有进一步拓展空间。后续可面向更大规模、更长时间跨度和更多业务环节的数据场景开展持续验证，并进一步提升系统在实时监测、在线更新和自动联动等方面的能力，推动相关方法向工程化和实用化方向发展。

总体来看，面向推断泄露威胁的电力数据分类分级研究仍需在风险建模、防护优化、动态决策和场景验证等方面继续完善。未来应进一步推动分类分级方法由静态规则驱动向风险感知与动态响应驱动转变，以更好适应新型电力系统背景下的数据安全治理需求。

致 谢

时间匆匆，三年的硕士求学生涯即将走到尾声。回望来路，许多画面仍清晰如昨：初入校园时的期待与忐忑，第一次面对科研问题时的茫然与笨拙，深夜修改论文时的疲惫与坚持，以及在一次次讨论、推翻、重构中逐渐建立起来的信心。三年并不算长，却足以让一个人在求索中认识自己的不足，在磨砺中学会沉静，在压力与挑战面前慢慢拥有继续向前的勇气。如今站在毕业的门槛前，心中有不舍，有感慨，也有许多难以言尽的感谢。

首先，最想感谢我的父母。一路走来，是他们给予我最无条件的支持与鼓励。求学之路从来不是一个人的跋涉，背后始终有父母默默的托举。他们也许并不完全了解研究生的学习与生活细节，也未必能体会论文写作和项目推进中的每一次焦虑，但他们始终用最朴素、最坚定的方式支持着我。在我迷茫时，他们给予安慰；在我疲惫时，他们给予理解；在我面临选择时，他们给予信任。父母的爱不常以华丽的语言表达，却总在最需要的时候成为我继续坚持的底气。能够走到今天，离不开他们多年如一日的包容、付出与守望。

衷心感谢我的导师刘杨老师三年来的悉心培养与指导。从研究方向的确定，到论文选题的凝练；从科研思路的梳理，到具体问题的分析与修改，刘老师都给予了我耐心而细致的指导。三年的学习过程中，我不仅在专业知识和科研能力上获得了成长，更从老师严谨的治学态度、认真负责的工作作风和清晰深刻的学术视野中受益良多。科研并非一条轻松平坦的道路，许多时候需要反复尝试、不断修正，也需要在不确定中保持耐心与专注。刘老师的教导让我逐渐懂得，真正有价值的研究不仅要关注技术本身，更要有扎实的问题意识、严谨的逻辑判断和持之以恒的探索精神。对此，学生铭记于心，深表感谢。

特别感谢王子骏师兄在科研道路上给予我的引领与不懈帮助。初入课题组时，面对新的研究领域和复杂的实验任务，我曾有过许多困惑与无措。师兄在科研方法、实验设计、论文写作以及日常学习中都给予了我许多具体而真诚的帮助。无论是一次次耐心的讲解，还是关键节点上的提醒与指导，都让我少走了许多弯路，也让我在科研训练中逐渐找到方向。师兄严谨踏实的态度、认真负责的精神和乐于助人的品质，是我硕士阶段十分珍贵的榜样。

诚挚感谢课题组刘烃老师的关心与教导。您曾勉励我们要努力成长为各自细分领域的栋梁之才，这份教诲我将始终铭记于心，并以此激励自己在今后漫长的人生道路上持续探索、砥砺前行。感谢杨雨洁老师、王云老师、范铭老师、王海军老师、晋武

侠老师、田决老师等老师们在学术交流、项目推进和日常学习中给予的指导与帮助。感谢魏子旭、王相茗、胡博文、晋文涛、周罕琦、谭维维等师兄师姐在研究过程中给予的指点。感谢冯江琳、李昂良、杜浩存三位师弟以及徐嘉琪、尚锦奥、罗子安、贺彤等电网组伙伴在科研讨论、实验协作和生活点滴中的陪伴与支持。三年的学习生活，因为有课题组这个集体而变得更加充实和温暖。那些一起开组会、改论文、跑实验、讨论问题的日子，或许曾经紧张忙碌，甚至令人疲惫，但如今想来，都是这段求学时光中不可替代的记忆。正是在这样的氛围中，我逐渐理解了科研合作的意义，也感受到了集体前行的力量。

同时，感谢朱老师和一路陪伴我的朋友们。感谢你们在我遇到困难时给予的帮助，在我情绪低落时给予的安慰，在我犹豫彷徨时给予的鼓励。研究生阶段并不只有论文、实验和毕业要求，也有许多关于成长、选择和自我调整的时刻。幸运的是，在这些时刻，我并不是孤身一人。朋友们的陪伴让许多沉重的日子变得轻盈，也让这三年的记忆多了许多温暖的底色。

最后，感谢这三年的自己。学习与研究让我更加清醒地认识到自身的有限，也让我明白，唯有保持谦逊、认真与持续学习，才能在反复试错中不断前进。三年时光或许并不完美，也曾有遗憾与不足，但正是这些真实的经历构成了成长本身。毕业不是终点，而是新的开始。愿未来的自己仍能心怀热爱与敬畏，脚踏实地，坚定前行。

参考文献

- [1] 张世帅, 张学松, 孔庆云, 等. 电力市场多维定向信息发布技术研究[J]. 电网技术, 2008, (S2): 4.
- [2] Yu N, Zhang S, Qin J, et al. Data-driven control, optimization, and decision-making in active power distribution networks[J]. Applied Energy, 2025, 397: 126253.
- [3] 王子骏, 刘杨, 鲍远义, 等. 电力系统安全仿真技术:工程安全,网络安全与信息物理综合安全[J]. 中国科学: 信息科学, 2022, (052-003).
- [4] Wang Z, Liu T, Liu Y, et al. Data Inference:Data Security Threats in the AI Era[J]. Engineering, 2025, 52(9): 29–33.
- [5] 刘烜, 王子骏, 刘杨, 等. 数据推断:信息物理融合系统数据泄露威胁范式和防御方法[J]. 中国科学:信息科学, 2023, 53(11): 2152–79.
- [6] Wang Z, Liu Y, Yu N, et al. Data Inference From Publicly Available Data: Threats and Defense Methods in Power Systems[J]. IEEE Transactions on Power Systems, 2025, 40(1): 1049–59.
- [7] 李鹏, 习伟, 蔡田田, 等. 数字电网的理念, 架构与关键技术[J]. 中国电机工程学报, 2022, 42(14): 5002–17.
- [8] 张俊, 蒲天骄, 高文忠, 等. 电力系统智能计算的关键技术及应用展望[J]. Power Generation Technology, 2025, 46(3).
- [9] Wei Z, Yuan X, Wang Z, et al. Topology Consistency Verification in Power System Based on Data Inference[C]// 2023 3rd International Conference on Energy Engineering and Power Systems (EEPS). 2023: 787–91.
- [10] Jin W, Zhou Y, Hu B, et al. Privacy-Preserving Distributed Economic Dispatch Based on State Decomposition in Smart Grids[J]. IEEE Transactions on Industrial Informatics, 2025, 21(11): 9057–68.
- [11] Yang W, Wang S, Wu D, et al. Deep learning model inversion attacks and defenses: a comprehensive survey[J]. Artificial Intelligence Review, 2025, 58(8): 242.
- [12] Liu R, Wang D, Ren Y, et al. Unstoppable Attack: Label-Only Model Inversion Via Conditional Diffusion Model[J]. IEEE Transactions on Information Forensics and Security, 2024, 19: 3958–73.
- [13] Hu H, Salcic Z, Sun L, et al. Membership Inference Attacks on Machine Learning: A Survey[J]. ACM Comput Surv, 2022, 54(11s): Article 235.
- [14] Van Breugel B, Sun H, Qian Z, et al. Membership inference attacks against synthetic data through overfitting detection[J]. arXiv preprint arXiv:230212580, 2023.
- [15] Leemann T, Pawelczyk M, Kasneci G. Gaussian membership inference privacy[J]. Advances in Neural Information Processing Systems, 2023, 36: 73866–78.
- [16] 秦臻, 庄添铭, 朱国淞, 等. 面向人工智能模型的安全攻击和防御策略综述[J]. 计算机研究与发展, 2024, 61(10): 2627–48.
- [17] 王继民, 张纪峰, 陈嘉龙. 控制系统隐私保护研究综述[J]. 自动化学报, 2025, 51(10): 2178–200.
- [18] 邓晓平, 张桂青, 魏庆来, 等. 非侵入式负荷监测综述[J]. 自动化学报, 2022, 48(3): 644–63.
- [19] 庞博, 张凌浩, 梁晖辉, 等. 面向智能电网的数据聚合隐私保护方案[J]. 重庆大学学报,

- 2025, 48(3): 38–49.
- [20] 张辉, 颜星雨, 毛建旭, 等. 面向源网荷的智能化数据协同推断技术研究综述[J]. 自动化学报, 2025, 51(11): 2387–411.
- [21] Demelius L, Kern R, Trügler A. Recent Advances of Differential Privacy in Centralized Deep Learning: A Systematic Survey[J]. ACM Comput Surv, 2025, 57(6): Article 158.
- [22] Pan K, Ong Y-S, Gong M, et al. Differential privacy in deep learning: A literature survey[J]. Neurocomputing, 2024, 589: 127663.
- [23] Kua J, Hossain M B, Natgunanathan I, et al. Privacy Preservation in Smart Meters: Current Status, Challenges and Future Directions[J]. Sensors, 2023, 23(7): 3697.
- [24] Hafeez K, O’shea D, Newe T, et al. E-DPNCT: an enhanced attack resilient differential privacy model for smart grids using split noise cancellation[J]. Scientific Reports (Nature Publisher Group), 2023, 13(1): 19546.
- [25] Zhou Y, Xu K, Zhu L. Association analysis for nonlinearly dependent data[J]. SCIENTIA SINICA Mathematica, 2024, 54(8): 1169.
- [26] Ma J, Sun Z. Mutual Information Is Copula Entropy[J]. Tsinghua Science & Technology, 2011.
- [27] 刘磊, 高超, 王志刚, 等. 基于非线性相关性和复杂网络的径流相似性分区[J]. 水科学进展, 2022, 33(3): 442–51.
- [28] Reshef D N, Reshef Y A, Finucane H K, et al. Detecting Novel Associations in Large Data Sets[J]. Science, 2011, 334(6062): 1518–24.
- [29] Song L, Mittal P. Systematic evaluation of privacy risks of machine learning models[C]// 30th USENIX security symposium (USENIX security 21). 2021: 2615–32.
- [30] 中华人民共和国数据安全法[Z]. 2021.
- [31] 国家市场监督管理总局、国家标准化管理委员会. GB/T 43697-2024. 数据安全技术-数据分类分级规则[S]. 2024.
- [32] 上海市市场监督管理局. DB31/T 1446—2023. 公共数据安全分级指南[S]. 2023.
- [33] 福建中信网安信息科技有限公司. GB/T 43705—2025. 科学数据安全分类分级指南[S]. 2025.
- [34] 太原清众鑫科技有限公司. DB14/T 3551—2025. 能源数据安全保护分类分级指南[S]. 2025.
- [35] 严炜炜, 谢顺欣, 潘静, 等. 数据分类分级:研究趋势、政策标准与实践进展[J]. 数字图书馆论坛, 2022, (9).
- [36] 商希雪, 韩海庭. 数据分类分级治理规范的体系化建构[J]. 电子政务, 2022, 10: 75–87.
- [37] Li X, Chen X, Wang C, et al. Research on Automatic Classification and Grading of Industrial Data Based on Large Language Model[Z]. Proceedings of the 2023 4th International Conference on Big Data Economy and Information Management. Zhengzhou, China; Association for Computing Machinery. 2024: 719–25.10.1145/3659211.3659335.
- [38] Lai R, Chang Y, Cao Z, et al. Automated parsing method for standards related to data classification and grading[J]. Future Generation Computer Systems, 2025, 178: 108254.
- [39] Li Y, Wu Z, Li J, et al. A Multi-Scene Automatic Classification and Grading Method for Structured Sensitive Data Based on Privacy Preferences[J]. Future Internet, 2025, 17(9): 384.
- [40] Yang T, Zhang Y, Kang C, et al. Exploration of Data Classification and Grading Strategy for Power Grid Enterprises[C]// Proceeding of the 2024 5th International Conference on Computer Science and Management Technology. 2024: 1332–6.
- [41] 高翔, 郭卫霞, 郑宇辰. 浅谈电力行业数据分类分级安全管理的实践[J]. 工业信息安全,

- 2023, (1): 68–73.
- [42] 李新家, 张崇超, 马云龙, 等. 一种面向复杂业务场景的多源异构数据分类分级方法研究[J]. 电力信息与通信技术, 2025, (6).
- [43] 国家发展和改革委员会. 电力监控系统安全防护规定[EB/OL]. 2024. <https://zfxxgk.ndrc.gov.cn/upload/images/202411/20241111172728.pdf>.
- [44] 国家能源局. 能源行业数据安全管理办法（试行）[EB/OL]. 2025. <https://www.nea.gov.cn/20251212/f8ee9d3f829641cb9cc4f1e9405e794a/c.html>.
- [45] Fredrikson M, Jha S, Ristenpart T. Model Inversion Attacks that Exploit Confidence Information and Basic Countermeasures[Z]. Proceedings of the 22nd ACM SIGSAC Conference on Computer and Communications Security. Denver, Colorado, USA; Association for Computing Machinery. 2015: 1322–33.10.1145/2810103.2813677.
- [46] Shokri R, Stronati M, Song C, et al. Membership inference attacks against machine learning models[C]// 2017 IEEE symposium on security and privacy (SP). IEEE, 2017: 3–18.
- [47] Singh A. From past to present: the evolution of data breach causes (2005–2025)[J]. LatIA, 2025, 3: 333–.
- [48] Nalewajski R F. Elements of information theory [M]. Perspectives in Electronic Structure Theory. Springer. 2011: 371–95.
- [49] Efthymiou C, Kalogridis G. Smart grid privacy via anonymization of smart metering data[C]// 2010 first IEEE international conference on smart grid communications. IEEE, 2010: 238–43.
- [50] Dwork C. Differential privacy [M]. Encyclopedia of Cryptography, Security and Privacy. Springer. 2025: 649–52.
- [51] Cheng S, Zhang J, Dong Y. How to Understand Data Sensitivity? A Systematic Review by Comparing Four Domains[Z]. Proceedings of the 4th International Conference on Big Data Engineering. Beijing, China; Association for Computing Machinery. 2022: 13–20.10.1145/3538950.3538953.
- [52] Jegorova M, Kaul C, Mayor C, et al. Survey: Leakage and Privacy at Inference Time[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2023, 45(7): 9090–108.
- [53] Arjmand M, Akbari B, Ghaeini H R. From voltage to vulnerability: A comprehensive survey of dynamic security risk assessment techniques in smart grids[J]. International Journal of Information Security, 2025, 25(1): 7.
- [54] PJM Interconnection. Public Data[DB/OL]. Data Miner 2. (2024-01-31) 2024–09–01. <https://dataminer2.pjm.com/list>.
- [55] Bills G. On-line stability analysis study, RP 90-1 [R]: North American Rockwell Information Systems Co., Anaheim, CA (USA), 1970.
- [56] Pai A. Energy function analysis for power system stability [M]. Springer Science & Business Media, 1989.
- [57] Athay T, Podmore R, Virmani S. A practical method for the direct analysis of transient stability[J]. IEEE Transactions on Power Apparatus and Systems, 2007, (2): 573–84.
- [58] Kaggle. Global Energy Forecasting Competition 2012-Load Forecasting[DB/OL]. Kaggle. (2012-09-06) 2025–02–23. <https://www.kaggle.com/c/global-energyforecasting-competition-2012-load-forecasting>.
- [59] Fano R M, Hawkins D. Transmission of information: A statistical theory of communications[J]. American Journal of Physics, 1961, 29(11): 793–4.
- [60] Birchfield A B, Xu T, Gegner K M, et al. Grid structural characteristics as validation criteria for synthetic networks[J]. IEEE Transactions on power systems, 2016, 32(4): 3258–65.

- [61] 李凤华, 李晖, 牛犇, 等. 隐私计算——概念, 计算框架及其未来发展趋势[J]. 工程(英文), 2019, 5(6): 1179.
- [62] Yadati N, Nimishakavi M, Yadav P, et al. Hypergcnn: A new method for training graph convolutional networks on hypergraphs[J]. Advances in neural information processing systems, 2019, 32.
- [63] Yun S, Jeong M, Kim R, et al. Graph transformer networks[J]. Advances in neural information processing systems, 2019, 32.
- [64] Yang Y, Zhou Y, Wu J, et al. An event-triggered hybrid system model for cascading failure in power grid[J]. IEEE Transactions on Automation Science and Engineering, 2022, 19(3): 1312–25.
- [65] Angulo-Paniagua J, Quirós-Tortós J. Comparing chi-square-based bad data detection algorithms for distribution system state estimation[C]// 2020 IEEE PES Transmission & Distribution Conference and Exhibition-Latin America (T&D LA). IEEE, 2020: 1–5.
- [66] Minaee S, Mikolov T, Nikzad N, et al. Large language models: A survey[J]. arXiv preprint arXiv:240206196, 2024.
- [67] Guo D, Yang D, Zhang H, et al. Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning[EB/OL]. arXiv preprint arXiv:250112948, 2025.
- [68] Terven J. Deep reinforcement learning: A chronological overview and methods[J]. Ai, 2025, 6(3): 46.
- [69] Shao Z, Wang P, Zhu Q, et al. Deepseekmath: Pushing the limits of mathematical reasoning in open language models[EB/OL]. arXiv preprint arXiv:240203300, 2024.

攻读学位期间取得的研究成果

- [1] Xing Z, Wang Z, Feng J, et al. MIC-DNN: Data-Driven Correlation Analysis Framework for Power Data[C]// 2025 40th Youth Academic Annual Conference of Chinese Association of Automation (YAC). 2025: 2969–74.
- [2] 吴桐, 邢之熠, 王子骏, 等. 电网公开数据关联下的拓扑泄露威胁和防御研究[J]. 电网技术. 2026, 50(5): 2137-2147.
- [3] 刘杨, 冯江琳, 王子骏, 邢之熠, 等. 一种电网线路潮流信息推断威胁评估方法及系统: 中国, CN202510433280.3[P] (已授权) . 2025-05-06.
- [4] 刘杨, 邢之熠, 王子骏, 等. 一种电碳交易过程数据自适应分类分级方法及相关装置: 中国, CN202410880405.2[P] (已受理) . 2024-07-02.
- [5] 赵毅涛, 邢之熠, 沈鑫, 等. 一种输出上链传输数据的分类方法、系统、设备及介质: 中国, CN202510529359.6[P] (已受理) . 2025-04-25.
- [6] 吴桐, 邢之熠, 黄菊, 等. 电网公开数据关联下的拓扑泄露威胁评估方法及装置: 中国, CN202511376484.4[P] (已受理) . 2025-09-25.
- [7] 邢之熠, 等. 电碳交易过程数据自适应分类分级软件 (软件著作权): 中国, 2024SR0496371[P], 2024.04.12.
- [8] 邢之熠, 冯江琳, 周俊林, 等. 数治先锋: 基于要素匹配和关联决策的数据分类分级系统: 第十八届全国大学生软件创新大赛, 国家一等奖, RJXTAQS20250102QGJS1055. 2025-05-19.

答辩委员会会议决议

论文围绕电力数据开放共享场景下的推断型泄露风险识别与动态分级防护问题展开研究，针对传统数据分类分级方法主要依赖静态规则、难以刻画多源数据关联条件下隐性泄露风险的问题，开展了系统分析与方法设计。该选题契合数据安全治理和电力数据安全共享的现实需求，具有一定的理论意义和实用价值。论文主要完成工作如下：

- 1.面向电力数据开放共享过程存在的推断型泄露风险，采用多指标关联分析与推断模型验证相结合的方法，对潜在风险路径和敏感信息推断能力进行了识别与验证；
- 2.面向静态分级难以适应风险变化的问题，设计了数据安全等级动态更新方法，将推断风险、可用性损失、防护成本和合规要求统一纳入等级更新过程，实现了由静态规则驱动向风险感知驱动的分级治理扩展；
- 3.面向电力数据安全治理实际需求，设计并实现了基于数据关联的自适应分类分级系统，为面向推断泄露威胁的电力数据精细化安全治理提供系统实现方案。

论文写作认真，表述清楚，内容充实，态度科学严肃。从论文的工作表明作者已掌握网络空间安全学科的基础理论和专业知识，具备一定的独立从事科学研究和工程实践工作的能力。论文答辩中叙述清晰，问题回答正确。是一篇高质量的硕士学位论文。

经答辩委员会讨论和投票表决，一致同意通过邢之熠同学的硕士学位论文答辩，并建议授予工学硕士学位。

常规评阅人名单

本学位论文共接受 2 位专家评阅，其中常规评阅人 1 名，名单如下：

范铭

副教授

西安交通大学

.

学位论文独创性声明 (1)

本人声明：所呈交的学位论文系在导师指导下本人独立完成的研究成果。文中依法引用他人的成果，均已做出明确标注或得到许可。论文内容未包含法律意义上已属于他人的任何形式的研究成果，也不包含本人已用于其他学位申请的论文或成果。

本人如违反上述声明，愿意承担以下责任和后果：

1. 交回学校授予的学位证书；
2. 学校可在相关媒体上对作者本人的行为进行通报；
3. 本人按照学校规定的方式，对因不当取得学位给学校造成的名誉损害，进行公开道歉。
4. 本人负责因论文成果不实产生的法律纠纷。

论文作者（签名）： 日期： 年 月 日

学位论文独创性声明 (2)

本人声明：研究生所提交的本篇学位论文已经本人审阅，确系在本人指导下由该生独立完成的研究成果。

本人如违反上述声明，愿意承担以下责任和后果：

1. 学校可在相关媒体上对本人的失察行为进行通报；
2. 本人按照学校规定的方式，对因失察给学校造成的名誉损害，进行公开道歉。
3. 本人接受学校按照有关规定做出的任何处理。

指导教师（签名）： 日期： 年 月 日

学位论文知识产权权属声明

我们声明，我们提交的学位论文及相关的职务作品，知识产权归属学校。学校享有以任何方式发表、复制、公开阅览、借阅以及申请专利等权利。学位论文作者离校后，或学位论文导师因故离校后，发表或使用学位论文或与该论文直接相关的学术论文或成果时，署名单位仍然为西安交通大学。

论文作者（签名）： 日期： 年 月 日

指导教师（签名）： 日期： 年 月 日

(本声明的版权归西安交通大学所有，未经许可，任何单位及任何个人不得擅自使用)