

# 面向推断风险的 数据分类分级体系

规则确定基线 · 组合推断补充证据 · GRPO 支持联合等级建议

---

## 规则基线

明确分什么、依据什么定级

→

## 推断证据

发现单字段之外的组合影响

→

## 等级建议


在硬约束内复核并联合优化

形成“有规则依据、有推断证据、可审批、可复评”的分类分级结果。


# 单项定级之外，还要检查组合后能揭示什么

新的风险可能出现在字段之间，也可能来自接收方已经掌握的信息。

## 单独观察



## 联合观察



**需要补充评估：组合后多揭示了什么，以及是否改变原有分级依据。**

依据：所供分级手册“深度”要素、附录 D/E；风险评估手册第 382 项。图为原理示意。

# 四个阶段，形成有依据、可复核的等级结论


以南网分类分级规则为基线，将推断证据接入等级复核与审批。



范围：基础分类分级、推断风险增强、等级复核建议、审批固化与动态更新。

# 基础定级：先分类，再按影响形成规则等级

大模型与检索增强辅助条款提取，定级依据仍是业务语义和南网规则。



依据：所供分级手册第四部分、表 4.4、附录 A-C；重要 / 核心数据按对应识别、申报与审批程序处理。

# 场景定义：谁在什么时候已经知道什么

同一数据，在不同主体、时点和已有背景下，可能形成不同的推断证据。

## 一张场景卡，固定评估问题

|         |             |
|---------|-------------|
| 接收主体    | 角色、授权与用途    |
| 评估时点    | 披露前 / 披露后   |
| 已知背景 B  | 公开、自有、历史已获取 |
| 受保护目标 y | 此时对该主体仍需保护  |

## 把“已有”与“可能新增”分开

### 已有背景 B

已掌握的信息保留，不因重新定级而消失

### 可得字段 H

依据主体、时点、授权及确认的等级映射确定

披露时点改变 → 重新确认 B、H 和目标

市场“公开信息”面向有关市场成员；不能等同于向社会公众公开。

依据：所供披露细则 2.7、5.1；开放目录说明、注册细则；等级一可见范围映射须经业务确认。

# 关联找线索，联合验证确认能否推断

两路分析相互补充：关联图解释关系，集合评估直接检验联合信息。

## 关联发现

|          |       |
|----------|-------|
| Pearson  | 线性关系  |
| Spearman | 单调关系  |
| MIC      | 非线性依赖 |

产物：候选关联图、方向线索  
方向需结合业务或预测验证

## 联合推断评估



连续目标：样本外预测能力  
结构目标：匹配任务的恢复指标

产物：集合能力  $V(B \cup S)$  与可核验结果


关联弱的字段也可能参与强组合：联合评估不能被两两关联图直接排除。

方法定位：关联图提供解释与优先级；模型预测检验推断能力；连续与结构目标分别验证。

# V 判断暴露，M 与 Γ 解释字段为何需要复核

同一目标、同一场景：比较加入字段 i 前后，推断能力增加了多少。

V：在留出数据上的推断能力（示意  $R^2$ ）




最终能力是否越线，用 V 判断；为什么这个字段值得复核，用 M、Γ 和见证背景解释。

全部数值为原理示意：T\* 为示意背景族中的最大见证；τ 需按目标确认；分数不直接映射安全等级。

# 等级复核：先把推断证据转成影响依据

技术越线触发复核；建议等级仍需要回答“影响谁、影响多严重”。



- 规则基线：原则上不低于基线
- 重要 / 核心：按识别程序处理
- 证据不足或约束冲突：专项复核

数据项、数据集、衍生产品分别复核；组合的风险不自动复制为每个成员的等级。


**优化只在有依据的候选级别和可行约束内选择方案，不以代价替代影响判断。**

依据：所供分级手册表 4.4、附录 D/E；输出区分规则等级、建议等级与最终批准等级。

# 联合优化：满足约束，同时减少不必要的调整

示意前提：候选级别已复核，且级别调整会改变该角色未来可获取的字段。

## 四组已核验越线组合



## 比较满足同一组约束的方案

全部上调到 3 级

A 2→3 B 1→3 C 1→3 D 1→3

7  
级次

只上调 A、D

A 2→3 B 保持 C 保持 D 1→3

3  
级次

选择 A 与 D，可让这四组组合各缺少成员。


关键是“哪个调整能同时满足哪些组合约束”，而不是简单上调 M 最大的字段。

示意：目标 3 级，角色最多取得 2 级字段，各级次权重相同；已知背景保留；仅讨论这四组约束。

# GRPO：在规则硬约束内，逐步形成等级建议

同一状态采样多条调整轨迹，在组内比较收益，学习更合适的调整顺序。

硬约束贯穿全程：规则基线 · 合法候选级别 · 已知背景 / 披露要求 · 审批边界



**奖励：已核验越线减少 – 调整代价**

通过一致性检查与补充验证  
才形成可提交的建议

算法保留 KL 约束等训练机制；不允许用奖励抵消规则违规。整数规划与覆盖贪心作为对照，结果见备查 A2。

## 验证闭环：建议形成后，再检查剩余可得组合

扫描用于提高效率，补充验证用于发现漏项；一次性验证不能代替闭环。



**结论必须连同范围提交：数据版本、模型、目标、背景与已核验组合规模。**

依据：项目 E2/E2b 验证记录。范围内无残余，不代表所有模型、未来数据与更大组合都安全。

# 输出可审批的等级清单，随变化持续复评

让每一项等级建议都能追溯到规则、场景、推断证据与审批记录。

## 一项完整的分级记录

|       |                    |
|-------|--------------------|
| 对象与分类 | 字段 / 数据集 / 产品及业务路径 |
| 规则基线  | 规则等级、依据条款与版本       |
| 补充证据  | 目标、背景、能力、验证范围      |
| 等级建议  | 建议级别、复核理由与约束       |
| 最终记录  | 审批结论、目录版本、复评条件     |

## 审批之后，才固化正式结果



## 触发复评的变化

- 数据与产品变化
- 背景与主体变化
- 规则与时效变化

规则有依据，风险有证据，建议可解释，结果可审批，变化可复评。

落地前确认：有效规则版本、目标及阈值、真实授权与历史背景、试点数据；本次不预填真实南网等级。

# 备查：风险量与等级一致性条件

以下是研究评估量与约束的形式化表达，不是南网法规中的数值分级规则。

## 风险量的定义

$$\Delta_i(T) = V(B \cup T \cup \{i\}) - V(B \cup T)$$

$$M^{(0)} = \Delta_i(\emptyset) \quad M^{(K)} = \max \Delta_i(T) \quad \Gamma^{(K)} = M^{(K)} - M^{(0)}$$

最大值在可行背景  $T$  中取：来自候选背景池，不含  $B$  或字段  $i$ ，字段数不超过  $K$ 。

## 一致性检查

对该主体仍受保护的目标：所有纳入检查的可得组合  $S$  均满足  $V(B \cup S) \leq \tau$ 。

目标：在允许的候选级别内，减少加权调整代价；约束：规则基线、披露要求与一致性。

$B$  已足以暴露、成员不可调整或映射不成立时，报告冲突并人工复核，不承诺一定有解。

$V$  是固定经验协议下的样本外能力； $K$  是评估预算； $\tau$  按目标与业务确认；以上省略目标和场景下标。

# 备查：已有验证结果与下一步

重点展示 GRPO 的研究机制，同时保留精确基线和已有实验的真实结论。

## GRPO 与基线的代价比较

相对精确最优的平均代价（越接近 1 越好）

| 方法               | 见过的组         | 未见过的组        |
|------------------|--------------|--------------|
| 精确最优             | 1.000        | 1.000        |
| 覆盖贪心 + 回退        | 1.021        | 1.016        |
| <b>GRPO + 回退</b> | <b>1.010</b> | <b>1.008</b> |

当前规模精确求解平均约 8 ms。  
GRPO 相对贪心小幅改善，扩展价值仍待验证。

来源：01 号实验 WORKLOG、e3\_summary.csv、e2b\_summary.csv；公开电力数据、随机等级 / 代价、≤ 35 字段、≤ 3 字段组合、2 种子。

## 验证闭环的作用

使用估计值先验后，需要核验的集合比例



闭环在既有真值表内达到零残余；  
验证调用通过查表模拟，非新增重训。

下一步：真实权限与等级、南网样本、  
更大组合范围与动态场景。