

本次工作：正式协议与完整评估



对应 102—109 号文件夹

- 统一正式实验协议，比较单／多目标主干和参考模型族
- 生成完整风险表，完成评分基线与发布规则比较
- 补齐背景认证、区间评价和辅助标签量实验，形成 V3 阶段论文结果

统一正式实验协议

- 训练集拟合主干与专用模型；验证集选择攻击器轮次／类型和读出超参数；测试集报告样本外表现
- 参考能力来自单目标 DNN、多目标 DNN、梯度提升树的既定选择协议及单调处理
- 主干选择、读出消融、风险表和发布实验使用相同字段角色与数据拆分
- 报告的是有限样本、指定模型族下的经验能力


完成单目标／多目标主干对照



- 单种子对照中，多目标主干的集合值误差更小；一次查询可以同时服务 12 个目标
- 保留多目标主干作为正式配置，单目标主干作为消融。原图蓝色为 PJM，橙色为 CAISO

量化单目标方案的重复开销



图2 single-target 的代价：查询 12 倍、训练 12 倍，而精度并不更好



- 12 个目标的查询：PJM 46.5 ms 对 4.4 ms；CAISO 60.0 ms 对 5.6 ms
- 单目标预学习也需要重复训练。本轮同时根据精度和成本确定共享多目标方案


补齐三模型经验参考值

图3 正式攻击器族：规模越大，树模型越常胜出；只用一个 DNN 会低估 0.005-0.027



- 103 号补算单目标 DNN 全量结果，形成正式参考表；树模型与两种 DNN 各有贡献
- 单一多目标 DNN 会低估部分集合能力； $K \leq 2$ 正式结果统一按新参考表重新计算


重做读出组件比较



- 在正式参考表上比较共享输出头与按集合求解的闭式读出
- PJM 的 M^2 MAE 从约 0.118 降至 0.032；CAISO 也明显改善
- 逐集合适配读出是本轮最主要的有效改动。蓝色为 PJM，橙色为 CAISO


生成正式字段风险全表

图3 背景预算的实际意义：多数字段在拿到 1-2 个辅助字段后风险明显上升




- 104 号形成 $2 \times 12 \times 41 \times 3 = 2,952$ 条字段—目标—预算记录，并保存风险值和支撑背景
- $\tau=0.7$ ：PJM 的关键条目由 K=0 的 11 条增至 K=2 的 337 条；CAISO 由 18 增至 246 条

完成评分基线比较





- 置换重要性、SAGE 和一般相关性评分的效果较弱；精确单字段能力是很强的排序基线
- PJM 上单字段与估计 M^2 的 PR-AUC 接近，因此贡献表述落在风险幅度、具体背景和阈值证据上

完成发布规则的漏放／误拒评估



- 每个数据集抽取 2,000 个三字段集合：单字段规则漏放约 19% / 56% 的真实危险集合
- 精确 M 预算本次无漏放，但误拒约 86% / 74%；逐阶预算降至约 50% / 33%，展示了保守性的代价


增加前三背景认证与区间报告



- 108 号改为验证前三个背景: PJM K=2 的认证恢复比从 0.822 提高到 0.908
- 补做留一字段校准, $\alpha=0.01$ 的经验覆盖率约 98%; 所需参考集合已在正式表中, 无需额外训练


量化区间判定的收益与代价

图2 区间保守判定把 τ -critical 漏判基本消除：PJM $\tau=0.7$ 的 recall 0.754 $\rightarrow$ 0.994，代价是 precision 0.99 $\rightarrow$ 0.87
安全语义上这是正确方向（宁可误报不可漏报）；precision 的下降由后续重训认证复核吸收




- PJM、 $\tau=0.7$ ：召回从 0.754 提高到 0.994，同时精确率降至 0.870
- $\tau=0.9$ 时误报更明显，因此采用保守筛选后验证的流程；元训练版本和口径不同的 $K=3$ 结果移作补充

补做辅助标签量敏感性实验



- 109 号比较 10%、25%、50%、100% 的嵌套数据量；只用多目标 DNN，四档内部保持可比
- 10% 数据下三字段集合能力仍保留约 81% / 90%；与此同时，部分小样本 M 反而高于完整数据

完成小样本最大值偏差的排查



- 对 M 的变化分解后，发现能力下降与背景选择增益同时存在
- 小样本下选择增益可能盖过能力下降，不能据此解释成“数据越少越危险”
- 评价时同时报告认证与区间，辅助标签量实验已完成解释与口径修正

本次完成的工作

- 102—103：确定共享主干、正式参考族和读出方案
- 104—106：风险全表、字段评分、发布规则均已完成
- 107—109：结果核查、认证与区间补充、辅助标签量实验已收束
- 对应英文论文 V3 的完整首轮证据已形成，阶段结果和适用范围均已记录