

第 1 次组会汇报

字段的推断风险应该怎么定义

对应工作：0913/0914 方向讨论与分级预实验、98—101 号实验

本次要点

1. 通用模型已经能快速估计任意字段集合的推断能力 $V(S)$ ，但“估得快”本身不是交付物。往下延伸时，我们先做了字段级分级，发现真正缺的是“**一个字段的推断风险**”到底是什么。
2. 用 Shapley 值做字段推断风险**不合适**：冗余字段会被互相稀释，协同通道会被平均掉。
3. 在 MCI (Catav 等, ICML 2021) 的基础上，提出**背景受限的最大边际推断能力** $M^{(K)}$ ：攻击者最多再掌握 K 个字段时，公开这个字段最多能增加多少推断能力。
4. 初步验证：定理和命题在真值上零违例；41 个字段上 $K=2$ 已接近饱和；换到独立数据上，排序和阈值结论基本保住。

1 起点：通用模型能估 $V(S)$ ，然后呢？

此前的主线是一个随机掩码训练的**通用推断模型**：一次训练，就能对任意字段集合 S 给出攻击者重训后的推断能力 $V(S)$ （测试 R^2 ）。9 月中旬讨论方向时遇到的问题是：

- 只说“估得快”没有意义，最后必须交付一个**能用于决策的对象**；
- 数据分类分级的实际流程是**逐字段定级**，集合级结论（哪些组合危险）落不进现有流程。

所以第一步想法是往下延伸：用通用模型给出的大量 $V(S)$ ，**反推一张字段级分级表**。

2 第一次尝试：字段分数 + 协同例外清单

在对数残差标度 $g(v) = -\frac{1}{2} \ln(1-v)$ 上，把集合风险拆成“字段分数之和 + 少量协同例外”：

$$g(V(S)) \approx \sum_{i \in S} w_i + \max_{(i,j) \subseteq S} \delta_{ij}^+.$$

选对数标度的原因： $g(0) = 0$ 自动成立、不会越过 1；在高斯情形下 g 就是互信息（单位为奈特），可加等价于“各字段提供相互独立的信息”。

用 69 号的重训真值（12 个目标）做了预实验：

表 1: 字段级分级预实验（69 号真值）

问题	结论	关键数字
对数标度有用吗	明显好于原始 R^2	大集合 MAE 0.152 $\rightarrow$ 0.084
协同稀疏吗	是	946 对中 87.9% 近似可加，6.7% 协同
只用字段分数够吗	不够，漏掉协同	协同三元组危险误判 4.5%
加例外清单	有用（聚合要取最大）	危险误判 4.5% $\rightarrow$ 0.7%
大集合	冗余累积，分数系统性高估	21—43 阶偏差 +0.115

这条路能走，但暴露出一个更根本的问题：

表 2: 一个两行就能验算的反例（PJM，目标为计量负荷）

集合	V	$g(V)$
{风电出力}	0.064	0.033
{风电占比}	0.162	0.088
可加模型预测		0.122
{风电出力, 风电占比} 真实值	0.928	1.316

两者相差约 10 倍，而且**无法通过调权重弥合**。也就是说，字段分数 w_i 不是数据里客观存在的量，只是把集合风险“投影”到字段上的一种选择。投影的方式换了，分数就变了。于是问题变成：

一个字段的“真实风险”应该用什么量来表示？分级表只是它的离散化。这个量定义清楚，就成为论文主线。

3 候选一：Shapley 值（98、99 号）

Shapley 值是最常用的字段“贡献”度量，而且在通用模型上可以算得较准（98 号：精确枚举的 Kendall τ 约 0.89）。但问题出在**语义**上：Shapley 回答的是“全部风险怎样

公平分摊”，而数据安全要问的是“在某个背景下公开这个字段，风险最多增加多少”。




图 1: 98 号：Shapley 值（蓝）与单字段能力（灰）、背景最大边际（橙）的对比

原图：DNN_Aggesvation98/figures/fig3_shapley_vs_risk_semantics.png

- **冗余被稀释**：两个负荷预测各自能推出 0.98，Shapley 每个只分到 0.22；删掉其中一个，另一个还在，全集删除边际约为 0。
- **协同被平均掉**：风电出力和风电占比合起来能推出 0.83，但在大多数联盟里已经有负荷预测，风电字段的边际接近 0，所以 Shapley 只给 0.04—0.05。

99 号做了一个更直接的副本实验：给负荷预测再加 4 个完全相同的副本。




图 2: 99 号：副本越多，Shapley 越低； $M^{(1)}$ 与单字段能力不变

原图：DNN_Aggesvation99/figures/fig3_copy_dilution.png

负荷预测的 Shapley 从 0.223 降到 0.114, 而 $M^{(1)}$ 始终是 0.991。发布方只要多发几个副本, 就能把风险分数“做低”, 所以 Shapley 不能作为风险分级的依据。

4 提出 $M^{(K)}$: 背景受限的最大边际推断能力

4.1 定义

目标为 y , 公开基底为 B (已经必须公开的字段), 候选字段集合为 H , 背景预算为 K :

$$M_i^{(K)} = \max_{T \subseteq H \setminus \{i\}, |T| \leq K} [\bar{V}(B \cup T \cup \{i\}) - \bar{V}(B \cup T)].$$

- 含义: 攻击者最多另外掌握 K 个字段时, 公开字段 i 最多能让推断能力增加多少。取到最大值的 T^* 称为**见证背景**, 说明“在什么情况下这个字段最危险”。
- $\bar{V}$ 是经验攻击能力的**单调闭包**: 攻击者拿到 S , 可以只用其中一部分字段。真值上约 7—9% 的集合非单调, 不做闭包, 安全定理就不成立。
- $K = 0$ 就是单字段能力; $K \geq |H| - 1$ 且 $B = \emptyset$ 时就是 MCI。

图1 $v(S) \rightarrow$ 条件边际 $\rightarrow$ 四种字段量: 数学关系与安全语义总览




图 3: 99 号: $V(S)$ 、条件边际与几种字段量之间的关系, 以及 $M^{(K)}$ 的三条安全语义

原图: DNN_Aggesvation99/figures/fig1_relation_map.png

4.2 与 MCI 的关系

MCI 是 Catav 等 2021 年提出的, $M^{(K)}$ 是它在“有限背景 + 公开基底”下的截断版本。副本不变、单字段下界、见证 (context) 等性质直接继承自 MCI, 引用, 不作为本文创新。

表 3: 继承、新增与需要证明的内容

继承自 MCI	本文新增	本文证明的新结论
最大边际与见证背景	背景预算 K (攻击者知识上限)	截断的预算不等式 (逐阶预算)
单调、 $V(\emptyset) = 0$ 的假设	公开基底 B	通用安全余量
单字段下界、副本不变	阈值、余量、关键性等安全语义	τ -关键 $\Leftrightarrow$ 属于小的最小不安全集合
Shapley 在副本下被稀释	经验攻击能力的单调闭包	估计误差传播与上下界 $L \leq M \leq U$

三条安全语义 (前提是 $\bar{V}$ 单调):

1. **余量**: $M_i^{(K)}$ 是“不论阈值多少, 公开 i 都不会越线”所需的最小余量;
2. **关键性**: 存在大小不超过 K 的背景使 i 越过阈值 τ , 当且仅当 i 属于某个大小不超过 $K + 1$ 的最小不安全集合;
3. **预算**: $|A| \leq K + 1$ 时 $V(B \cup A) - V(B) \leq \sum_{i \in A} M_i^{(K)}$, 可以直接用字段分数给集合定上界。

4.3 与已有字段量的区别

表 4: 各类字段风险度量满足的要求 (✓ 满足, ◦ 部分满足, — 不满足)

方法	可用攻击检验	联合推断	最坏情形	冗余不稀释	有限背景	公开基底
相关系数 / 互信息	—	—	—	✓	—	—
单字段重训 $M^{(0)}$	✓	—	—	✓	—	◦
推断图传播 (IGNN)	—	◦	—	◦	—	—
Shapley / SAGE	✓	✓	—	—	—	—
LOCO / 置换重要性	✓	✓	—	—	—	—
MCI	✓	✓	✓	✓	—	—
$M^{(K)}$ (本文)	✓	✓	✓	✓	✓	✓

一句话区分: Shapley、SAGE 取平均并分摊; LOCO 只看全集删除; MCI 取最坏情形, 但背景不受限; $M^{(K)}$ 取有限背景下的最坏情形。

5 初步验证 (99—101 号)

5.1 小博弈上的命题核验 (99 号)

在 98 号的两个精确博弈 (12、14 个字段, 全部 2^p 个集合都有重训真值) 上逐条检验:

表 5: 命题核验 (gameA / gameB)

命题	结果
$M^{(1)} = a_i + \max(0, \max_j I_{ij})$	偏差 0 / 0
预算不等式 $V(A) \leq \sum_{i \in A} M_i^{(K)}$	违例 0 / 0
关键性 $\Leftrightarrow$ 小的最小不安全集合	原始 V 上 0.2% 不一致; 闭包 $\bar{V}$ 上 0
$M^{(K)}$ 对 K 单调	违例 0 / 0

此外, 在随机 3、4 人博弈上暴力搜索反例, 修正了初稿中三处过强的表述 (例如“增强为 0 当且仅当次模”不成立)。

5.2 完整字段集上 K 取多大 (100 号)

去掉别名后 PJM、CAISO 各 41 个字段、12 个目标, 用并行专用重训精确计算规模不超过 4 的全部 112,791 个集合。

图1 完整字段集上的 K 敏感性 ($M^{(K)}$ 精确计算; MCI 由通用模型搜索大背景 + 专用重训认证给出下界)




图 4: 100 号: 推断升级曲线 (左) 与饱和比 $M^{(K)}/\text{MCI}$ 已认证下界 (右)

原图: DNN_Aggesvation100/figures/fig1_escalation_saturation.png

表 6: 饱和比 (均值 / 中位数)

	$K = 0$	$K = 1$	$K = 2$	$K = 3$
PJM	0.39 / 0.35	0.71 / 0.75	0.88 / 0.93	0.999 / 1.00
CAISO	0.51 / 0.52	0.81 / 0.85	0.93 / 0.97	0.999 / 1.00

- 单字段能力 ($K = 0$) 平均只有完整风险的 35%—50%，**绝大部分风险来自背景**。
- $K = 2$ 已接近饱和， $K = 3$ 基本饱和；更大的背景（平均 5 个字段）只让 0.2% 的条目再增加超过 0.02。所以主口径取 $K = 2$ 。
- 典型案例：PJM 风电出力单独 0.06，配上风电占比后 0.76（总发电 = 出力 / 占比）。

5.3 换到独立数据还成立吗 (101 号)

同一份数据上既找最坏背景又报告数值，会因为取最大值而偏高。101 号把数据对半分，一半用于发现、另一半用于认证（3 次随机对半 $\times$ 2 个方向）。


图1 101号独立认证 (discovery / audit 完全不相交, 3次随机对半 $\times$ 2 方向, 误差条为 95% t 区间)

图 5: 101 号: 发现 / 认证完全分离后的结果

原图: DNN_Aggesvation101/figures/fig1_independent_certification.png

- 取最大值的偏高确实存在: PJM $K = 2$ 约 0.051 ± 0.016 , CAISO 约 0.023 ± 0.013 。所以报告的 M 数值要用独立认证值，或者标注偏差量级。

- 结论层面基本保住： $\tau = 0.7$ 时，关键字段在独立数据上召回 87% (PJM) / 93% (CAISO)，强交互复现 71% / 95%。

5.4 一个伏笔：精确计算其实不慢

41 个字段、 $K = 2$ 的全部 11,521 个集合，用 GPU 并行重训约 **11 分钟** 就能精确算完。所以在这个规模上，通用模型**不是必需的**。它的价值要到更大的 K 、更多字段、反复换基底或换目标的场景才体现出来，并且必须配上区间和重训认证一起用。估计器的问题留到第 5、6 次汇报。

6 小结与下一次

小结

- 论文主线从“估得快”改为“字段的推断风险怎么定义、怎么用”。
- Shapley 语义不合适； $M^{(K)}$ 取有限背景下的最坏情形，副本不稀释，有见证背景，并有三条可用于发布判定的安全语义。
- $K = 2$ 接近饱和；独立数据上的排序和阈值结论基本成立，但数值要考虑取最大值带来的偏高。

下一次：用正式口径（多攻击器、单调闭包）算出完整风险表，回答“ $M^{(K)}$ 比现有的字段打分方法多看到了什么，对发布决策有什么用”。