

第 1 次组会汇报

从集合推断能力到字段推断风险

对应工作：9 月中旬方向讨论、98—101 号实验

本次要点

1. **出发点**：通用推断模型能快速给出任意字段集合的推断能力，但它只是工具，需要一个进一步的产物才能讲成一个完整的故事。
2. **为什么做字段级推断风险**：
 - 数据分级按字段进行，但只用单字段推断能力衡量字段风险不合理，会漏掉组合推断；
 - IGNN 这类黑盒模型给出的敏感度没有可检验的含义，解释性差；
 - 更合理的做法是：先考虑所有字段集合的推断风险，再用恰当的定义把集合风险归结到字段上。通用模型正好是遍历集合风险的工具。
3. **怎么从集合风险得到字段风险**：
 - Shapley 值是最常用的分配方法，但它“平均分摊”，冗余字段会被稀释，协同通道会被平均掉，不适合衡量安全风险；
 - Catav 等提出的 MCI 取“最坏背景下的最大边际”，方向正确，但背景不受限，也没有公开基底和安全语义；
 - 我们在 MCI 基础上提出**背景受限的最大边际推断能力** $M^{(K)}$ 。
4. **初步验证**：理论命题在真值上零违例；41 个字段上 $K = 2$ 已接近饱和；独立数据上排序和阈值结论基本保住。

1 出发点：通用推断模型之后还缺什么

1.1 集合推断能力 $V(S)$

本课题关心的是**数据推断泄露**：攻击者拿到一些看似不敏感的公开字段，训练模型去推断敏感目标（例如机组出力、实际负荷）。度量方式是：

集合推断能力 $V_y(S)$ ：攻击者掌握字段集合 S 的历史数据后，专门针对 S 训练推断模型（DNN、梯度提升树等，在验证集上挑最强的一个），对目标 y 在测试集上达到的 R^2 。

它的好处是**可检验**：任何一个数都可以真的做一次攻击实验来复核。

1.2 通用推断模型

问题在于集合数量是指数级的：41 个字段就有 2^{41} 个集合，而每个集合专门重训一次要 14—56 秒。此前的一系列实验因此训练了一个**通用推断模型**：

- 训练时随机遮住一部分字段（掩码），让一个网络学会“只看到任意一部分字段时怎么推断”；
- 训练一次之后，对任意集合 S 都能在毫秒级给出 $\hat{V}(S)$ ，不必再逐个重训。

1.3 但它只是工具

9 月中旬讨论方向时的核心问题是：**有了这个估计器，然后呢？**只说“估得快”不构成一个故事，最后必须交付一个能用于决策的产物。那么这个产物应该是什么？

2 为什么是字段级的推断风险


2.1 实际需求：数据分级是按字段做的

《数据安全技术数据分类分级规则》（GB/T 43697—2024）[1] 和电力市场信息披露规则 [2] 都是**逐字段**给出类别、等级和披露要求的。规则也提到要考虑“汇聚、加工后等级的变化”，但没有说怎么做。所以一个**考虑推断的字段级风险**有直接的使用场景。

2.2 现有做法一：只看单字段推断能力，不合理

最直接的字段风险是单字段推断能力 $V(\{i\})$ ：只公开这一个字段，攻击者能推出多少。它的问题是**忽略了攻击者手里的其他信息**。

图2 典型推断升级曲线：单字段弱、一个辅助字段即跃升（出力+占比、节点价差），与单字段即强的字段对照

图 1: 100 号：典型字段在允许 K 个背景字段时的推断能力 ($K = 0$ 即单字段)

原图: DNN_Aggesvation100/figures/fig2_profile_cases.png

- PJM 风电出力单独只能推出总发电 0.06；攻击者另有风电占比时，推断能力达到 0.76（总发电 = 出力 ÷ 占比）。
- CAISO 实时 NP15 电价单独推 SP15 阻塞价只有 0.04，配上 SP15 电价后 0.38（阻塞分量 ≈ 节点价差）。
- 只按单字段定级，这些字段都会被判为“低风险”。

2.3 现有做法二：IGNN——考虑了推断，但是黑盒

IGNN (Hu 等, IEEE Trans. Smart Grid 2026) [3] 是电力领域最接近的工作，目标同样是“考虑数据推断泄露的字段敏感度评估”。

做法：每个字段的最终敏感度由“固有敏感度”和“从邻居传播来的敏感度”聚合得到：

$$s_i = \Phi\left(s_i^{\text{int}}, \sum_{v_j \in \mathcal{N}(v_i)} w_{ji} s_j\right).$$

分三个阶段：

1. **固有敏感度：**机密字段直接标为 1；一般字段由层次分析法（AHP）按专家打分的判断矩阵给出初值；
2. **推断关系图：**字段为节点。模型驱动的边来自潮流方程等物理关系（有向，权重 1）；数据驱动的边来自相关系数（无向，权重为相关系数）；
3. **图聚合：**以初始敏感度为节点特征，用带推断权重的图注意力网络（GAT）聚合，训练时只监督机密节点（敏感度 = 1）。

评价方式：按输出的敏感度把一般字段分成低、中、高三组，分别用来推断机密字段，比较推断准确率（高风险组最高 0.9145）。

存在的问题（此前整理过）：

- **敏感度没有真值定义**：输出的 0—1 分数到底是什么，论文没有定义，也无法用攻击实验直接复核；
- **监督目标退化**：只监督本来就是 1 的机密节点，一般字段的分数只是网络结构、初值和传播共同诱导出的自由变量；消融实验显示主要起作用的是 AHP 专家初值；
- **无法表达联合推断**：推断关系被简化为字段两两之间的边，“两个字段合起来才能推出来”的情形表达不了；相关系数是对称的，而推断能力不对称；
- 它的评价标准其实是在衡量**推断能力**，而不是它声称的“融合风险”。

2.4 我们的思路

思路：字段风险从集合风险里“算出来”

1. **集合风险有明确含义**： $V(S)$ 就是攻击者拿到 S 后能推出多少，每个数都能用攻击实验复核；
2. **考虑所有集合**：组合推断、冗余、间接推断都包含在“所有集合的风险”里，不需要人为画边；
3. **用恰当的定义把集合风险归结到字段**：得到的字段风险继承集合风险的含义，可以解释（“在什么背景下危险”）、可以检验；
4. **通用模型是遍历集合风险的工具**：要考虑大量集合，逐个重训太慢，这正是通用模型的用处。

这样一来，通用模型在故事里有了明确的位置，而“字段风险”成为论文主线。剩下的关键问题是第 3 步：**用什么定义把集合风险归结到字段？**

3 从集合风险到字段风险：候选定义

3.1 我们希望字段风险满足什么

表 1: 字段风险应满足的要求

要求	含义
可用攻击检验	数值能通过重训攻击者复核，而不是专家打分或网络输出
考虑联合推断	能反映“单独无用、组合危险”
最坏情形	安全场景关心的是“最危险时有多危险”，而不是平均
冗余不稀释	多发几个副本，不能让每个字段的风险变低
有限背景	攻击者掌握的其他信息是有限的，可以作为参数设定
公开基底	已经必须公开的字段，风险应在它们之上计算

下面用一个 3 字段小例子贯穿比较（讲 Shapley 时再加一个副本变成 4 字段）。目标为 PJM 计量负荷，数值取自 98 号真值（取整，作示意）：

表 2: 示意小例子： L = 负荷预测， W_1 = 风电出力， W_2 = 风电占比

集合 S	$\{L\}$	$\{W_1\}$	$\{W_2\}$	$\{W_1, W_2\}$	含 L 的集合
$V(S)$	0.99	0.06	0.15	0.83	0.99

另有 $V(\emptyset) = 0$ 。负荷预测一个字段就几乎完全暴露负荷；两个风电字段单独都很弱，合起来能推出 0.83，是一条“备用推断通道”。

3.2 候选一：Shapley 值

来源。 Shapley 值来自合作博弈论 (Shapley 1953) [4]： n 个玩家合作得到总收益 $v(F)$ ，如何“公平”地分给每个人。放到我们的问题里，玩家是字段，收益是推断能力： $v(S) = V(S)$ 。

原理：用 3 字段例子一步步算。 Shapley 的思路是：把所有字段随机排一个顺序依次加入，记下每个字段加入时带来的**边际增益**（加入后的 V 减去加入前的 V ），再对所有顺序取平均。3 个字段共有 $3! = 6$ 种顺序：

表 3: 3 字段例子：每种加入顺序下各字段的边际增益

加入顺序	L 的边际	W_1 的边际	W_2 的边际	每行之和
$L \rightarrow W_1 \rightarrow W_2$	0.99	0	0	0.99
$L \rightarrow W_2 \rightarrow W_1$	0.99	0	0	0.99
$W_1 \rightarrow L \rightarrow W_2$	0.93	0.06	0	0.99
$W_1 \rightarrow W_2 \rightarrow L$	0.16	0.06	0.77	0.99
$W_2 \rightarrow L \rightarrow W_1$	0.84	0	0.15	0.99
$W_2 \rightarrow W_1 \rightarrow L$	0.16	0.68	0.15	0.99
平均 = Shapley 值	0.678	0.133	0.178	0.99

例如第 4 行：先加 W_1 ， V 从 0 到 0.06；再加 W_2 ，从 0.06 到 0.83， W_2 的边际为 0.77；最后加 L ，从 0.83 到 0.99， L 的边际为 0.16。

把“对顺序平均”写成对集合求和，就是一般公式：

$$\phi_i = \sum_{S \subseteq F \setminus \{i\}} \frac{|S|!(n-|S|-1)!}{n!} [v(S \cup \{i\}) - v(S)],$$

其中权重 $\frac{|S|!(n-|S|-1)!}{n!}$ 就是“随机顺序中，排在 i 前面的恰好是 S ”的概率。

公理。 Shapley 值是唯一同时满足以下四条的分配方式（上表中都能看到）：

- **效率：** $\sum_i \phi_i = v(F) - v(\emptyset)$ ，全部收益恰好分完（每行之和都是 0.99，平均后也是）；
- **对称：** 贡献完全相同的两个字段分到相同的值；
- **虚拟：** 对任何集合都没有贡献的字段分到 0；
- **可加：** 两个博弈相加，Shapley 值也相加。

问题一：协同通道被平均掉。 看 W_1 那一列：它只有在“ W_2 已经在、 L 还没来”的第 6 行才有大增益 0.68；在 L 已经先加入的 3 行里增益为 0。6 行平均下来只有 0.133。

但对防护来说，恰恰要问的是：**负荷预测不发布的时候，还剩什么推断通道？** 答案是两个风电字段合起来能推出 0.83。Shapley 用平均把这条备用通道“藏”掉了，因为在大多数顺序里负荷预测排在前面，已经把风险“领走”了。

问题二：冗余被稀释（4 字段例子）。 再加入一个与负荷预测完全相同的副本 L' （例如同一个预测值以另一个字段名发布），字段变为 4 个，共 $4! = 24$ 种顺序。按各字段边际增益的取值统计：

表 4: 4 字段例子 (加入副本 L'): 24 种顺序中各边际增益出现的次数

字段	边际增益: 出现次数	说明	Shapley
L	0: 12 次; 0.99: 6; 0.93: 2; 0.84: 2; 0.16: 2	L' 排在前面的 12 种顺序里 L 没有贡献	0.408
L'	与 L 完全相同 (对称)		0.408
W_1	0: 16 次; 0.06: 6; 0.68: 2	前面有 L 或 L' 的顺序更多了	0.072
W_2	0: 16 次; 0.15: 6; 0.77: 2	同上	0.102

- 效率公理要求总和仍是 0.99, 于是 L 和 L' 平分: 每份从 0.678 降到 **0.408**; 加两个副本时每份降到 **0.292**。
- 攻击者拿到 L 或 L' 中任意一个, 都能推出 0.99, 风险并没有变小。但在 Shapley 下, 发布方只要多发几个副本, 就能把每个字段的风险分数“做低”。
- 风电字段也被连带稀释 ($0.133 \rightarrow 0.072$), 因为前面已有负荷类字段的顺序更多了。

顺带: LOCO 的问题更极端。 LOCO (Leave-One-Covariate-Out, Lei 等 2018[8]) 用“从全集删掉字段 i 的损失” $v(F) - v(F \setminus \{i\})$ 衡量重要性; 置换重要性 (Breiman 2001[9]) 打乱字段 i 的取值, 思想相同。在 3 字段例子中, W_1 、 W_2 的 LOCO 都是 0; 加了副本之后, L 的 LOCO 也变成 0, 因为删掉一个还有另一个。

表 5: 两个例子的汇总 ($M^{(1)}$ 的定义见 3.4 节, 这里先理解为“在最坏的 1 个背景字段下, 公开字段 i 带来的增益”)

字段	单字段	Shapley		LOCO		$M^{(1)}$ 两种都一样
		3 字段	加副本	3 字段	加副本	
L 负荷预测	0.99	0.678	0.408	0.16	0	0.99
W_1 风电出力	0.06	0.133	0.072	0	0	0.68
W_2 风电占比	0.15	0.178	0.102	0	0	0.77

Shapley 在机器学习中的使用: 同一个分配公式, 不同的“价值函数”。 Shapley 公式本身只需要两样东西: 谁是玩家、 $v(S)$ 是什么。机器学习里几类以 Shapley 命名的方法用的是完全相同的公式, 区别只在 $v(S)$ 的定义, 而 $v(S)$ 决定了算出来的数是什么含义:

表 6: 机器学习中三类 Shapley 方法：公式相同，价值函数不同

方法	价值函数 $v(S)$	$\sum_i \phi_i$ 等于	回答的问题
SHAP [5]	一个 训练好的模型 f ，对某一个样本 x ，这个样本的预测值只知道 S 中字段的取值时的期望预测 $\mathbb{E}[f(X) \mid X_S = x_S]$	平均预测值	模型对 这个样本 的预测，各字段贡献多少（局部解释）
SAGE [6]	同一个 训练好的全量模型 ，只给它 S 中的字段（其余按分布积分掉）时，在整个数据集上的 损失下降	全量模型的总预测能力	模型在整体上 依赖 哪些字段（全局解释）
SPVIM [7]	只用 S 中的字段 重新训练 一个最优模型能达到的预测能力（如 R^2 ）	全部字段的可预测性 $V(F)$	数据中的可预测性，各字段占 多少份额

- SHAP 和 SAGE 都是在一个**固定的模型**上算的，回答“模型用了谁”。模型训练时碰巧选中了哪个字段，分数就集中到哪个字段，其余可替代的字段会被判为不重要。
- SPVIM 对每个子集重新训练，回答“只拿这些字段能推出多少”，这和攻击者的做法一致，**与我们的 $V(S)$ 是同一口径**。在通用模型上算 Shapley，其实就是 SPVIM 的思路，只是用通用模型代替了逐个重训。
- 两类结果差别很大：98 号在精确博弈上比较，全量模型 SAGE 与“重训口径的 Shapley”的排序 Kendall τ 只有 0.59，二阶交互的一致性只有 0.03。所以即使用 Shapley，也只能用 SPVIM 这一类。

为什么考虑过它。 当时的一个方案是：通用模型给出 $V(S)$ ，再用 Shapley 值分解成字段贡献，用 Shapley 交互分析字段之间的协同。98 号验证了**在通用模型上 Shapley 值可以算得很准**（精确枚举时与真值的 Kendall τ 约 0.89）。所以问题不在算不算得准，而在上面说的**语义**：Shapley 是“公平分摊”，而风险需要“最坏情形、不分摊”。




图 2: 98 号：真实数据 (PJM 14 字段精确博弈，目标计量负荷) 上 Shapley 值 (蓝)、单字段 (灰) 与背景最大边际 (橙) 的对比

原图：DNN_Aggesvation98/figures/fig3_shapley_vs_risk_semantics.png




图 3: 99 号：给负荷预测加入精确副本，Shapley 被持续稀释， $M^{(1)}$ 与单字段能力不变

原图：DNN_Aggesvation99/figures/fig3_copy_dilution.png

真实数据上同样如此。 负荷预测加 4 个副本后，Shapley 从 0.223 降到 0.114，原字段加全部副本的 Shapley 之和也只有 0.57；而 $M^{(1)}$ 始终是 0.991。CAISO 上复现了同样的现象：


图8 CAISO 对照博弈（14 字段全枚举）：强字段 Shapley 仅为单字段能力的 12-23%，删除边际 ≈ 0 ；全量模型 SAGE 集中到被模型选中的一两个替代字段

图 4: 100 号：CAISO 14 字段精确博弈。强字段的 Shapley 只有单字段能力的 12%—23%，全集删除边际约为 0；全量模型 SAGE 集中到模型碰巧选中的一两个替代字段

原图：DNN_Aggresvation100/figures/fig8_caizo_redundancy_control.png

结论：Shapley 回答的是“全部风险怎样公平分摊”，而数据安全要问的是“在某个背景下公开这个字段，风险**最多**增加多少”。前者要求分完、取平均；后者要求不分摊、取最坏。所以 Shapley 可以作为“份额解释”的辅助，但不适合作为风险分级的依据。

3.3 候选二：MCI (Catav 等, ICML 2021)

动机。 Catav 等 [10] 指出的正是上面的问题：Shapley 在相关、重复特征下系统性低估。他们的例子是 $Y = f_1 \wedge (f_2 \vee f_3)$ ：把 f_1 复制 3 份， f_1 的 Shapley 从 0.65 降到 0.15。他们的目标是解释**数据**（哪些特征与结果有关），而不是解释某个模型。

定义。 给定单调不减、 $\nu(\emptyset) = 0$ 的评价函数 ν ，特征 f 的**边际贡献特征重要性** (Marginal Contribution Feature Importance) 为

$$I_\nu(f) = \max_{S \subseteq F} [\nu(S \cup \{f\}) - \nu(S)],$$

即在**所有可能的背景**中，加入 f 带来的**最大增益**。取到最大值的 S 称为 context，用来解释“ f 在什么情况下最重要”。 ν 采用 Covert 等 2020 的“通用预测能力”：对每个子集重新拟合模型后的损失下降（实验中用逐子集重训模型的测试或交叉验证性能）。这与我们的 $V(S)$ 是**同一口径**。

公理与唯一性。 MCI 由三条公理刻画：

- **边际贡献：** $I(f) \geq \nu(F) - \nu(F \setminus \{f\})$ ，重要性不低于“全集中删掉它的损失”；

- **消去**：从数据中删去一些特征，其余特征的重要性不会增加；
- **最小性**：在满足前两条的函数中取最小的。

定理： ν 单调时，MCI 是唯一满足这三条公理的函数。

主要性质。

- **单字段下界**： $I(f) \geq \nu(\{f\})$ ；
- **复制不变**：加入或删除副本，不改变其他特征的 MCI，副本自身也不被稀释；
- **超效率**：对任意集合 S ， $\nu(S) \leq \sum_{f \in S} I(f)$ ，字段分数之和是集合价值的上界（Shapley 只保证全集上相等）；
- 以及虚拟、对称、次可加。

计算。 精确计算需要遍历所有背景，是指数级的；任何采样方法都只能得到**下界**。实验中用 2^{14} — 2^{15} 个随机排列的前驱集合来估计。

小例子上的结果。 3 字段例子中， $I(L) = 0.99$ （空背景）， $I(W_1) = 0.68$ （背景 $\{W_2\}$ ）， $I(W_2) = 0.77$ （背景 $\{W_1\}$ ）；加入副本 L' 后都不变， $I(L') = 0.99$ 。取最大而不是平均，所以协同通道不会被平均掉；不要求分完，所以副本不会被稀释。方向正确。

直接用于数据安全的不足。

- **背景不受限**：最坏背景可以是“除它以外的全部字段”，相当于假设攻击者什么都知道。这既不现实，也无法计算（ 2^{n-1} 个背景），更难以用重训去认证；
- **没有公开基底**：实际中有些字段已经按规则必须公开，风险应该在它们之上计算；
- **没有安全语义**：MCI 是解释工具，没有和阈值、放行、关键字段这些决策概念联系起来；
- **单调性假设**：经验攻击能力（有限样本、有限次训练）并不严格单调，需要处理。


3.4 我们的定义：背景受限的最大边际推断能力 $M^{(K)}$

定义。 目标 y ，公开基底 B （已经必须公开的字段），候选字段集合 H ，背景预算 K ：

$$M_i^{(K)} = \max_{T \subseteq H \setminus \{i\}, |T| \leq K} \left[\bar{V}(B \cup T \cup \{i\}) - \bar{V}(B \cup T) \right].$$

- **含义**：攻击者除公开基底外最多另外掌握 K 个字段时，公开字段 i 最多能让推断能力增加多少。

- **见证背景**：取到最大值的 T^* ，说明“在什么情况下这个字段最危险”，即 MCI 的 context。
- **单调闭包** $\bar{V}(S) = \max_{T \subseteq S} V(T)$ ：攻击者拿到 S 后，可以只用其中一部分字段。真值上约 7%—9% 的集合非单调，不做闭包，下面的安全定理就不成立。
- **特殊情形**： $K = 0$ 即单字段能力； $K \geq |H| - 1$ 且 $B = \emptyset$ 时就是 MCI。

图1 $v(S) \rightarrow$ 条件边际 $\rightarrow$ 四种字段量：数学关系与安全语义总览图 5: 99 号： $V(S)$ 、条件边际与几种字段量（单字段、 $M^{(K)}$ 、协同、Shapley）之间的数学关系与安全语义

原图：DNN_Aggresvation99/figures/fig1_relation_map.png

与 MCI 的关系。 令 $v_B(T) = V(B \cup T) - V(B)$ ，它满足 MCI 对评价函数的全部假设，而 $M^{(K)}$ 就是 v_B 上背景规模不超过 K 的 MCI。因此 MCI 的性质（单字段下界、复制不变、见证背景等）直接继承，引用而不作为本文创新。

表 7: 继承、新增与需要证明的内容

继承自 MCI	本文新增	本文证明的新结论
最大边际与见证背景	背景预算 K (攻击者知识上限)	截断的预算不等式
单调、 $V(\emptyset) = 0$	公开基底 B	通用安全余量
单字段下界、复制不变	阈值、余量、关键性等安全语义	τ -关键 $\Leftrightarrow$ 属于小的最小不安全集合
Shapley 在副本下被稀释	经验攻击能力的单调闭包	估计误差传播与上下界 $L \leq M \leq U$

三条安全语义 (前提是 $\bar{V}$ 单调):

1. **余量**: 只要攻击者的背景不超过 K 个字段, 公开 i 最多让推断能力增加 $M_i^{(K)}$ 。所以背景的推断能力只要比阈值低 $M_i^{(K)}$ 以上, 公开 i 就一定不越线;
2. **关键性**: 存在大小不超过 K 的背景使 i 越过阈值 τ , 当且仅当 i 属于某个大小不超过 $K+1$ 的最小不安全集合;
3. **预算**: 任何不超过 $K+1$ 个字段的集合 A , 都有 $V(B \cup A) - V(B) \leq \sum_{i \in A} M_i^{(K)}$ 。这是 MCI 超效率的截断版, 可以直接用字段分数给集合定上界, 用于发布审查。

3.5 各定义的对比

表 8: 各类字段风险度量满足的要求 (✓ 满足, ◦ 部分满足, — 不满足)

方法	可用攻击检验	联合推断	最坏情形	冗余不稀释	有限背景	公开基底
相关系数 / 互信息	—	—	—	✓	—	—
单字段重训 $M^{(0)}$	✓	—	—	✓	—	◦
推断图传播 (IGNN)	—	◦	—	◦	—	—
Shapley / SAGE	✓	✓	—	—	—	—
LOCO / 置换重要性	✓	✓	—	—	—	—
MCI	✓	✓	✓	✓	—	—
$M^{(K)}$ (本文)	✓	✓	✓	✓	✓	✓

4 初步验证 (99—101 号)

4.1 理论命题在真值上成立 (99 号)

在 98 号的两个精确博弈 (12、14 个字段, 全部 2^p 个集合都有重训真值) 上逐条检验:

表 9: 命题核验 (gameA / gameB)

命题	结果
$M^{(1)} = a_i + \max(0, \max_j I_{ij})$	偏差 0 / 0
预算不等式 $V(A) \leq \sum_{i \in A} M_i^{(K)}$	违例 0 / 0
关键性 $\Leftrightarrow$ 小的最小不安全集合	原始 V 上 0.2% 不一致; 闭包 $\bar{V}$ 上 0
$M^{(K)}$ 对 K 单调	违例 0 / 0

此外, 在随机 3、4 人博弈上暴力搜索反例, 修正了初稿中三处过强的表述 (例如“增强为 0 当且仅当次模”不成立)。

4.2 K 取多大 (100 号)

去掉别名后 PJM、CAISO 各 41 个字段、12 个目标，用并行专用重训精确计算规模不超过 4 的全部 112,791 个集合。MCI 用通用模型搜索大背景，再用重训认证给出下界。




图 6: 100 号：推断升级曲线（左）与饱和比 $M^{(K)}/MCI$ 已认证下界（右）

原图：DNN_Aggresvation100/figures/fig1_escalation_saturation.png

表 10: 饱和比（均值 / 中位数）				
	$K = 0$	$K = 1$	$K = 2$	$K = 3$
PJM	0.39 / 0.35	0.71 / 0.75	0.88 / 0.93	0.999 / 1.00
CAISO	0.51 / 0.52	0.81 / 0.85	0.93 / 0.97	0.999 / 1.00

- 单字段能力 ($K = 0$) 平均只有完整风险的 35%—50%，大部分风险来自背景，这也印证了第 2 节的判断。
- $K = 2$ 已接近饱和， $K = 3$ 基本饱和；更大的背景（平均 5 个字段）只让 0.2% 的条目再增加超过 0.02。所以背景不必无限，主口径取 $K = 2$ 。

4.3 换到独立数据还成立吗 (101 号)

同一份数据上既找最坏背景又报告数值，会因为取最大值而偏高。101 号把数据对半分，一半用于发现、另一半用于认证（3 次随机对半 $\times$ 2 个方向）。

图1 101号独立认证 (discovery / audit 完全不相交, 3次随机对半 × 2 方向, 误差条为 95% t 区间)




图 7: 101 号: 发现 / 认证完全分离后的结果

原图: `DNN_Aggesvation101/figures/fig1_independent_certification.png`

- 取最大值的偏高确实存在: PJM $K = 2$ 约 0.051 ± 0.016 , CAISO 约 0.023 ± 0.013 。所以报告的 M 数值要用独立认证值, 或者标注偏差量级。
- 结论层面基本保住: $\tau = 0.7$ 时, 关键字段在独立数据上召回 87% (PJM) / 93% (CAISO); 强交互复现 71% / 95%。

4.4 一个伏笔

41 个字段、 $K = 2$ 的全部 11,521 个集合, GPU 并行重训约 11 分钟就能精确算完。所以在这个规模上, 通用模型还不是必需的; 它的价值要到更大的 K 、更多字段、反复换基底或换目标时才体现出来 (第 3、5 次汇报)。

5 小结与下一次

小结

- 通用模型需要一个进一步的产物。我们选择**字段级推断风险**：单字段口径会漏掉组合推断，IGNN 这类黑盒分数没有可检验的含义；从“所有集合的推断能力”出发归结到字段，既可解释、可检验，又用上了通用模型。
- 归结方式上，Shapley 的“平均分摊”会稀释冗余、平均掉协同通道；MCI 的“最坏背景最大边际”方向正确，但背景不受限、缺少安全语义。
- 因此提出 $M^{(K)}$ ：有限背景、相对公开基底、单调闭包，并有余量、关键性、预算三条安全语义；初步验证显示 $K = 2$ 接近饱和，独立数据上结论基本成立。

下一次：用正式口径（多攻击器、单调闭包）算出完整风险表，回答“ $M^{(K)}$ 比现有字段打分方法多看到了什么，对发布决策有什么用”。

参考文献

- [1] 国家市场监督管理总局, 国家标准化管理委员会. GB/T 43697—2024 数据安全技术数据分类分级规则, 2024.
- [2] 国家能源局. 电力市场信息披露基本规则（国能发监管〔2024〕9号）, 2024.
- [3] B. Hu, R. Nie, Y. Zhou, et al. IGNN: An inference graph neural network for data sensitivity assessment considering data inference leakage in cyber-physical power grid. IEEE Transactions on Smart Grid, 2026 (early access, doi:10.1109/TSG.2026.3667966).
- [4] L. S. Shapley. A value for n-person games. Contributions to the Theory of Games, 2(28): 307–317, 1953.
- [5] S. M. Lundberg, S.-I. Lee. A unified approach to interpreting model predictions. NeurIPS, 2017.
- [6] I. Covert, S. M. Lundberg, S.-I. Lee. Understanding global feature contributions with additive importance measures (SAGE). NeurIPS, 2020.
- [7] B. D. Williamson, J. Feng. Efficient nonparametric statistical inference on population feature importance using Shapley values (SPVIM). ICML, 2020.
- [8] J. Lei, M. G'Sell, A. Rinaldo, R. J. Tibshirani, L. Wasserman. Distribution-free predictive inference for regression (LOCO). JASA, 113(523): 1094–1111, 2018.
- [9] L. Breiman. Random forests. Machine Learning, 45: 5–32, 2001.
- [10] A. Catav, B. Fu, Y. Zoabi, et al. Marginal contribution feature importance – an axiomatic approach for explaining data. ICML, PMLR 139: 1324–1335, 2021.