

第 2 次组会汇报

$M^{(K)}$ 比现有做法多看到了什么

对应工作：103—106、108、109、117 号实验

本次要点

1. 先把“攻击者能推出多少”的口径定死：**三种攻击器取最大 + 单调闭包**。只用一个 DNN 会低估。
2. 完整风险表显示，只看单字段时， $\tau = 0.7$ 下关键条目仅占 2%—4%；允许 2 个背景字段后升到 50%—68%。
3. 与相关系数、SAGE、LOCO、推断图等现有打分相比， $M^{(2)}$ 不会漏掉协同、冗余和间接三类结构；决策上，单字段规则**只找到 13%—17% 的关键字段**。
4. 落到发布审查：单字段规则会放行 19% / 56% 的危险集合，按 M 做预算则**零危险放行**。
5. 两条诚实的边界：单字段推断能力做粗排并不差； $M^{(K)}$ 是最大值统计量，小样本和弱攻击者都会让结论出偏。

1 正式口径：攻击者能推出多少（103 号）

真值 $V(S)$ 由三种攻击器（单目标 DNN、多目标 DNN、梯度提升树）逐集合专用训练得到，在验证集上选最强的一个，再做单调闭包。

图3 正式攻击器族：规模越大，树模型越常胜出；只用一个 DNN 会低估 0.005-0.027




图 1: 103 号：各攻击器被选中的占比（左），以及只用一个 DNN 时的低估幅度（右）

原图：DNN_Aggesvation103/figures/fig3_attacker_share.png

- 集合规模为 3 时，梯度提升树被选中 55% (PJM) / 43% (CAISO)，多目标 DNN 只占约 10%。
- 只用一个 DNN 会让 V 低估 0.005—0.027，且集合越大低估越多。100 号及之前的数值因此偏低，后面一律使用本口径。

2 完整风险表：风险主要来自背景（104 号）

PJM、CAISO 各 41 个字段 × 12 个目标， $K = 0, 1, 2$ 全部精确计算。

图3 背景预算的实际意义：多数字段在拿到 1-2 个辅助字段后风险明显上升




图 2: 104 号：正式真值下的推断升级曲线

原图：DNN_Aggesvation104/figures/fig3_escalation_official.png

表 1: $\tau = 0.7$ 时的关键（字段，目标）条目（共 492 条）

	$K = 0$ （只看单字段）	$K = 1$	$K = 2$
PJM	11（2.2%）	115	337（68%）
CAISO	18（3.7%）	137	246（50%）

每个关键条目都带有见证背景，例如：

表 2: 见证背景示例（精确真值）

目标	字段	$M^{(0)}$	$M^{(1)}$	见证背景	机制
PJM 总发电	风电占比	0.162	0.871	风电出力	总发电 = 出力 ÷ 占比
PJM 总发电	光伏出力	0.033	0.643	光伏占比	同上
CAISO 实时 SP15 阻塞价	实时 NP15 电价	0.040	0.406	实时 SP15 电价	阻塞 $\approx$ 节点价差
CAISO 实际负荷	南区负荷计划	0.319	0.635	SP15 光伏预测	净负荷关系

3与现有字段打分方法对比（105、117号）

3.1 机理：三类方法各有盲区

构造一个结构已知的小例子 $Y = a \cdot A \cdot B + b \cdot P + \text{噪声}$ ： A 、 B 协同（单独无用）， C_1 、 C_2 是 P 的两个带噪副本（冗余）， D 是间接字段（ $A + B$ 为 0.54，加上 D 后为 0.73，越过 0.7）。




图 3: 117 号：各方法在协同、冗余、间接字段上的分数（63 个集合全部重训）

原图：DNN_Aggesvation117/figures/fig1_toy_mechanism.png

- 相关系数、单字段能力、推断图（成对边）**看不见协同**： A 、 B 都是 0。

- LOCO、置换重要性、SAGE 在全字段模型上计算，冗余字段互为替身 (C_1 的 LOCO 为 0.01)，间接字段 D 被掩盖为 0。
- $M^{(2)}$ 在三类结构上都给出正确的量级。

3.2 检测关键字段：单字段推断能力是强基线

图1 RQ-B1：模型依赖型指标（SAGE/置换重要性）明显最差；关联指标次之；单字段精确 R^2 是很强的基线，M 的增益在 CAISO 明显、PJM 边际




图 4: 105 号: $\tau = 0.7$ 、 $K = 2$ 下检测关键字段的 PR-AUC

原图: DNN_Aggregation105/figures/fig1_baseline_pr.png

对本文不利的结果，如实报告：只做“排序”时，单字段重训能力 $M^{(0)}$ 在 PJM 上的 PR-AUC 为 0.877，与 $M^{(2)}$ 持平；只有在 CAISO 上 M 明显更好 (0.764 $\rightarrow$ 0.829)。原因是单字段能力为 0.6 的字段，加一个背景就容易越过 0.7。所以论文不能说“单字段分析完全看不到组合风险”。准确的说法是：单字段能力能粗排出“可能危险的字段”，但给不出危险有多大、在什么背景下危险、是否已越过阈值。模型归因类方法（SAGE、置换重要性）最差。

3.3 决策层面：差距才真正拉开

117 号在 10 个目标（第 3 次汇报会介绍的五组数据）上比较“按规则定出的关键字段”与“扣留字段后还剩多少危险组合”。

图2 决策层面的对比 (10 个目标平均; 选择只用估计值, 真值只用于评价)




图 5: 117 号：关键字段召回（左）与扣留后仍未打破的危险组合（右）。估计器为当时版本，最终版数字见第 5 次

原图: DNN_Aggresvation117/figures/fig2_decision_disposal.png

- 现行的单字段定级规则只召回 **13%** ($\tau = 0.5$) / **17%** ($\tau = 0.7$) 的关键字段。
- 按单字段定级扣留，扣得少，但 **98.2%** / **95.5%** 的危险组合仍未被打破；按 $\hat{M}^{(2)}$ 自适应扣留，只多扣约 1 个字段，残余危险组合降到 2% 左右。

4 落到发布审查 (106 号)

随机抽 2,000 个规模为 3 的待发布集合， $\tau = 0.7$ ，用正式真值判断它们实际是否安全。


图1 发布审查 (随机 2,000 个规模 3 的待发布集合, $\tau=0.7$)：单字段规则放行 19%/56% 的危险集合；M 预算规则零危险放行

图 6: 106 号：各审查规则的危险放行率（左）与误拒率（右）

原图: DNN_Aggresvation106/figures/fig1_release_audit.png

表 3: 发布审查结果 (PJM / CAISO)

审查规则	危险放行	误拒
单字段能力 $\leq \tau$ 即放行	19.1% / 56.4%	0 / 0
通用模型直接估计 $\hat{V}(A) \leq \tau$	6.6% / 2.6%	0 / 0
逐阶预算 $U^{(2)} \leq \tau$	0 / 0	50% / 33%
精确 M 预算 $\sum M^{(2)} \leq \tau$	0 / 0	86% / 74%

- 这是最直接的安全论据：按 M 做预算有理论保证（第 1 次的预算定理），**零危险放行**。
- 逐阶预算 $U^{(2)}$ 是实用的折中：仍然零危险放行，误拒从 86% / 74% 降到 50% / 33%。
- 由此得到两级流程：先用逐阶预算快速放行，没通过的再用直接估计加重训认证复核。

5 两条边界

5.1 用估计值判定时要给区间（108 号）

用通用模型估计的 $\hat{M}$ 做点判定，PJM $K=2$ 、 $\tau=0.7$ 时关键字段召回只有 0.754。改为区间 $[L, U]$ ：下界 L 取前 3 个候选见证背景的重训值，上界 U 用留一字段校准的分位数。然后做保守判定。

图2 区间保守判定把 τ -critical 漏判基本消除：PJM $\tau=0.7$ 的 recall 0.754 $\rightarrow$ 0.994，代价是 precision 0.99 $\rightarrow$ 0.87
安全语义上这是正确方向（宁可误报不可漏报）；precision 的下降由后续重训认证复核吸收




图 7: 108 号：点估计与区间保守判定的对比

原图：DNN_Aggresvation108/figures/fig2_critical_interval.png

召回从 0.754 升到 0.994，代价是精确率从约 0.99 降到 0.87（误报交给重训认证复核）。 $\tau=0.9$ 时精确率明显下降，需要单独说明。

5.2 攻击者能力的假设很关键（109 号）

让攻击者只拿到 10%—50% 的带标签辅助数据：

- 推断能力下降有限：只用 10% 数据，三字段组合的平均 V 只下降 10%—19%。**数据少并不是有效的防护。**
- 反直觉的是，小样本下 $M^{(2)}$ 反而比全量高 5%—12%。原因是 $M^{(K)}$ 是**最大值统计量**：候选背景越多（ $K = 2$ 时有 821 个），越容易挑中正噪声（winner's curse）。
- 审计方如果按弱攻击者评估，会单向漏判：按 10% 数据评估并放行时，PJM 在 $\tau = 0.5$ 下有 **25.6%** 的危险集合被放行。

图4 $M^{(K)}$ 是最大值统计量：小样本下取 max 会系统性挑中正噪声（winner's curse），候选背景数越多（ K 越大）正偏越强——这是 108 号「认证下界 + 区间」口径的第二个独立理由




图 8: 109 号：选择增益随候选背景数增大（左）； $K = 2$ 的偏差分解（中）；小样本挑出的见证背景大多是噪声（右）

原图：DNN_Aggresvation109/figures/fig4_winners_curse.png

结论：审计必须假设最强的攻击者（攻击器族取最大）；报告 M 数值时优先用重训认证过的下界，而不是估计值取最大后的结果。

6 小结与下一次

小结

- $M^{(K)}$ 的价值主要不在排序，而在**决策**：它能说出危险有多大、在什么背景下危险、是否越线，并带有零危险放行的保证。
- 单字段规则只找到 13%—17% 的关键字段，并放行 19% / 56% 的危险集合。
- 使用时要注意：给区间而不是点估计；按最强攻击者审计；数值要考虑取最大值带来的偏高。

下一次：前面都是 PJM、CAISO 的系统级字段。下一次换到真实电力场景（标准算例、澳洲 NEM 的真实机组、按披露时点重新定义的 PJM / CAISO），看组合风险是否依然存在、有多大。