

第 5 次组会汇报

估计器：预学习几乎没用，为什么，怎么改

对应工作：115、116、118、122、125 号实验

本次要点

1. 先修了一个数值缺陷：读出层特征标准化的下限只有 10^{-8} ，在真实数据上个别集合预测爆掉， M 被高估。修正后 NEM 的 $M^{(2)}$ 偏差从 $+0.110$ 降到 -0.016 。
2. 消融实验发现：**随机初始化、完全不训练的主干**加上同样的读出，与掩码预训练过的主干**几乎一样好**。起决定作用的是“逐子集闭式读出”。
3. 诊断出三层原因：只预测目标会让**表征塌缩**；在审计用到的小集合上，**随机特征本来就够用**； M 取最大值，对少数读出**爆掉极敏感**。
4. 改进：预训练时**加上重建被遮住的列**，与随机主干拼接，并把预测截断到训练目标的取值范围。最终估计器 C3 的 $M^{(2)}$ 误差降 29%， V 误差降 32%，没有一项指标变差；下游结果全部重算。

1 估计器是什么，为什么需要它

第 1、3 次提到：41 个字段、 $K = 2$ 用并行重训十几分钟就能精确算完；但 $K = 3$ 时 CAISO 每个目标要算 52,360 个集合，换基底、换目标定义时还要反复重算，所以需要“一次训练、任意集合秒级查询”的估计器。




图 1: 论文中的估计器结构（最终版，已包含本次的改进）：(a) 掩码预训练一次；(b) 每个查询集合在冻结特征上做闭式岭回归读出；(c) 扫描—认证

原图: [paper/claude/V6_ieee/figures/fig3_model.png](#)

- 主干：3 层 $\times$ 256 的 MLP，输入 $[x \odot m, m]$ ，训练时随机遮住一部分字段（掩码），冻结最后一个隐层作为特征 ϕ 。
- 逐子集闭式读出：对查询集合 S ，在训练行上用 $[x_S, x_S^2, \phi(x_S)]$ 解一次岭回归，得到 $\hat{V}(S)$ 。
- 本次开始时的口径：预训练只预测目标；三个种子的特征拼接后读出一次。

2 第一个问题：真实数据上 M 被高估（115 号）

第 3 次汇报的 NEM 上，集合估计误差只有 0.011—0.018， $M^{(2)}$ 却被高估了 0.13—0.17。

定位：高估不是因为 $\hat{V}(T \cup i)$ 估高了，而是作为背景的 $\hat{V}(T)$ 被严重低估，甚至“崩成 0”。读出层做特征标准化时，标准差下限只有 10^{-8} 。训练集上近似常数的特征（死神经元）在测试集上稍有变化，就被放大成天文数字，预测爆掉。 M 对背景取最大，恰好挑中这些差分。

表 1: 115 号：NEM 崩溃集合上逐步修正

	仍然崩溃的集合	平均误差
原口径（标准差下限 10^{-8} ）	162	0.187
标准差下限 10^{-3}	42	0.105
+ 测试特征截断到训练集取值范围	3	0.035
+ 5 折交叉验证选 λ	1	0.026

同时把“三种子特征拼接”改为“三种子各自读出、预测取平均”（口径 E）：拼接会把维度推到 800 以上，放大数值问题。

表 2: 115 号：11 个目标平均

读出方式	$M^{(2)}$ 偏差	$M^{(2)}$ 误差	排序 Spearman	认证前 1
A 原口径（三种子拼接）	+0.029	0.051	0.891	0.798
E 数值修正 + 三种子预测平均	−0.018	0.020	0.970	0.940
NEM 单独：A → E	+0.110 → −0.016		0.742 → 0.962	0.500 → 0.920




图 2: 115 号：V 误差小不代表 M 误差小（左）；各读出方式的认证效率（右）

原图：DNN_Aggesvation115/figures/fig2_variant_summary.png

教训：估计器要按“**边际（差分）保真度**”来选，而不是集合值误差。V 的误差 88%—96% 是各集合共有的系统性低估，在差分 $V(T \cup i) - V(T)$ 中会抵消；决定 M 的是集合特有的误差，尤其是它的上尾。

3 第二个线索：主干里有大量死神经元（115、116 号）

各组主干原本只在本组的 15—24 个字段、1—2 个目标上预训练。改用**全列主干**（一次预训练、掩码重建全部 53 列）后：

图2 三种主干（读出方式相同）：本组主干 / 全列主干（一次预训练、任意目标复用） / 留目标主干（预训练时整列删去目标）；4 个目标平均




图 3: 116 号：三种主干的表征健康度、误差和扫描—认证效果（读出方式相同）

原图：DNN_Aggesvation116/figures/fig2_backbones.png

- 死神经元从 24.2% 降到 7.7%，有效维度从 1.45 升到 2.44，V 误差 $0.049 \rightarrow 0.040$ 。
- M 只略有改善 ($0.029 \rightarrow 0.026$)：更好的主干主要减小了共同偏差，而共同偏差在差分中本来就会抵消。

这提示：只服务少数目标的预训练，表征并不健康。

4 消融：预学习几乎没用（118 号）

在第 3 次的 10 个目标上，逐项替换估计器的组成部分：

图1 估计器对比与消融（10 个目标平均；黑点为各数据集平均；灰浅 = 无子集读出或无主干，灰深 = 单种子消融，蓝 = 本文）




图 4: 118 号：估计器对比与消融（10 个目标平均；黑点为各数据集平均；蓝色为本文）

原图：DNN_Aggesvation118/figures/fig1_variants.png

表 3: 118 号：关键消融（10 个目标平均，单种子）

估计方式	V 误差	$M^{(2)}$ 误差	排序 Spearman	认证前 1
线性读出（无主干）	0.212	0.144	0.737	0.803
共享输出头（主干直接输出，三种子）	0.067	0.057	0.930	0.883
随机初始化主干 + 读出	0.027	0.022	0.959	0.906
预训练不掩码	0.032	0.036	0.928	0.898
伯努利掩码	0.030	0.024	0.958	0.932
不做数值修正	0.031	0.036	0.904	0.825
本文 · 单种子（掩码预训练）	0.030	0.023	0.953	0.936

- **起决定作用的是逐子集闭式读出：**同一批主干，只把“直接输出”换成“按子集闭式读出”， $M^{(2)}$ 误差从 0.057 降到 0.021。共享输出头相当于假设攻击者拿到什么字段都用同一种组合方式，恰好抹掉了组合效应。
- **随机初始化、完全不训练的主干已经是很强的基线：** V 、 M 误差与预训练主干相当甚至略好，只在认证前 1 上稍差（0.906 对 0.936）。
- 掩码有必要（不掩码的预训练比随机主干还差），但掩码分布不关键（103 号：均匀、伯努利、不掩码的 $M^{(1)}$ 误差差别很小）。
- 对每个集合热启动微调整个网络（ ≤ 100 步），10 个目标中 9 个比闭式读出更差，还慢 3 倍以上。

这个结果有点反直觉：预训练花了功夫，却没比随机网络好多少。122 号专门回答两个问题：**为什么？能不能改好？**

5 为什么预学习几乎没用 (122 号)

5.1 原因一：只预测目标，表征塌缩

图1 只预测目标的掩码预训练使表征塌缩（有效维度 ≈ 1.6 ，随机初始化 ≈ 3.3 ），集合值精度与随机特征相当；加入被遮列重建后有效维度恢复 ≈ 2.75 ，V 误差降约 25%




图 5: 122 号：表征的有效维度（左）与集合值误差（中、右）

原图: DNN_Aggregation122/figures/fig1_collapse_and_V.png

- 只服务 1—3 个目标时，网络把隐层压到“平均意义下预测这几个目标”的一两个方向上：有效维度只有 1.60，随机初始化是 3.30。
- 改成小集合掩码 (small) 没有用，说明塌缩与掩码分布无关，是训练目标太窄。
- 加入“重建被遮住的候选列”后，有效维度恢复到 2.75，单种子 V 误差下降约 25%。

5.2 原因二：小集合上，随机特征本来就够用

图2 秩截断：预训练的前几个主方向与目标对齐 ($r=2$ 时误差约为随机特征的一半)，但读出的精度主要来自高维的其余方向——那里随机 ReLU 特征与只预测目标的主干一样好；重建的收益也在其余方向





图 6: 122 号：秩截断。只保留主干特征的前 r 个主成分再读出

原图: DNN_Aggregation122/figures/fig2_rank_truncation.png


- $r = 2$ 时，预训练主干的误差约为随机特征的一半：预训练确实学到了与目标对齐的主方向。
- 但用满 256 维后，只预测目标的主干约等于随机特征：闭式岭读出在 256 维随机 ReLU 特征上相当于一个核回归，对 ≤ 3 个字段、约 6,000 行的问题本来就够用。

图3 随机特征 $\approx$ 预训练只在审计用到的小集合上成立：规模 16 时重建主干的误差约为随机特征的 1/3图 7: 122 号: V 误差随集合规模的变化原图: DNN_Aggesvation122/figures/fig3_set_size.png

“随机特征 $\approx$ 预训练” 只在审计用到的小集合上成立：规模 16 时，随机特征的误差是重建主干的 3.3 倍。

5.3 原因三： M 取最大值，对读出爆掉极敏感

图4 M 是对背景取最大，误差由边际误差的上尾决定：未截断时重建主干的尖峰特征让少数读出错掉，上尾变长；加预测截断后上尾被切掉，只预测目标的主干不再有任何优势

图 8: 122 号: V 、边际 Δ 、边际误差上尾与 $M^{(2)}$ 的误差

原图: DNN_Aggesvation122/figures/fig4_V_vs_M_tail.png

- 重建主干把 V 和 Δ 的平均误差都压低了，但 M 是对背景取最大，由边际误差的上尾决定。
- 未截断时，重建主干只在 PJM 发电 / 联络线组上出问题：它学到了“尖峰探测”单元（来自厚尾的价格、备用列），少数测试行预测爆掉，背景的 $\hat{V} = 0$ ，以它为背景的价格字段 M 全部被高估（例：真值 0.07，估计 0.23）。
- 修复**：把预测截断到训练目标的取值范围（不看测试标签），对应“攻击者不会预测出从未见过的目标值”。

图5 重建主干唯一的失败 (PJM 总发电/净交换) 来自尖峰特征造成的读出爆掉; 把预测截断到训练目标取值范围 (不看测试标签) 即修复




图 9: 122 号: PJM 发电 / 联络线组的读出爆掉与预测截断修复

原图: DNN_Aggregation122/figures/fig5_collapse_fix.png

反直觉的副产品: 加上截断之后, 只预测目标的主干在任何指标上都不再优于随机初始化。它以前在 M 、认证上的一点“优势”, 来自塌缩表征碰巧不容易引发读出爆掉, 而不是学到了更多信息。

6 改进与定型 (122、125 号)

6.1 改进思路

- **重建主干**: 预训练损失 = 目标 MSE + 被遮候选列的重建 MSE, 提供与目标对齐的主方向和“运行状态”信息;
- **随机主干**: 同结构、不训练, 提供核回归的高维“主体”;
- 两者特征拼接后读出; 加三道数值防护 (标准差下限、特征截断、预测截断); 三个种子各自读出, 预测取平均。

选择规则在运行新候选之前写入配置文件, 避免事后挑选。

图1 候选估计器比较 (选择规则事先写入 base.yaml; 柱顶为绝对值)




图 10: 125 号: 候选估计器相对旧口径 E 的比较 (柱顶为绝对值)

原图: DNN_Aggregation125/figures/fig1_candidates.png

表 4: 125 号：候选估计器 (10 个目标平均；旧 E = 只预测目标的主干 ×3 种子)

指标	旧 E	C1 重建 ×3	C2 重建 ⊕ 随机 ×1	C3 重建 ⊕ 随机 ×3
V 误差 (规模 ≤ 3)	0.0264	0.0196	0.0196	0.0179
V 误差 (规模 4)	0.0379	0.0285	0.0295	0.0258
$M^{(2)}$ 误差	0.0211	0.0171	0.0163	0.0149
$M^{(2)}$ 排序 Spearman	0.957	0.963	0.965	0.968
认证前 1 / 前 3	0.934 / 0.970	0.961 / 0.978	0.960 / 0.977	0.961 / 0.978
背景召回前 3	0.67	0.71	0.71	0.74
每字段最大高估 (上尾)	0.074	0.055	0.049	0.048

定型为 C3: 10 项主要指标中 9 项不劣于其余候选, 且没有任何一项劣于旧 E; $M^{(2)}$ 误差 -29%, V 误差 -32%。代价是耗时约为旧 E 的 2.5 倍 (第 6 次会讲等价加速)。

6.2 下游结果全部重算

先用旧估计器跑一遍下游脚本, 确认与 117、124 号原结果**逐数一致**, 再换成 C3。




图 11: 125 号：下游结果用新估计器重算

原图: DNN_Aggresvation125/figures/fig2_downstream.png

表 5: 125 号：下游结果 (旧 E → C3)

下游结果	旧 E	C3
扫描—认证关键召回 $\tau = 0.5 / 0.7$ (精确率均为 1.00)	0.880 / 0.746	0.910 / 0.786
估计最小命中集扣留后残留危险组合 $\tau = 0.5 / 0.7$	5.8% / 1.8%	1.5% / 1.6%
自适应 $\hat{M}$ 贪心扣留后残留 $\tau = 0.5 / 0.7$	2.3% / 1.3%	0.3% / 1.3%
背景放大量 $\Gamma^{(2)}$ 误差	0.017	0.014
危险背景召回前 1 / 前 3	0.47 / 0.67	0.55 / 0.74

如实记录: 加保守余量 $\delta = 0.05$ 时, C3 的召回比旧 E 低约 0.01。原因是旧 E 的共同低估更大, δ 恰好补偿了它; 新估计器偏差小, $\delta = 0$ 就够用。

7 小结与下一次

小结

- 估计器中起决定作用的是**逐子集闭式读出**；只预测目标的掩码预训练会塌缩，在小集合上不比随机网络好。
- 改为“**目标 + 重建**”预训练，与随机特征拼接，加**预测截断**后，预训练才真正起作用： $M^{(2)}$ 误差降 29%，关键字段召回 $0.746 \rightarrow 0.786$ ($\tau = 0.7$)。
- 论文中的表述相应调整：贡献是“逐子集读出 + 带重建的掩码条件特征”，不是“预训练本身让 V 更准”。
- 选估计器看**边际保真度**和**误差上尾**，不看集合值误差。

下一次：统一计时（等价的快速读出），以及与 TabPFN、LazyVI 等外部“免重训”方法的对比。